



COLEGIO DE POSTGRADUADOS

COLEGIO DE POSTGRADUADOS

**INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS**

CAMPUS MONTECILLO

PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

DISTRIBUCIONES ESTADÍSTICAS DE VARIABLE ALEATORIA

Ajuste de Distribuciones

Geoestadística aplicada en el estudio de los recursos forestales

Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Perez Vazquez

I. ASPECTOS PRELIMINARES

Se utilizaron dos variables de interés para el cálculo de probabilidades y el ajuste de distribuciones: contenido de carbono y contenido de nitrógeno en la capa de hojarasca de mantillo. Se realizó un análisis descriptivo previo de cada una de las variables y se determinó la distribución de probabilidad con un nivel de significancia de 5%.

II. DISTRIBUCIONES DE PROBABILIDAD CON R

El paquete stats de R implementa numerosas funciones para la realización de cálculos asociados a distintas distribuciones de probabilidad. Para las distribuciones continuas, se encuentran la distribución uniforme, normal, t Student, F Fisher, Chi-Cuadrada, Exponencial, Gamma, Weibull. Para cada distribución, R dispone de cuatro funciones. Se puede acceder a cada una de ellas simplemente precediendo el nombre de la distribución por las siguientes letras:

Cuadro 1. Prefijos para R

PREFIJO	DESCRIPCIÓN
D	Función de densidad o de probabilidad
P	Función de distribución
Q	Función para el cálculo de cuantiles
R	Función para simular datos con dicha distribución

El procedimiento general de la prueba es:

- 1) Obtener los datos de la variable aleatoria a analizar.
- 2) Calcular la media y la varianza de los datos.
- 3) Crear un histograma y obtener la frecuencia observada en cada intervalo.
- 4) Establecer la hipótesis nula, proponiendo una distribución de probabilidad que se ajuste a la forma del histograma.
- 5) Calcular la frecuencia esperada, a partir de la función de probabilidad propuesta
- 6) Calcular el estadístico de prueba
- 7) Definir el nivel de significancia de la prueba y determinar el valor crítico de la misma
- 8) Comparar el estadístico de prueba con el valor crítico. Si el estadístico de prueba es menor que el valor crítico no se puede rechazar la hipótesis nula.

III. ANALISIS INDIVIDUAL DEL CONJUNTO DE DATOS

Medidas descriptivas de los datos.

Como primer paso se realizó un análisis exploratorio, obteniendo las estadísticas descriptivas principales (media, mediana, varianza, desviación estándar, asimetría y curtosis) para cada una de las variables de interés.

Cuadro 2. Medidas descriptivas de localización y dispersión del conjunto de datos.

Variable	N	Media	Mediana	Varianza	Desviación estándar	Asimetría	Curtosis
<i>Contenido de C</i>	40	4.449085	4.75885	1.371148	1.17096	-0.4261311	1.995028
<i>Contenido de N</i>	40	0.1186408	0.12419	0.0009567886	0.030932	-0.0013720	2.242991

Se observa que, para ambas variables, la media y la mediana presentan una similitud, ambas muestran una simetría negativa, con ligera tendencia hacia la izquierda, sin embargo, para la variable *contenido de nitrógeno*, el valor de su simetría es más cercano a cero. La curtosis es positiva para ambas variables, lo que indica que la distribución tiene colas más pesadas que la distribución normal. En adición, la desviación estándar indica una mayor variabilidad para el caso de contenido de C en comparación con el contenido de N.

SCRIPT PARA CONTENIDO DE C	SCRIPT PARA CONTENIDO DE N
<pre>summary(datos\$CONT_C) length(datos\$CONT_C) mean(datos\$CONT_C) median(datos\$CONT_C) var(datos\$CONT_C) sd(datos\$CONT_C) skewness(datos\$CONT_C) kurtosis(datos\$CONT_C)</pre>	<pre>summary(datos\$CONT_N) length(datos\$CONT_N) mean(datos\$CONT_N) median(datos\$CONT_N) var(datos\$CONT_N) sd(datos\$CONT_N) skewness(CONT_N) kurtosis(CONT_N)</pre>

Gráficos de análisis de distribución

Se crearon los histogramas de frecuencias relativas para ambas variables y se sobrepuso la curva de función de densidad. En el caso del histograma de Contenido de C se aprecia que la distribución de los datos se encuentra sesgada a la izquierda. Para el contenido de Nitrógeno, se observa una ligera asimetría a la derecha, sin embargo, se aprecia una distribución bimodal con dos picos.




Figura 1. Histogramas de Frecuencias Relativas y Función de Densidad de Probabilidad.

SCRIPT PARA HISTOGRAMAS Y FUNCION DE DENSIDAD

#Elaboración de histogramas

```

par(mfrow=c(1,2))
hist(datos$CONT_C,main = "Histograma de Contenido de C",xlab = "Contenido de C",ylab = "Densidad",density = 20,xlim = c(2,7),plot = TRUE,probability = TRUE,col = "azure3",border = "azure4")
lines(density(datos$CONT_C),col="red",lwd=2)
hist(datos$CONT_N,main = "Histograma de Contenido de N",xlab = "Contenido de N",ylab = "Densidad",density = 20,plot = TRUE,probability = TRUE,col = "azure3",border = "azure4")
lines(density(datos$CONT_N),col="red",lwd=2)
dev.off()

```

Antes de ajustar una o más distribuciones a un conjunto de datos, generalmente es necesario elegir buenos candidatos entre un conjunto predefinido de distribuciones. Esta elección puede facilitarse a partir de la observación de la curva de función de distribución acumulativa empírica para cada una de las variables de interés.




Figura 2. Función de distribución acumulada empírica

SCRIPT PARA FUNCIÓN DE DISTRIBUCIÓN ACUMULATIVA EMPÍRICA
<pre>#Función de distribución acumulativa empírica par(mfrow=c(1,2)) plot(ecdf(datos\$CONT_C),main="ECDF - Contenido de C",cex.main=1,xlim=c(2,7)) plot(ecdf(datos\$CONT_N),main="ECDF - Contenido de N", cex.main=1, xlim=c(0.05,0.20)) dev.off()</pre>

El diagrama QQ es un diagrama de dispersión que compara las distribuciones ajustadas y empíricas en términos de los valores dimensionales de las variables, es decir, los cuartiles empíricos. Es una técnica gráfica para determinar si el conjunto de datos proviene de una población conocida. En el eje Y se tienen los cuartiles empíricos y en el eje X tenemos los obtenidos por el modelo teórico.




Figura 3. QQ Plot para normalidad de la variable Contenido de C




Figura 4. QQ Plot para normalidad de la variable Contenido de N.

En este caso, se muestran las dos gráficas, dado que QQNorm sirve para probar la bondad de ajuste de una distribución gaussiana y QQPlot se utiliza para cualquier tipo de

distribución. La línea de referencia de 45 grados, sin embargo, se encuentran dentro de los intervalos de confianza, por lo cual se podría asumir que tienen una distribución normal. No obstante, los datos pueden provenir de una distribución que puede diferir a esta distribución, dado que la interpretación puede ser subjetiva, por lo que se realizaron otras pruebas de normalidad.

SCRIPT PARA LA GRÁFICA QQPLOT Y QQNORM

```
#Grafica QQ

par(mfrow=c(1,2))
qqnorm(Carb.estandar,main = "Normal QQNorm - Contenido de C")
abline(0,1)
qqPlot(CONT_C,main = "QQPlot - Contenido de C",ylab = "Contenido de C")
dev.off()

par(mfrow=c(1,2))
qqnorm(Nitr.estandar,main = "Normal QQNorm - Contenido de N")
abline(0,1)
qqPlot(CONT_N,main = "QQPlot - Contenido de N",ylab = "Contenido de N")
dev.off()
```

IV. GENERACIÓN DE MUESTRAS ALEATORIAS

Se diseñó un script para generar la muestra de una distribución T student, F, Normal, Weibull, Gamma, Uniforme, Beta, Cauchy, Exponencial y Chi Cuadrada. Además se graficó su respectivo histograma, la función de densidad empírica por Kernel de la muestra aleatoria, la función de densidad teórica de la distribución en turno, su gráfica de función de distribución acumulada empírica, su gráfica QQ, sus pruebas y medidas de bondad de ajuste. Se utilizaron las pruebas de Kolmogorov Smirlov, Anderson & Darling y la de Cramer-von Misses para probar el ajuste.

1-. Distribución T Student

Para la generación de una muestra aleatoria T-Student con 10 grados de libertad y sus respectivas gráficas se utilizó el siguiente script.

SCRIPT PARA DISTRIBUCIÓN T-STUDENT

```
#####Simulacion de muestras aleatorias

##Distribución t student

xt<-rt(n=200,df=10)

par(mfrow=c(2,2))
hist(xt,main = "Histograma de datos observados",probability = TRUE,xlab = "X - T student",
ylab="Densidad",plot = TRUE,col = "azure3",border = "azure4")
lines(density(xt),col="red",lwd=2)
legend("topleft",legend = "Funcion de densidad",col = "red",lty = 1:2,cex = 0.6)
plot(density(xt),main="densidad de datos estimados")
curve(dt(x,df=10),from = -4,to = 4,main="T - student densidad teorica",add = TRUE,col="red")
legend("topleft",legend = c("Densidad empirica","Densidad teorica"),
      col = c("black","red"),lty=1:2,cex=0.6)
qqt(xt,df=10,main = "QQ Plot - Tstudent")
abline(0,1)dev.off()
```




Figura 5. Simulación de muestra aleatoria – T Student.

En las gráficas anteriores se observa un buen ajuste para dicha distribución generada. La distribución t es una distribución continua que se especifica por el número de grados de libertad. Es una distribución simétrica, con forma de campana similar a la distribución normal, pero con colas más gruesas.

De acuerdo con las pruebas de bondad de ajuste con las hipótesis, $H_0 = X \sim t \text{ student}$; y $H_1 = \text{Otra distribución}$. Dado que $P\text{value} > 0.05$, se acepta la hipótesis H_0 .

Cuadro 3. Pruebas de bondad de ajuste para la distribución T-Student.

Test	Script	Pvalue	Conclusión
Kolmogorov-Smirnov	<pre>> ks.test(xt,"pt",10) One-sample Kolmogorov-Smirnov test data: xt D = 0.043252, p-value = 0.8485 alternative hypothesis: two-sided</pre>	0.8485	No se rechaza
Anderson & Darling	<pre>> ad.test(xt,"pt",df=10) Anderson-Darling test of goodness-of-fit Null hypothesis: Student's t distribution with parameter df = 10 data: xt An = 0.5684, p-value = 0.6782</pre>	0.6782	No se rechaza
Cramer-von Misses	<pre>> cvm.test(xt,"pt",df=10) Cramer-von Mises test of goodness-of-fit Null hypothesis: Student's t distribution with parameter df = 10 data: xt omega2 = 0.06472, p-value = 0.7849</pre>	0.7849	No se rechaza

2-. Distribución F

Para la generación de una muestra aleatoria con distribución F con parámetros $df_1=10$ y $df_2=5$ (grados de libertad) y sus respectivas gráficas, se utilizó el siguiente script.

SCRIPT PARA DISTRIBUCIÓN F

```
##Distribución F
xf<-rf(n=200,df1 = 10,df2 = 5)

par(mfrow=c(2,2))
hist(xf,main = "Histograma de datos observados",probability = TRUE,xlab = "X - D
istribución F",ylab="Densidad",plot = TRUE,col = "azure3",border = "azure4",ylim
= c(0.0,0.8))
lines(density(xf),col="red",lwd=2)
legend("topright",legend = "Funcion de densidad",col = "red",lty = 1:2,cex = 0.6
)
plot(density(xf),main="densidad de datos estimados")
curve(df(x,df1 = 10,df2=5),from = 0,to = 14,main="F - densidad teorica",add = TR
UE,col="red")
legend("topright",legend = c("Densidad empirica","Densidad teorica"),
      col = c("black","red"),lty=1:2,cex=0.6)
plot(ecdf(xf),main="Funcion de distribución acumulativa empirica")
qqf(xf,df1 =10,df2=5,main = "QQ Plot - F")
abline(0,1)
dev.off()
```




Figura 6. Simulación de muestra aleatoria – Distribución F

Las gráficas anteriores muestran un buen ajuste para dicha distribución generada. Se observa que en este tipo de distribuciones muestran una asimetría hacia la derecha, que es descrita por los grados de libertad.

De acuerdo con las pruebas de bondad de ajuste con las hipótesis, $H_0 = X \sim F$; y $H_1 = \text{Otra distribución}$. Dado que $P\text{value} > 0.05$, se acepta la hipótesis H_0 .

Cuadro 4. Pruebas de bondad de ajuste para la distribución F.

Test	Script	Pvalue	Conclusión
Kolmogorov-Smirnov	<pre>> ks.test(xf,"pf",df1 = 10,df2 = 5)</pre> One-sample Kolmogorov-Smirnov test data: xf D = 0.043236, p-value = 0.8488 alternative hypothesis: two-sided	0.8488	No se rechaza
Anderson & Darling	<pre>> ad.test(xf,"pf",df1 = 10,df2 = 5)</pre> Anderson-Darling test of goodness-of-fit Null hypothesis: F distribution with parameters df1 = 10, df2 = 5 data: xf An = 0.52, p-value = 0.7263	0.7263	No se rechaza
Cramer-von Misses	<pre>> cvm.test(xf,"pf",df1 = 10,df2 = 5)</pre> Cramer-von Mises test of goodness-of-fit Null hypothesis: F distribution with parameters df1 = 10, df2 = 5 data: xf omega2 = 0.060279, p-value = 0.8128	0.8128	No se rechaza

3-. Distribución Normal

Para la generación de una muestra aleatoria con distribución normal, con media = 4.449085 y sd = 1.156231, y sus respectivas gráficas se utilizó el siguiente script.

SCRIPT PARA DISTRIBUCIÓN NORMAL
<pre>##Distribución Normal xnormal<-rnorm(n=200,m=4.449085,sd=1.156231) par(mfrow=c(2,2)) hist(xnormal,main = "Histograma de datos observados",probability = TRUE,xlab = " X - Distribución Normal",ylab="Densidad",plot = TRUE,col = "azure3",border = "az ure4",ylim = c(0.0,0.4)) lines(density(xnormal),col="red",lwd=2)</pre>

```

legend("topleft",legend = "Funcion de densidad",col = "red",lty = 1:2,cex = 0.6)

plot(density(xnormal),main="densidad de datos estimados")
curve(dnorm(x,m=4.449085,sd=1.156231),from = 0,to = 8,main="Normal - densidad te
orica",add = TRUE,col="red")
legend("topleft",legend = c("Densidad empirica","Densidad teorica"),
      col = c("black","red"),lty=1:2,cex=0.6)
plot(ecdf(xnormal),main="Funcion de distribución acumulativa empirica")
qqPlot(xnormal,distribution="norm",main = "Normal - QQ-Plot")
dev.off()

```

Se obtuvieron las siguientes gráficas en donde se observa el comportamiento de la muestra para dicha distribución generada.




Figura 7. Simulación de muestra aleatoria – Distribución Normal

De acuerdo con las pruebas de bondad de ajuste con las hipótesis, $H_0 = X \sim \text{Normal}$; y $H_1 = \text{Otra distribución}$. Dado que $P\text{value} > 0.05$, se acepta la hipótesis H_0 .

Cuadro 5. Pruebas de bondad de ajuste para la distribución Normal.

Test	Script	Pvalue	Conclusión
Kolmogorov-Smirnov	<pre>> ks.test(xnormal,"pnorm",4.449085,1.156231)</pre> One-sample Kolmogorov-Smirnov test data: xnormal D = 0.045322, p-value = 0.8059 alternative hypothesis: two-sided	0.8059	No se rechaza
Anderson & Darling	<pre>> ad.test(xnormal,"pnorm",4.449085,1.156231)</pre> Anderson-Darling test of goodness-of-fit fit Null hypothesis: Normal distribution data: xnormal An = 0.53514, p-value = 0.711	0.711	No se rechaza
Cramer-von Misses	<pre>> cvm.test(xnormal,"pnorm",4.449085,1.156231)</pre> Cramer-von Mises test of goodness-of-fit fit Null hypothesis: Normal distribution data: xnormal omega2 = 0.082523, p-value = 0.6779	0.6779	No se rechaza

4-. Distribución Weibull

Para la generación de una muestra aleatoria con distribución Weibull con parámetros shape = 4.656166 y scale= 4.885373 y sus respectivas gráficas se utilizó el siguiente script.

SCRIPT PARA DISTRIBUCIÓN WEIBULL
<pre>##Distribución weibull xweibull<-rweibull(n=200,scale = 4.656166,shape = 4.885373) par(mfrow=c(2,2)) hist(xweibull,main = "Histograma de datos observados",probability = TRUE,xlab = "X - Distribución weibull",ylab="Densidad",plot = TRUE,col = "azure3",border = "azure4",ylim = c(0.0,0.4),xlim = c(0,8)) lines(density(xweibull),col="red",lwd=2) legend("topright",legend = "Funcion de densidad",col = "red",lty = 1:2,cex = 0.6) plot(density(xweibull),main="densidad de datos estimados") curve(dweibull(x,scale =4.885373,shape = 4.656166),from = 0,to = 8,main="weibull - densidad teorica",add = TRUE,col="red") legend("topleft",legend = c("Densidad empirica","Densidad teorica"),col = c("black","red"),lty=1:2,cex=0.6) plot(ecdf(xweibull),main="Funcion de distribución acumulativa empirica")</pre>

```
qqPlot(xweibull,distribution = "weibull",scale=2.5,shape=1.5,las = 1,main = "weibull Q-Q Plot")
dev.off()
```

Se obtuvieron las siguientes gráficas en donde se observa el comportamiento de la muestra con dicha distribución. El parámetro de forma describe la manera en que se distribuyen los datos, se aprecia que la distribución se aproxima a una curva normal.




Figura 8. Simulación de muestra aleatoria – Distribución Weibull

De acuerdo con las pruebas de bondad de ajuste con las hipótesis, $H_0 = X \sim \text{Weibull}$; y $H_1 = \text{Otra distribución}$. Dado que $P\text{value} > 0.05$, se acepta la hipótesis H_0 .

Cuadro 6. Pruebas de bondad de ajuste para la distribución Weibull.

Test	Script	Pvalue	Conclusión
Kolmogorov-Smirnov	<pre>> ks.test(xweibull,"pweibull",scale = 4.656166,shape = 4.885373)</pre> One-sample Kolmogorov-Smirnov test data: xweibull D = 0.048952, p-value = 0.724 alternative hypothesis: two-sided	0.724	No se rechaza
Anderson & Darling	<pre>> ad.test(xweibull,"pweibull",scale = 4.656166,shape = 4.885373)</pre> Anderson-Darling test of goodness-of-fit Null hypothesis: Weibull distribution with parameters scale = 4.656166, shape = 4.885373 data: xweibull An = 0.59641, p-value = 0.6512	0.6512	No se rechaza
Cramer-von Misses	<pre>> cvm.test(xweibull,"pweibull",scale = 4.656166,shape = 4.885373)</pre> Cramer-von Mises test of goodness-of-fit Null hypothesis: weibull distribution with parameters scale = 4.656166, shape = 4.885373 data: xweibull omega2 = 0.070922, p-value = 0.7465	0.7465	No se rechaza

5-. Distribución Gamma

Para la generación de una muestra aleatoria con distribución Gamma con parámetros shape=12.874768 y rate=2.893995, y sus respectivas gráficas se utilizó el siguiente script.

SCRIPT PARA DISTRIBUCIÓN GAMMA
<pre>## Distribución Gamma xgamma<-rgamma(200,shape = 12.874768,rate=2.893995) par(mfrow=c(2,2)) hist(xgamma,main = "Histograma de datos observados",probability = TRUE,xlab = "X - Distribución Gamma",ylab="Densidad",plot = TRUE,col = "azure3",border = "azure4",ylim = c(0.0,0.35),xlim = c(0,10)) lines(density(xgamma),col="red",lwd=2) legend("topright",legend = "Funcion de densidad",col = "red",lty = 1:2,cex = 0.6)</pre>

```

plot(density(xgamma),main="densidad de datos estimados")
curve(dgamma(x,shape = 12.874768,rate=2.893995),from = 0,to = 10,main="Gamma - d
ensidad teorica",add = TRUE,col="red")
legend("topright",legend = c("Densidad empirica","Densidad teorica"),
      col = c("black","red"),lty=1:2,cex=0.6)
plot(ecdf(xgamma),main="Funcion de distribución acumulativa empirica")
qqPlot(xgamma,distribution = "gamma",shape = 12.874768,rate=2.893995,main = "Gam
ma Q-Q Plot")
dev.off()

```




Figura 9. Simulación de muestra aleatoria – Distribución Gamma

En las gráficas anteriores se observa el comportamiento de los datos con dicha distribución, en las cuales se aprecia que esta distribución sigue una asimetría hacia la derecha.

De acuerdo con las pruebas de bondad de ajuste con las hipótesis, $H_0 = X \sim \text{Gamma}$; y $H_1 = \text{Otra distribución}$. Dado que $P\text{value} > 0.05$, se acepta la hipótesis H_0 .

Cuadro 7. Pruebas de bondad de ajuste para la distribución Gamma.

Test	Script	Pvalue	Conclusión
Kolmogorov-Smirnov	<pre>> ks.test(xgamma,"pgamma",shape = 12.874768,rate=2.893995)</pre> One-sample Kolmogorov-Smirnov test data: xgamma D = 0.060072, p-value = 0.466 alternative hypothesis: two-sided	0.466	No se rechaza
Anderson & Darling	<pre>> ad.test(xgamma,"pgamma",shape = 12.874768,rate=2.893995)</pre> Anderson-Darling test of goodness-of-fit Null hypothesis: Gamma distribution with parameters shape = 12.874768, rate = 2.893995 data: xgamma An = 0.86936, p-value = 0.4335	0.4335	No se rechaza
Cramer-von Mises	<pre>> cvm.test(xgamma,"pgamma",shape = 12.874768,rate=2.893995)</pre> Cramer-von Mises test of goodness-of-fit Null hypothesis: Gamma distribution with parameters shape = 12.874768, rate = 2.893995 data: xgamma omega2 = 0.13783, p-value = 0.4292	0.4292	No se rechaza

6-. Distribución Uniforme

Para la generación de una muestra aleatoria con distribución uniforme con parámetros min=8 y max=30, y sus respectivas gráficas se utilizó el siguiente script.

SCRIPT PARA DISTRIBUCIÓN UNIFORME
<pre>##Distribución Uniforme xunifor<-runif(200,min = 8,max = 30) par(mfrow=c(2,2)) hist(xunifor,main = "Histograma de datos observados",probability = TRUE,xlab = "X - Distribución Uniforme",ylab="Densidad",plot = TRUE,col = "azure3",border = "azure4",ylim = c(0.0,0.1),xlim = c(7,31)) lines(density(xunifor),col="red",lwd=2)</pre>

```

legend("topright",legend = "Funcion de densidad",col = "red",lty = 1:2,cex = 0.6
)

plot(density(xunifor),main="densidad de datos estimados")
curve(dunif(x,min = 8,max = 30),from = 7,to = 31,main="Uniforme - densidad teórica",add = TRUE,col="red")
legend("center",legend = c("Densidad empirica","Densidad teorica"),
      col = c("black","red"),lty=1:2,cex=0.6)
plot(ecdf(xunifor),main="Funcion de distribución acumulativa empirica")
qqPlot(xunifor,distribution = "unif",min=8,max=30,main = "Uniforme Q-Q Plot")
dev.off()

```

Se obtuvieron las siguientes gráficas, en donde se observa el comportamiento de la muestra generada a partir de dicha distribución.




Figura 10. Simulación de muestra aleatoria – Distribución Uniforme

De acuerdo con las pruebas de bondad de ajuste con las hipótesis, $H_0 = X \sim \text{Uniforme}$; y $H_1 = \text{Otra distribución}$. Dado que $P\text{value} > 0.05$, se acepta la hipótesis H_0 .

Cuadro 8. Pruebas de bondad de ajuste para la distribución Uniforme.

Test	Script	Pvalue	Conclusión
Kolmogorov-Smirnov	<pre>> ks.test(xunifor,"punif",min = 8,max = 30)</pre> One-sample Kolmogorov-Smirnov test data: xunifor D = 0.065698, p-value = 0.3538 alternative hypothesis: two-sided	0.3538	No se rechaza
Anderson & Darling	<pre>> ad.test(xunifor,"punif",min = 8,max = 30)</pre> Anderson-Darling test of goodness-of-fit Null hypothesis: uniform distribution with parameters min = 8, max = 30 data: xunifor An = 1.1246, p-value = 0.2979	0.2979	No se rechaza
Cramer-von Mises	<pre>> cvm.test(xunifor,"punif",min = 8,max = 30)</pre> Cramer-von Mises test of goodness-of-fit Null hypothesis: uniform distribution with parameters min = 8, max = 30 data: xunifor omega2 = 0.22611, p-value = 0.2222	0.2222	No se rechaza

7-. Distribución Beta

Para la generación de una muestra aleatoria con distribución beta con parámetros 4 y 2.5, y sus respectivas gráficas se utilizó el siguiente script.

SCRIPT PARA DISTRIBUCIÓN BETA
<pre>##Distribución beta xbeta<-rbeta(200,shape1 = 4,shape2 = 2.5) par(mfrow=c(2,2)) hist(xbeta,main = "Histograma de datos observados",probability = TRUE,xlab = "X - Distribución Beta",ylab="Densidad",plot = TRUE,col = "azure3",border = "azure4", ylim = c(0,2.5),xlim = c(0,1)) lines(density(xbeta),col="red",lwd=2) legend("topleft",legend = "Funcion de densidad",col = "red",lty = 1:2,cex = 0.6) plot(density(xbeta),main="densidad de datos estimados") curve(dbeta(x,shape1 = 4,shape2 = 2.5),from = 0,to = 1,main="Beta - densidad teo rica",add = TRUE,col="red") legend("topleft",legend = c("Densidad empirica","Densidad teorica"), col = c("black","red"),lty=1:2,cex=0.6) plot(ecdf(xbeta),main="Funcion de distribución acumulativa empirica") qqPlot(xbeta,distribution = "beta",shape1=4,shape2=2.5,main = "Beta Q-Q Plot")</pre>

Se obtuvieron las siguientes gráficas en donde se observa el comportamiento de la muestra con dicha distribución. La distribución beta es una distribución continua definida por dos parámetros de forma. La distribución puede adoptar diferentes formas dependiendo de los valores de los dos parámetros. En este caso, cuando la primera forma es mayor que la segunda forma, la distribución es asimétrica hacia la izquierda.




Figura 11. Simulación de muestra aleatoria – Distribución Beta

De acuerdo con las pruebas de bondad de ajuste con las hipótesis, $H_0 = X \sim \text{Beta}$; y $H_1 = \text{Otra distribución}$. Dado que $P\text{value} > 0.05$, se acepta la hipótesis H_0 .

Cuadro 9. Pruebas de bondad de ajuste para la distribución Beta.

Test	Script	Pvalue	Conclusión
Kolmogorov-Smirnov	<pre>> ks.test(xbeta,"pbeta",shape1 = 4, shape2 = 2.5)</pre> One-sample Kolmogorov-Smirnov test data: xbeta D = 0.049461, p-value = 0.7121 alternative hypothesis: two-sided	0.7121	No se rechaza
Anderson & Darling	<pre>> ad.test(xbeta,"pbeta",shape1 = 4, shape2 = 2.5)</pre> Anderson-Darling test of goodness-of-fit Null hypothesis: beta distribution with parameters shape1 = 4, shape2 = 2.5 data: xbeta An = 0.70955, p-value = 0.5507	0.5507	No se rechaza
Cramer-von Mises	<pre>> cvm.test(xbeta,"pbeta",shape1 = 4,shape2 = 2.5)</pre> Cramer-von Mises test of goodness-of-fit Null hypothesis: beta distribution with parameters shape1 = 4, shape2 = 2.5 data: xbeta omega2 = 0.10542, p-value = 0.5594	0.5594	No se rechaza

8-. Distribución Cauchy

Para la generación de una muestra aleatoria con distribución Cauchy con parámetros 9 y 3, y sus respectivas gráficas se utilizó el siguiente script.

SCRIPT PARA DISTRIBUCIÓN CAUCHY
<pre>##Distribución Cauchy xcauchy<-rcauchy(200,location = 9,scale = 3) par(mfrow=c(2,2)) hist(xcauchy,main = "Histograma de datos observados",probability = TRUE,xlab = " X - Distribución Cauchy",ylab="Densidad",plot = TRUE,col = "azure3",border = "az ure4") lines(density(xcauchy),col="red",lwd=2) legend("topleft",legend = "Funcion de densidad",col = "red",lty = 1:2,cex = 0.6) plot(density(xcauchy),main="densidad de datos estimados") curve(dcauchy(x,location = 9,scale = 3),from = -150,to = 100,main="Beta - densid ad teorica",add = TRUE,col="red")</pre>

```

legend("topleft",legend = c("Densidad empirica","Densidad teorica"),
      col = c("black","red"),lty=1:2,cex=0.6)
plot(ecdf(xcauchy),main="Funcion de distribución acumulativa empirica")
qqPlot(xcauchy,distribution = "cauchy",location=9,scale=3,main = "Cauchy Q-Q Plot")
dev.off()

```

Se obtuvieron las siguientes gráficas en donde se observa el comportamiento de la muestra con dicha distribución. La distribución de Cauchy se representa con una curva en forma de campana, similar a una distribución normal, Sin embargo, en la distribución de Cauchy, las colas se aproximan a cero con mayor lentitud que las colas de la distribución normal.




Figura 12. Simulación de muestra aleatoria – Distribución Cauchy

De acuerdo con las pruebas de bondad de ajuste con las hipótesis, $H_0 = X \sim \text{Cauchy}$; y $H_1 = \text{Otra distribución}$. Dado que $P\text{value} > 0.05$, se acepta la hipótesis H_0 .

Cuadro 10. Pruebas de bondad de ajuste para la distribución Cauchy.

Test	Script	Pvalue	Conclusión
Kolmogorov-Smirnov	<pre>> ks.test(xcauchy,"pcauchy",location = 9,scale = 3)</pre> One-sample Kolmogorov-Smirnov test data: xcauchy D = 0.051135, p-value = 0.6724 alternative hypothesis: two-sided	0.6724	No se rechaza
Anderson & Darling	<pre>> ad.test(xcauchy,"pcauchy",location = 9,scale = 3)</pre> Anderson-Darling test of goodness-of-fit Null hypothesis: Cauchy distribution with parameters location = 9, scale = 3 data: xcauchy An = 0.74644, p-value = 0.5211	0.5211	No se rechaza
Cramer-von Misses	<pre>> cvm.test(xcauchy,"pcauchy",location = 9,scale = 3)</pre> Cramer-von Mises test of goodness-of-fit Null hypothesis: Cauchy distribution with parameters location = 9, scale = 3 data: xcauchy omega2 = 0.077553, p-value = 0.7067	0.7067	No se rechaza

9.- Distribución Exponencial

Para la generación de una muestra aleatoria con distribución Exponencial con rate=1 y sus respectivas gráficas se utilizó el siguiente script.

SCRIPT PARA DISTRIBUCIÓN EXPONENCIAL
<pre>## Distribucion Exponencial xexp<-rexp(n=200,rate = 1) par(mfrow=c(2,2)) hist(xexp,main = "Histograma de datos observados",probability = TRUE,xlab = "X - Distribución Exponencial",ylab="Densidad",plot = TRUE,col = "azure3",border = "azure4") lines(density(xexp),col="red",lwd=2) legend("topright",legend = "Funcion de densidad",col = "red",lty = 1:2,cex = 0.6)</pre>

```

plot(density(xexp),main="densidad de datos estimados")
curve(dexp(x,rate = 1),from = 0,to = 5,main="Exponencial - densidad teorica",add
= TRUE,col="red")
legend("topright",legend = c("Densidad empirica","Densidad teorica"),
      col = c("black","red"),lty=1:2,cex=0.6)
plot(ecdf(xexp),main="Funcion de distribución acumulativa empirica")
qqPlot(xexp,distribution = "exp",rate=1,main = "Exponencial Q-Q Plot")
dev.off()

```

Se obtuvieron las siguientes gráficas en donde se observa el comportamiento de la muestra con dicha distribución. Para la distribución exponencial de 1 parámetro, el valor umbral es cero y la distribución se define por su parámetro de escala. Para la distribución exponencial de 1 parámetro, el parámetro de escala es igual a la media.




Figura 13. Simulación de muestra aleatoria – Distribución Exponencial

De acuerdo con las pruebas de bondad de ajuste con las hipótesis, $H_0 = X \sim \text{Exponencial}$; y $H_1 = \text{Otra distribución}$. Dado que $P\text{value} > 0.05$, se acepta la hipótesis H_0 .

Cuadro 11. Pruebas de bondad de ajuste para la distribución Exponencial.

Test	Script	Pvalue	Conclusión
Kolmogorov-Smirnov	<pre>> ks.test(xexp,"pexp",rate = 1)</pre> One-sample Kolmogorov-Smirnov test data: xexp D = 0.047242, p-value = 0.7635 alternative hypothesis: two-sided	0.7635	No se rechaza
Anderson & Darling	<pre>> ad.test(xexp,"pexp",rate = 1)</pre> Anderson-Darling test of goodness-of-fit Null hypothesis: exponential distribution with parameter rate = 1 data: xexp An = 0.56328, p-value = 0.6832	0.6832	No se rechaza
Cramer-von Misses	<pre>> cvm.test(xexp,"pexp",rate = 1)</pre> Cramer-von Mises test of goodness-of-fit Null hypothesis: exponential distribution with parameter rate = 1 data: xexp omega2 = 0.10785, p-value = 0.5482	0.5482	No se rechaza

10.- Distribución Chi-cuadrada

Para la generación de una muestra aleatoria con distribución Chi-Cuadrada con 3 grados de libertad y sus respectivas gráficas se utilizó el siguiente script.

SCRIPT PARA DISTRIBUCIÓN CHI CUADRADA
<pre>##Distribucion Chi cuadrada xchi<-rchisq(n=200,df=3) par(mfrow=c(2,2)) hist(xchi,main = "Histograma de datos observados",probability = TRUE,xlab = "X - Distribución Chi-Cuadrada",ylab="Densidad",plot = TRUE,col = "azure3",border = "azure4") lines(density(xchi),col="red",lwd=2)</pre>

```

legend("topright",legend = "Funcion de densidad",col = "red",lty = 1:2,cex = 0.6
)

plot(density(xchi),main="densidad de datos estimados")
curve(dchisq(x,df=3),from = 0,to = 20,main="Chi-Cuadrada - densidad teorica",add
= TRUE,col="red")
legend("topright",legend = c("Densidad empirica","Densidad teorica"),
      col = c("black","red"),lty=1:2,cex=0.6)
plot(ecdf(xchi),main="Funcion de distribución acumulativa empirica")
qqPlot(xchi,distribution = "chisq",df=3,main = "Chi-Cuadrada Q-Q Plot")
dev.off()

> skewness(xchi)
[1] 1.525001

```




Figura 14. Simulación de muestra aleatoria – Distribución Exponencial

En las gráficas anteriores se observa el comportamiento de la muestra con dicha distribución. Se observa una asimetría hacia la derecha, la "cola" de la distribución apunta hacia la derecha y porque el valor de asimetría es mayor que 0 (es decir, positivo).

De acuerdo con las pruebas de bondad de ajuste con las hipótesis, $H_0 = X \sim \text{Chi-cuadrada}$; y $H_1 = \text{Otra distribución}$. Dado que $P\text{value} > 0.05$, se acepta la hipótesis H_0 .

Cuadro 12. Pruebas de bondad de ajuste para la distribución Chi-Cuadrada.

Test	Script	Pvalue	Conclusión
Kolmogorov-Smirnov	<pre>> ks.test(xchi,"pchisq",df=3)</pre> One-sample Kolmogorov-Smirnov test data: xchi D = 0.050295, p-value = 0.6924 alternative hypothesis: two-sided	0.6924	No se rechaza
Anderson & Darling	<pre>> ad.test(xchi,"pchisq",df=3)</pre> Anderson-Darling test of goodness-of-fit Null hypothesis: chi-squared distribution with parameter df = 3 data: xchi An = 0.3692, p-value = 0.8785	0.8785	No se rechaza
Cramer-von Mises	<pre>> cvm.test(xchi,"pchisq",df=3)</pre> Cramer-von Mises test of goodness-of-fit Null hypothesis: chi-squared distribution with parameter df = 3 data: xchi omega2 = 0.060373, p-value = 0.8122	0.8122	No se rechaza

V. AJUSTE DE DISTRIBUCIONES

1-. Distribución normal

La función de densidad de probabilidad de una variable aleatoria normal X viene determinada por dos parámetros: el valor esperado y la desviación típica de X . Estos valores se representan por μ y σ , respectivamente. Esto es, sean

$$\mu = E[X] \quad \text{y} \quad \sigma = sd(X)$$

La densidad de probabilidad normal tiene una forma acampanada que es simétrica respecto del valor μ . Su variabilidad viene medida por σ . Cuanto mayor es σ , mayor es la variabilidad de la variable. Si X sigue una distribución normal $N(\mu, \sigma)$, entonces:

$$f(x) = \text{dnorm}(x, \mu, \sigma)$$

$$P(X \leq k) = \text{pnorm}(x, \mu, \sigma)$$

$$q_a = \min\{x: P(X \leq x) \leq a\} = \text{qnorm}(a, \mu, \sigma)$$

$\text{rnorm}(n, \mu, \sigma)$ genera n valores aleatorios $N(\mu, \sigma)$

○ Ajuste de la distribución y establecimiento de hipótesis

El ajuste de la distribución se realizó a partir de la función `fitdist`, estableciendo el método de máxima verosimilitud para la estimación de parámetros. El ajuste de una distribución usando `fitdist` supone que se definen las funciones d , p , q correspondientes (que se mantienen respectivamente para la densidad, la distribución y las funciones cuantílicas).

Se obtuvieron los siguientes resultados:

SCRIPT PARA CONTENIDO DE C
<pre> > ##### Distribución normal > # ajuste de distribución > #contenido de C > ajusteCnormal<-fitdist(CONT_C,"norm",method = "mle") > ajusteCnormal Fitting of the distribution ' norm ' by maximum likelihood Parameters: estimate Std. Error mean 4.449085 0.1828161 sd 1.156231 0.1292701 > summary(ajusteCnormal) Fitting of the distribution ' norm ' by maximum likelihood Parameters : estimate Std. Error mean 4.449085 0.1828161 sd 1.156231 0.1292701 Loglikelihood: -62.56416 AIC: 129.1283 BIC: 132.5061 Correlation matrix: mean sd mean 1 0 sd 0 1 > plot(ajusteCnormal) </pre>

SCRIPT PARA CONTENIDO DE N

```

> #contenido de N
> ajusteNnormal <-fitdist(CONT_N,"norm",method = "mle")
> ajusten0
Fitting of the distribution ' norm ' by maximum likelihood
Parameters:
      estimate Std. Error
mean  0.1186408 0.004829257
sd    0.0305429 0.003398342
> summary(ajusteNnormal)
Fitting of the distribution ' norm ' by maximum likelihood
Parameters :
      estimate Std. Error
mean 0.1186408 0.004829257
sd   0.0305429 0.003398342
Loglikelihood: 82.78738   AIC:  -161.5748   BIC:  -158.197
Correlation matrix:
      mean sd
mean    1  0
sd      0  1

> plot(ajusteNnormal)

```

Los parámetros obtenidos por el ajuste a partir del método de máxima verosimilitud son los siguientes:

Cuadro 13. Parametros obtenidos para el ajuste de Distribución Normal.

	<i>Media</i>	<i>Desviación estándar</i>	<i>AIC</i>
Contenido de C	4.449085	1.156231	129.1283
Contenido de N	0.1186408	0.0305429	-161.5748

En las siguientes gráficas se observa para ambas variables que los datos pueden ajustarse a una distribución normal. La grafica de densidad que representa la función de densidad de la distribución ajustada a lo largo del histograma de distribución empírica presenta una asimetría con tendencia hacia la izquierda (negativa).




Figura 15. Gráficos de ajuste de distribución Normal para Contenido de C.




Figura 16. Gráficos de ajuste de distribución Normal para Contenido de N.

Posteriormente se establecieron las hipótesis para probar normalidad en cada una de las variables evaluadas.

$$H_0 = \text{Normal}(\mu, \sigma)$$

$$H_1 = \text{Otra distribución}$$

○ Pruebas de bondad de ajuste

Se realizaron las pruebas de Kolmogorov-Smirnov, Anderson Darling y Krammer Von Misses para probar la bondad de ajuste de la distribución de los datos. Se observa que para la variable Contenido de Carbono y Nitrogeno se aceptan las hipótesis de normalidad.

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE CARBONO
<pre> > ##Prueba de bondad de ajuste > #Contenido de C > ks.test(CONT_C,"pnorm",4.449085,1.156231) One-sample Kolmogorov-Smirnov test data: CONT_C D = 0.1359, p-value = 0.4141 alternative hypothesis: two-sided > ad.test(CONT_C,"pnorm",4.449085,1.156231) Anderson-Darling test of goodness-of-fit Null hypothesis: Normal distribution data: CONT_C An = 0.95248, p-value = 0.3826 > cvm.test(CONT_C,"pnorm",4.449085,1.156231) Cramer-von Mises test of goodness-of-fit Null hypothesis: Normal distribution data: CONT_C omega2 = 0.16849, p-value = 0.3388 </pre>
SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE NITROGENO
<pre> > #Contenido de N > ks.test(CONT_N,"pnorm",0.1186408,0.0305429) One-sample Kolmogorov-Smirnov test data: CONT_N D = 0.11879, p-value = 0.5837 alternative hypothesis: two-sided </pre>

```

> ad.test(CONT_N,"pnorm",0.1186408,0.0305429)

Anderson-Darling test of goodness-of-fit
Null hypothesis: Normal distribution

data:  CONT_N
An = 0.6197, p-value = 0.6285

> cvm.test(CONT_N,"pnorm",0.1186408,0.0305429)

Cramer-von Mises test of goodness-of-fit
Null hypothesis: Normal distribution

data:  CONT_N
omega2 = 0.10932, p-value = 0.5432

```

○ Cálculo de probabilidades

Para calcular la probabilidad de que x tome un valor dado se utilizó la función *pnorm*. En este caso, se tomaron como parámetros los obtenidos anteriormente para los contenidos de C con distribución $N(\mu = 4.4490, \sigma = 1.15623)$

Cuadro 14. Cálculo de probabilidades - Contenido de C.

	$P(X \leq 5)$	$P(X > 4)$	$P(2 \leq X \leq 4)$
Contenido de C	0.6831319	0.6511415	0.3317778

Se muestra el ejemplo, para el caso de que la probabilidad de tener contenidos de carbono sea $P(2 \leq X \leq 4) = 0.33$ donde la siguiente grafica representa el área bajo la curva.

SCRIPT PARA EL CÁLCULO DE PROBABILIDADES NORMALES PARA CONTENIDO DE C
<pre> > #Calculo de probabilidades > #Contenido de C > pnorm(5,mean = 4.449085,sd=1.156231) [1] 0.6831319 > 1-pnorm(4,mean = 4.449085,sd=1.156231) [1] 0.6511415 > pnorm(4,mean = 4.449085,sd=1.156231,lower.tail = FALSE) [1] 0.6511415 </pre>


```

> pnorm(4,mean = 4.449085,sd=1.156231)-pnorm(2,mean = 4.449085,sd=1.156231)
[1] 0.3317778
> regionX=seq(2,4,0.05)
> xP<-c(2,regionX,4)
> yp<-c(0,dnorm(regionX,mean = 4.449085,sd=1.156231),0)
> curve(dnorm(x,mean = 4.449085,sd=1.156231),xlim = c(0,7),main = "Densidad N(4.44,1.15)")
> polygon(xP,yp,col = "orange1")
> box()

```




Figura 17. Área bajo la curva para la $P(2 \leq X \leq 4)$ de Contenido de Carbono.

Para el caso de la segunda variable, se tomaron como parámetros los obtenidos anteriormente para los contenidos de N con distribución $N(\mu = 0.1186, \sigma = 0.0305)$.

Cuadro 15. Cálculo de probabilidades - Contenido de N.

	$P(X \leq 0.13)$	$P(X > 0.09)$	$P(0.06 \leq X \leq 0.11)$
Contenido de N	0.6450199	0.8258068	0.3611919

Se muestra el ejemplo, para el caso de que la probabilidad de tener contenidos de nitrógeno sea $P(0.06 \leq X \leq 0.11) = 0.36$ donde la siguiente grafica representa el área bajo la curva.

SCRIPT PARA EL CALCULO DE PROBABILIDADES NORMALES PARA CONTENIDO DE N

```
> #Contenido de N
> pnorm(0.13,mean = 0.1186408,sd=0.0305429)
[1] 0.6450199
> 1-pnorm(0.09,mean = 0.1186408,sd=0.0305429)
[1] 0.8258068
> pnorm(0.11,mean =0.1186408,sd=0.0305429)-pnorm(0.06,mean = 0.1186408,s
d=0.0305429)
[1] 0.3611919
> regionX1=seq(0.06,0.11,0.05)
> xP1<-c(0.06,regionX1,0.11)
> yp1<-c(0,dnorm(regionX1,mean = 0.1186408,sd=0.0305429),0)
> curve(dnorm(x,mean = 0.1186408,sd=0.0305429),xlim = c(0.00,0.20),main
= "Densidad N(0.11,0.03)",cex.main=1)
> polygon(xP1,yp1,col = "orange1",border = "orange1",lwd=5)
> box()
```




Figura 18. Área bajo la curva para la $P(0.06 \leq X \leq 0.11)$ de Contenido de Nitrógeno.

2-. Distribución Weibull

La distribución de Weibull es una distribución de probabilidad continua. Se dice que una variable aleatoria X de tipo continua tiene distribución Weibull de parámetros α y β . Se dice que una variable aleatoria con distribución Weibull si su función de densidad es

$$f(X) = \begin{cases} \frac{\alpha X^{\alpha-1} e^{-\left(\frac{x}{\beta}\right)^\alpha}}{\beta^\alpha} & ; \quad x \geq 0 \\ & ; \quad \alpha, \beta > 0 \\ & ; \quad \text{otro caso} \end{cases}$$

Y se denota como $X \sim W(\alpha, \beta) > 0$.

○ Ajuste de distribución y establecimiento de hipótesis

El ajuste de la distribución se realizó a partir de la función `fitdist`, estableciendo el método de máxima verosimilitud para la estimación de parámetros. Se obtuvieron los siguientes resultados:

SCRIPT PARA CONTENIDO DE C			
<pre> > ##### Distribución weibull # ajuste de distribución #Contenido de C > ajusteCweibull<-fitdist(CONT_C,"weibull",method = "mle") > ajusteCweibull Fitting of the distribution ' weibull ' by maximum likelihood Parameters: estimate Std. Error shape 4.656166 0.6127822 scale 4.885373 0.1740425 > summary(ajusteCweibull) Fitting of the distribution ' weibull ' by maximum likelihood Parameters : estimate Std. Error shape 4.656166 0.6127822 scale 4.885373 0.1740425 Loglikelihood: -61.36189 AIC: 126.7238 BIC: 130.1015 Correlation matrix: shape scale shape 1.0000000 0.3025808 scale 0.3025808 1.0000000 > plot(ajusteCweibull) </pre>			

SCRIPT PARA CONTENIDO DE N

```

> #Contenido de Nitrogeno
> ajusteNweibull<-fitdist(CONT_N,"weibull",method = "mle")
> ajusteNweibull
Fitting of the distribution ' weibull ' by maximum likelihood
Parameters:
      estimate Std. Error
shape 4.3810871 0.541337874
scale 0.1303564 0.004961909
> summary(ajusteNweibull)
Fitting of the distribution ' weibull ' by maximum likelihood
Parameters :
      estimate Std. Error
shape 4.3810871 0.541337874
scale 0.1303564 0.004961909
Loglikelihood: 83.00913 AIC: -162.0183 BIC: -158.6405
Correlation matrix:
      shape      scale
shape 1.0000000 0.3195177
scale 0.3195177 1.0000000

> plot(ajusteNweibull)

```

Los parámetros obtenidos por el ajuste, son los siguientes:

Cuadro 16. Parametros obtenidos para el ajuste de Distribución Weibull.

	<i>Shape</i>	<i>Scale</i>	<i>AIC</i>
Contenido de C	4.656166	4.885373	126.7238
Contenido de N	4.3810871	0.1303564	-162.0183

En las siguientes graficas se observa para ambas variables, que los datos dificilmente pueden ajustarse a una distribución Weibull.




Figura 19. Gráficos de ajuste de distribución Weibull para Contenido de C.




Figura 20. Gráficos de ajuste de distribución Weibull para Contenido de N.

Posteriormente se establecieron las hipótesis para probar la distribución de los datos en cada una de las variables evaluadas.

$$H_0 = X \sim W(\alpha, \beta)$$

$$H_1 = \text{Otra distribución}$$

- **Prueba de bondad de ajuste**

Se realizaron las pruebas de Kolmogorov-Smirnov, Anderson Darling y Krammer Von Misses para probar la bondad de ajuste de la distribución de los datos.

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE CARBONO
<pre> > ##Prueba de bondad de ajuste > #Contenido de C > ks.test(CONT_C,"pweibull",ajusteCweibull\$estimate) One-sample Kolmogorov-Smirnov test data: CONT_C D = 1, p-value < 2.2e-16 alternative hypothesis: two-sided > ad.test(CONT_C,"pweibull",ajusteCweibull\$estimate) Anderson-Darling test of goodness-of-fit Null hypothesis: weibull distribution data: CONT_C An = Inf, p-value = 1.5e-05 > cvm.test(CONT_C,"pweibull",ajusteCweibull\$estimate) Cramer-von Mises test of goodness-of-fit Null hypothesis: weibull distribution data: CONT_C omega2 = 13.333, p-value = 2.109e-10 </pre>
SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE NITROGENO
<pre> > #Contenido de N > ks.test(CONT_N,"pweibull",ajusteNweibull\$estimate) One-sample Kolmogorov-Smirnov test data: CONT_N D = 0.9745, p-value < 2.2e-16 alternative hypothesis: two-sided </pre>

```
> ad.test(CONT_N,"pweibull",ajustenweibull$estimate)

Anderson-Darling test of goodness-of-fit
Null hypothesis: weibull distribution

data:  CONT_N
An = 74.109, p-value = 1.5e-05

> cvm.test(CONT_N,"pweibull",ajustenweibull$estimate)

Cramer-von Mises test of goodness-of-fit
Null hypothesis: weibull distribution

data:  CONT_N
omega2 = 2.9914, p-value = 1.202e-08
```

3-. Distribución Gamma

La distribución gamma es una distribución de probabilidad continua con dos parámetros α y β cuya función de densidad es

$$f(x) = \begin{cases} \frac{x^{\alpha-1} e^{-\left(\frac{x}{\beta}\right)}}{\beta^{\alpha} \Gamma(\alpha)} & ; \alpha, \beta > 0 \\ 0 & ; \text{otro caso} \end{cases}$$

Es una distribución adecuada para modelizar el comportamiento de variables aleatorias continuas con asimetría positiva. Es decir, variables que presentan una mayor densidad de sucesos a la derecha de la media que a la izquierda. En su expresión se encuentran dos parámetros, siempre positivos, (α) y (β) de los que depende su forma y alcance por la derecha.

Y se denota como $X \sim \Gamma(\alpha, \beta); \alpha, \beta > 0$

○ **Ajuste de distribución y establecimiento de hipótesis**

El ajuste de la distribución se realizó a partir de la función `fitdist`, estableciendo el método de máxima verosimilitud para la estimación de parámetros. Se obtuvieron los siguientes resultados:

SCRIPT PARA CONTENIDO DE C

```

> ##### Distribución Gamma
> # ajuste de distribución

> #Contenido de Carbono
> ajusteCgamma<-fitdist(CONT_C,"gamma",method = "mle")
> ajusteCgamma
Fitting of the distribution ' gamma ' by maximum likelihood
Parameters:
      estimate Std. Error
shape 12.874768  2.8423621
rate   2.893995  0.6515098
> summary(ajusteCgamma)
Fitting of the distribution ' gamma ' by maximum likelihood
Parameters :
      estimate Std. Error
shape 12.874768  2.8423621
rate   2.893995  0.6515098
Loglikelihood: -64.30584  AIC: 132.6117  BIC: 135.9894
Correlation matrix:
      shape      rate
shape 1.0000000  0.9806561
rate  0.9806561  1.0000000

> plot(ajusteCgamma)

```

SCRIPT PARA CONTENIDO DE N

```

> #Contenido de Nitrogeno
> ajusteNgamma<-fitdist(CONT_N,"gamma",method = "mle")
> ajusteNgamma
Fitting of the distribution ' gamma ' by maximum likelihood
Parameters:
      estimate Std. Error
shape 14.12838  3.122617
rate  119.09060 26.793566
> summary(ajusteNgamma)
Fitting of the distribution ' gamma ' by maximum likelihood
Parameters :
      estimate Std. Error
shape 14.12838  3.122617
rate  119.09060 26.793566
Loglikelihood: 82.42945  AIC: -160.8589  BIC: -157.4811
Correlation matrix:
      shape      rate
shape 1.0000000  0.9823657
rate  0.9823657  1.0000000

> plot(ajusteNgamma)

```


Los parámetros obtenidos por el ajuste para distribución gamma son los siguientes:

Cuadro 17. Parametros obtenidos para el ajuste de Distribución Gamma.

	Shape	Rate	AIC
Contenido de C	12.874768	2.893995	132.6117
Contenido de N	14.12838	119.09060	-160.8589

En las siguientes figuras se aprecia para ambas variables, que los datos no se ajustan a una distribución Gamma.




Figura 21. Gráficos de ajuste de distribución Gamma para Contenido de C.




Figura 22. Gráficos de ajuste de distribución Gamma para Contenido de N.

Posteriormente se establecieron las hipótesis para probar la distribución de los datos en cada una de las variables evaluadas.

$$H_0 = X \sim \Gamma(\alpha, \beta);$$

$$H_1 = \text{Otra distribución}$$

○ Prueba de bondad de ajuste

Se realizaron las pruebas de Kolmogorov-Smirnov, Anderson Darling y Krammer Von Misses para probar la bondad de ajuste de la distribución de los datos.

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE CARBONO

```
> ##Prueba de bondad de ajuste
> #Contenido de C
> ks.test(CONT_C,"pgamma",ajusteCgamma$estimate)

One-sample Kolmogorov-Smirnov test

data:  CONT_C
D = 0.96494, p-value < 2.2e-16
alternative hypothesis: two-sided

> ad.test(CONT_C,"pgamma",ajusteCgamma$estimate)

Anderson-Darling test of goodness-of-fit
Null hypothesis: Gamma distribution

data:  CONT_C
An = 40.672, p-value = 1.5e-05

> cvm.test(CONT_C,"pgamma",ajusteCgamma$estimate)

Cramer-von Mises test of goodness-of-fit
Null hypothesis: Gamma distribution

data:  CONT_C
omega2 = 1.7079, p-value = 4.306e-05
```

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE NITROGENO

```
> #Contenido de N
> ks.test(CONT_N,"pgamma",ajusteNgamma$estimate)

One-sample Kolmogorov-Smirnov test

data:  CONT_N
D = 1, p-value < 2.2e-16
alternative hypothesis: two-sided

> ad.test(CONT_N,"pgamma",ajusteNgamma$estimate)

Anderson-Darling test of goodness-of-fit
Null hypothesis: Gamma distribution

data:  CONT_N
An = Inf, p-value = 1.5e-05

> cvm.test(CONT_N,"pgamma",ajusteNgamma$estimate)

Cramer-von Mises test of goodness-of-fit
Null hypothesis: Gamma distribution

data:  CONT_N
omega2 = 13.333, p-value < 2.2e-16
```

4-. Distribución Log-Normal

La distribución Normal Logaritmica es una distribución de probabilidad de una variable aleatoria cuyo logaritmo esta normalmente distribuido. Es decir, X es una variable aleatoria con una distribución normal, entonces $\exp(X)$ tiene una distribución log-normal.

$$\log(X) \sim N(\mu, \sigma^2)$$

Si X es una variable aleatoria lognormal, entonces su función de densidad es:

$$f(X) = \begin{cases} \frac{1}{X\sigma\sqrt{2\pi}} e^{-\left[\frac{(\log(X)-\mu)^2}{2\sigma^2}\right]} & ; \begin{matrix} x > 0 \\ \sigma > 0 \end{matrix} \\ 0 & \text{otro caso} \end{cases}$$

○ Ajuste de distribución y establecimiento de hipótesis

El ajuste de la distribución se realizó a partir de la función `fitdist`, estableciendo el método de máxima verosimilitud para la estimación de parámetros. Se obtuvieron los siguientes resultados:

SCRIPT PARA CONTENIDO DE C
<pre> > ##### Distribución LogNormal > #Contenido de C > ajusteClnorm<-fitdist(CONT_C,"lnorm",method = "mle") > ajusteClnorm Fitting of the distribution 'lnorm' by maximum likelihood Parameters: estimate Std. Error meanlog 1.4533568 0.04620676 sdlog 0.2922372 0.03267139 > summary(ajusteClnorm) Fitting of the distribution 'lnorm' by maximum likelihood Parameters : estimate Std. Error meanlog 1.4533568 0.04620676 sdlog 0.2922372 0.03267139 Loglikelihood: -65.68424 AIC: 135.3685 BIC: 138.7462 Correlation matrix: meanlog sdlog meanlog 1 0 sdlog 0 1 > plot(ajusteClnorm) </pre>

SCRIPT PARA CONTENIDO DE N

```

> #Contenido de N
> ajusteNlnorm<-fitdist(CONT_N,"lnorm",method="mle")
> ajusteNlnorm
Fitting of the distribution ' lnorm ' by maximum likelihood
Parameters:
      estimate Std. Error
meanlog -2.1674690 0.04331821
sdlog    0.2739684 0.03062876
> summary(ajusteNlnorm)
Fitting of the distribution ' lnorm ' by maximum likelihood
Parameters :
      estimate Std. Error
meanlog -2.1674690 0.04331821
sdlog    0.2739684 0.03062876
Loglikelihood: 81.73092   AIC: -159.4618   BIC: -156.0841
Correlation matrix:
      meanlog      sdlog
meanlog 1.000000e+00 -4.713681e-12
sdlog   -4.713681e-12 1.000000e+00

> plot(ajusteNlnorm)

```

Los parámetros obtenidos por el ajuste, son los siguientes:

Cuadro 18. Parametros obtenidos para el ajuste de Distribución Log-Normal.

	<i>Media</i>	<i>Desviación estándar</i>	<i>AIC</i>
Contenido de C	1.4533568	0.2922372	135.3685
Contenido de N	-2.1674690	0.2739684	-159.4618

Se observa en las siguientes graficas para ambas variables, que la distribución log-normal no se ajusta a la distribución de los datos.




Figura 23. Gráficos de ajuste de distribución Log-Normal para Contenido de C.




Figura 24. Gráficos de ajuste de distribución Log-Normal para Contenido de N.

Posteriormente se establecieron las hipótesis para probar la distribución de los datos en cada una de las variables evaluadas.

$$H_0 = \log(X) \sim N(\mu, \sigma^2)$$

$H_1 = \text{Otra distribución}$

- **Prueba de bondad de ajuste**

Se realizaron las pruebas de Kolmogorov-Smirnov, Anderson Darling y Krammer Von Misses para probar la bondad de ajuste de la distribución de los datos.

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE CARBONO
<pre> > ##Prueba de bondad de ajuste > #Contenido de C > ks.test(CONT_C,"plnorm",ajusteClnorm\$estimate) One-sample Kolmogorov-Smirnov test data: CONT_C D = 0.68508, p-value < 2.2e-16 alternative hypothesis: two-sided > ad.test(CONT_C,"plnorm",ajusteClnorm\$estimate) Anderson-Darling test of goodness-of-fit Null hypothesis: log-normal distribution data: CONT_C An = 9.0319, p-value = 4.673e-05 > cvm.test(CONT_C,"plnorm",ajusteClnorm\$estimate) Cramer-von Mises test of goodness-of-fit Null hypothesis: log-normal distribution data: CONT_C omega2 = 1.7986, p-value = 2.575e-05 </pre>
SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE NITROGENO
<pre> > #Contenido de N > ks.test(CONT_N,"plnorm",ajusteNlnorm\$estimate) One-sample Kolmogorov-Smirnov test data: CONT_N D = 0.97656, p-value < 2.2e-16 alternative hypothesis: two-sided </pre>

```
> ad.test(CONT_N,"plnorm",ajusteNlnorm$estimate)

Anderson-Darling test of goodness-of-fit
Null hypothesis: log-normal distribution

data:  CONT_N
An = 31.85, p-value = 1.5e-05

> cvm.test(CONT_N,"plnorm",ajusteNlnorm$estimate)

Cramer-von Mises test of goodness-of-fit
Null hypothesis: log-normal distribution

data:  CONT_N
omega2 = 2.7906, p-value = 5.858e-08
```

5-. Distribución Uniforme

En teoría de probabilidad y estadística, la distribución uniforme continua es una familia de distribuciones de probabilidad para variables aleatorias continuas, tales que, para cada miembro de la familia, todos los intervalos de igual longitud en la distribución en su rango son igualmente probables. El dominio está definido por dos parámetros, a y b , que son sus valores mínimo y máximo. La distribución es a menudo escrita en forma abreviada como

$$X \sim U(a, b)$$

Su función de densidad es

$$f(X) = \begin{cases} \frac{1}{b-a} & ; \quad \text{si } a \leq x \leq b \\ 0 & ; \quad \text{en caso contrario} \end{cases}$$

○ Ajuste de distribución y establecimiento de hipótesis

El ajuste de la distribución se realizó a partir de la función `fitdist`, estableciendo el método de máxima verosimilitud para la estimación de parámetros. Se obtuvieron los siguientes resultados:

SCRIPT PARA CONTENIDO DE C		
<pre> > ##### Distribución Uniforme > #Ajuste de distribuciones > #Contenido de C > ajusteCunif<-fitdist(CONT_C,"unif",method = "mle") > ajusteCunif Fitting of the distribution ' unif ' by maximum likelihood Parameters: estimate Std. Error min 2.116 NA max 6.394 NA > summary(ajusteCunif) Fitting of the distribution ' unif ' by maximum likelihood Parameters : estimate Std. Error min 2.116 NA max 6.394 NA Loglikelihood: NA AIC: NA BIC: NA Correlation matrix: [1] NA > plot(ajusteCunif </pre>		
SCRIPT PARA CONTENIDO DE N		
<pre> > #Contenido de N > ajusteNunif<-fitdist(CONT_N,"unif",method = "mle") > ajusteNunif Fitting of the distribution ' unif ' by maximum likelihood Parameters: estimate Std. Error min 0.06164 NA max 0.18025 NA > summary(ajusteNunif) Fitting of the distribution ' unif ' by maximum likelihood Parameters : estimate Std. Error min 0.06164 NA max 0.18025 NA Loglikelihood: NA AIC: NA BIC: NA Correlation matrix: [1] NA > plot(ajusteCunif) </pre>		

Los parámetros obtenidos por el ajuste, son los siguientes:

Cuadro 19. Parametros obtenidos para el ajuste de Distribución Uniforme.

Mínimo	Máximo	AIC
--------	--------	-----

Contenido de C	2.116	6.394	NA
Contenido de N	0.06164	0.18025	NA

Se observa en las siguientes graficas para ambas variables, que la distribución uniforme no se ajusta a la distribución de los datos.




Figura 25. Gráficos de ajuste de distribución Uniforme para Contenido de C.




Figura 26. Gráficos de ajuste de distribución Uniforme para Contenido de N.

Posteriormente se establecieron las hipótesis para probar la distribución de los datos en cada una de las variables evaluadas.

$$H_0 = X \sim U(a, b);$$

$$H_1 = \text{Otra distribución}$$

○ Prueba de bondad de ajuste

Se realizaron las pruebas de Kolmogorov-Smirnov, Anderson Darling y Krammer Von Misses para probar la bondad de ajuste de la distribución de los datos.

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE CARBONO

```
> ##Prueba de bondad de ajuste
> #Contenido de C
> ks.test(CONT_C,"punif",ajusteCunif$estimate)

One-sample Kolmogorov-Smirnov test

data:  CONT_C
D = 1, p-value < 2.2e-16
alternative hypothesis: two-sided

> ad.test(CONT_C,"punif",ajusteCunif$estimate)

Anderson-Darling test of goodness-of-fit
Null hypothesis: uniform distribution

data:  CONT_C
An = Inf, p-value = 1.5e-05

> cvm.test(CONT_C,"punif",ajusteCunif$estimate)

Cramer-von Mises test of goodness-of-fit
Null hypothesis: uniform distribution

data:  CONT_C
omega2 = 13.333, p-value < 2.2e-16
```

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE NITROGENO

```
> #Contenido de N
> ks.test(CONT_N,"punif",ajusteNunif$estimate)

One-sample Kolmogorov-Smirnov test

data:  CONT_N
D = 1, p-value < 2.2e-16
alternative hypothesis: two-sided

> ad.test(CONT_N,"punif",ajusteNunif$estimate)

Anderson-Darling test of goodness-of-fit
Null hypothesis: uniform distribution

data:  CONT_N
An = Inf, p-value = 1.5e-05

> cvm.test(CONT_N,"punif",ajusteNunif$estimate)

Cramer-von Mises test of goodness-of-fit
Null hypothesis: uniform distribution

data:  CONT_N
omega2 = 11.373, p-value = 3.892e-10
```

6-. Distribución Exponencial

En Estadística la distribución exponencial es una distribución de probabilidades continua con parámetro $\lambda > 0$ cuya función de densidad es:

$$f(X) = \begin{cases} \lambda e^{-\lambda x} & ; \text{ para } x \geq 0 \\ 0 & ; \text{ en caso contrario} \end{cases}$$

○ Ajuste de distribución y establecimiento de hipótesis

El ajuste de la distribución se realizó a partir de la función `fitdist`, estableciendo el método de máxima verosimilitud para la estimación de parámetros. Se obtuvieron los siguientes resultados:

SCRIPT PARA CONTENIDO DE C
<pre> > ##### Distribución Exponencial > #Ajuste de distribuciones > #Contenido de C > ajusteCexp<-fitdist(CONT_C,"exp",method = "mle") > ajusteCexp Fitting of the distribution ' exp ' by maximum likelihood Parameters: estimate Std. Error rate 0.2247653 0.03553781 > summary(ajusteCexp) Fitting of the distribution ' exp ' by maximum likelihood Parameters : estimate Std. Error rate 0.2247653 0.03553781 Loglikelihood: -99.70794 AIC: 201.4159 BIC: 203.1048 > plot(ajusteCexp) </pre>
SCRIPT PARA CONTENIDO DE N
<pre> > #Contenido de N > ajusteNexp<-fitdist(CONT_N,"exp",method = "mle") > ajusteNexp Fitting of the distribution ' exp ' by maximum likelihood Parameters: estimate Std. Error rate 8.428807 1.332711 > summary(ajusteNexp) Fitting of the distribution ' exp ' by maximum likelihood Parameters : estimate Std. Error rate 8.428807 1.332711 </pre>

```
Loglikelihood: 45.26621   AIC: -88.53242   BIC: -86.84354
> plot(ajusteNexp)
```

Los parámetros obtenidos por el ajuste son los siguientes:

Cuadro 20. Parametros obtenidos para el ajuste de Distribución Exponencial.

	<i>Rate</i>	<i>AIC</i>
Contenido de C	0.2247653	201.4159
Contenido de N	8.428807	-88.53242

Se observa en las siguientes graficas para ambas variables, que la distribución exponencial no se ajusta a la distribución de los datos.




Figura 27. Gráficos de ajuste de distribución Exponencial para Contenido de C.




Figura 28. Gráficos de ajuste de distribución Exponencial para Contenido de N.

Posteriormente se establecieron las hipótesis para probar la distribución de los datos en cada una de las variables evaluadas.

$H_0 = X \sim \text{Exponencial}$

$H_1 = \text{Otra distribución}$

○ Pruebas de bondad de ajuste

Se realizaron las pruebas de Kolmogorov-Smirnov, Anderson Darling y Krammer Von Misses para probar la bondad de ajuste de la distribución de los datos.

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE CARBONO

```
> ##Prueba de bondad de ajuste
> #Contenido de C
> ks.test(CONT_C,"pexp",ajusteCexp$estimate)
```

One-sample Kolmogorov-Smirnov test

```

data:  CONT_C
D = 0.38268, p-value = 8.879e-06
alternative hypothesis: two-sided

> ad.test(CONT_C,"pexp",ajusteCexp$estimate)

Anderson-Darling test of goodness-of-fit
Null hypothesis: exponential distribution

data:  CONT_C
An = 9.9657, p-value = 2.231e-05

> cvm.test(CONT_C,"pexp",ajusteCexp$estimate)

Cramer-von Mises test of goodness-of-fit
Null hypothesis: exponential distribution

data:  CONT_C
omega2 = 2.0343, p-value = 6.656e-06

```

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE CARBONO

```

> #Contenido de N
> ks.test(CONT_N,"pexp",ajusteNexp$estimate)

One-sample Kolmogorov-Smirnov test

data:  CONT_N
D = 0.41856, p-value = 7.278e-07
alternative hypothesis: two-sided

> ad.test(CONT_N,"pexp",ajusteNexp$estimate)

Anderson-Darling test of goodness-of-fit
Null hypothesis: exponential distribution

data:  CONT_N
An = 10.143, p-value = 2.022e-05

> cvm.test(CONT_N,"pexp",ajusteNexp$estimate)

Cramer-von Mises test of goodness-of-fit
Null hypothesis: exponential distribution

data:  CONT_N
omega2 = 2.0903, p-value = 4.806e-06

```

7-. Distribución Beta

En estadística, la distribución Beta es una distribución de probabilidad continua con dos parámetros α y β cuya función de densidad para valores de $0 \leq x \leq 1$ es:

$$f(X) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} X^{\alpha-1} (1 - X)^{\beta-1}$$

Γ es la funcion gamma

○ **Ajuste de distribución y establecimiento de hipótesis**

El ajuste de la distribución se realizó a partir de la función fitdist, estableciendo el método de máxima verosimilitud para la estimación de parámetros. Se obtuvieron los siguientes resultados:

SCRIPT PARA CONTENIDO DE N
<pre> > ##Distribucion beta > #Contenido de N > ajustenbeta<-fitdist(CONT_N,"beta",method = "mle") > ajustenbeta Fitting of the distribution ' beta ' by maximum likelihood Parameters: estimate Std. Error shape1 12.58204 2.777224 shape2 93.49718 20.997393 > summary(ajustenbeta) Fitting of the distribution ' beta ' by maximum likelihood Parameters : estimate Std. Error shape1 12.58204 2.777224 shape2 93.49718 20.997393 Loglikelihood: 82.59504 AIC: -161.1901 BIC: -157.8123 Correlation matrix: shape1 shape2 shape1 1.000000 0.9776245 shape2 0.9776245 1.0000000 > plot(ajustenbeta) </pre>

Los parámetros obtenidos por el ajuste, son los siguientes:

Cuadro 21. Parametros obtenidos para el ajuste de Distribución Beta.

	Shape 1	Shape 2	AIC
Contenido de N	12.58204	93.49718	-161.1901

Se observa en las siguientes graficas para ambas variables, que la distribución beta podría ajustarse a la distribución de los datos, en comparación con las distribuciones anteriores.




Figura 29. Gráficos de ajuste de distribución Beta para Contenido de N.

Posteriormente se establecieron las hipótesis para probar la distribución de los datos en cada una de las variables evaluadas.

$$H_0 = X \sim \text{Beta}$$

$$H_1 = \text{Otra distribución}$$

- **Prueba de bondad de ajuste**

Se realizaron las pruebas de Kolmogorov-Smirnov, Anderson Darling y Krammer Von Misses para probar la bondad de ajuste de la distribución de los datos. Se observa que los datos cumplen una distribución beta para los contenidos de N.

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE NITROGENO

```

> #Prueba de bondad de ajuste
> ks.test(CONT_N,"pbeta",12.58204,93.49718)

      One-sample Kolmogorov-Smirnov test

data:  CONT_N
D = 0.1477, p-value = 0.3156
alternative hypothesis: two-sided

> ad.test(CONT_N,"pbeta",12.58204,93.49718)

      Anderson-Darling test of goodness-of-fit
      Null hypothesis: beta distribution

data:  CONT_N
An = 0.77966, p-value = 0.4951

> cvm.test(CONT_N,"pbeta",12.58204,93.49718)

      Cramer-von Mises test of goodness-of-fit
      Null hypothesis: beta distribution

data:  CONT_N
omega2 = 0.15035, p-value = 0.3898

```

7-. Distribución Cauchy (Colas Pesadas)

Se dice que una variable aleatoria X de tipo continuo tiene distribución de cauchy de parámetros $\mu > 0$ y θ si su función de densidad es

$$f(X) = \frac{\mu}{\pi} \frac{1}{\mu^2 + (X - \theta)^2} \quad -\infty < X < \infty$$

Y se denota $X \sim C(\mu, \theta)$

Ajuste de distribución y establecimiento de hipótesis

El ajuste de la distribución se realizó a partir de la función `fitdist`, estableciendo el método de máxima verosimilitud para la estimación de parámetros. Se obtuvieron los siguientes resultados:

SCRIPT PARA CONTENIDO DE C

```
##Distribucion cauchy
#Ajuste de Distribuciones

> #Contenido de C
> ajusteCcauchy<-fitdist(CONT_C,"cauchy",method = "mle")
> ajusteCcauchy
Fitting of the distribution ' cauchy ' by maximum likelihood
Parameters:
      estimate Std. Error
location 4.8756618  0.1912178
scale    0.7204357  0.1552133
> #Contenido de C
> ajusteCcauchy<-fitdist(CONT_C,"cauchy",method = "mle")
> ajusteCcauchy
Fitting of the distribution ' cauchy ' by maximum likelihood
Parameters:
      estimate Std. Error
location 4.8756618  0.1912178
scale    0.7204357  0.1552133
> summary(ajusteCcauchy)
Fitting of the distribution ' cauchy ' by maximum likelihood
Parameters :
      estimate Std. Error
location 4.8756618  0.1912178
scale    0.7204357  0.1552133
Loglikelihood: -71.93098  AIC:  147.862  BIC:  151.2397
Correlation matrix:
      location      scale
location 1.0000000 -0.3263767
scale    -0.3263767  1.0000000

> plot(ajusteCcauchy)
```

SCRIPT PARA CONTENIDO DE N

```
> #Contenido de N
> ajusteNcauchy<-fitdist(CONT_N,"cauchy",method = "mle")
> ajusteNcauchy
Fitting of the distribution ' cauchy ' by maximum likelihood
Parameters:
      estimate Std. Error
location 0.12582661 0.004533634
scale    0.01826175 0.004119462
> summary(ajusteNcauchy)
Fitting of the distribution ' cauchy ' by maximum likelihood
Parameters :
      estimate Std. Error
location 0.12582661 0.004533634
scale    0.01826175 0.004119462
Loglikelihood: 74.06664  AIC:  -144.1333  BIC:  -140.7555
Correlation matrix:
      location      scale
location 1.0000000 -0.327262
scale    -0.327262  1.0000000

> plot(ajusteNcauchy)
```

Los parámetros obtenidos por el ajuste, son los siguientes:

Cuadro 22. Parametros obtenidos para el ajuste de Distribución Cauchy.

	<i>Location</i>	<i>Scale</i>	<i>AIC</i>
Contenido de C	4.8756618	0.7204357	147.862
Contenido de N	0.12582661	0.01826175	-144.1333

Se observa en las siguientes graficas para ambas variables, que la distribución Cauchy no se ajusta a la distribución de los datos.




Figura 30. Gráficos de ajuste de distribución Cauchy para Contenido de C.




Figura 31. Gráficos de ajuste de distribución Uniforme para Contenido de N.

Posteriormente se establecieron las hipótesis para probar la distribución de los datos en cada una de las variables evaluadas.

$$H_0 = C(\mu, \theta);$$

$$H_1 = \text{Otra distribución}$$

- **Prueba de bondad de ajuste**

Se realizaron las pruebas de Kolmogorov-Smirnov, Anderson Darling y Krammer Von Misses para probar la bondad de ajuste de la distribución de los datos.

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE CARBONO
<pre> > #Pruebas de bondad de ajuste > #Contenido de C > ks.test(CONT_C,"pcauchy",ajusteCcauchy\$estimate) One-sample kolmogorov-Smirnov test data: CONT_C D = 0.79804, p-value < 2.2e-16 alternative hypothesis: two-sided > ad.test(CONT_C,"pcauchy",ajusteCcauchy\$estimate) </pre>

Anderson-Darling test of goodness-of-fit
Null hypothesis: Cauchy distribution

data: CONT_C
An = 9.5492, p-value = 2.987e-05

```
> cvm.test(CONT_C,"pcauchy",ajusteCcauchy$estimate)
```

Cramer-von Mises test of goodness-of-fit
Null hypothesis: Cauchy distribution

data: CONT_C
omega2 = 1.7064, p-value = 4.344e-05

SCRIPT PARA TEST DE BONDAD DE AJUSTE PARA CONTENIDO DE NITROGENO

```
> #Contenido de N  
> ks.test(CONT_N,"pcauchy",ajusteNcauchy$estimate)
```

One-sample Kolmogorov-Smirnov test

data: CONT_N
D = 0.49018, p-value = 2.185e-09
alternative hypothesis: two-sided

```
> ad.test(CONT_N,"pcauchy",ajusteNcauchy$estimate)
```

Anderson-Darling test of goodness-of-fit
Null hypothesis: Cauchy distribution

data: CONT_N
An = 13.791, p-value = 1.5e-05

```
> cvm.test(CONT_N,"pcauchy",ajusteNcauchy$estimate)
```

Cramer-von Mises test of goodness-of-fit
Null hypothesis: Cauchy distribution

data: CONT_N
omega2 = 2.9189, p-value = 2.222e-08

VI. MEJOR AJUSTE DE DISTRIBUCIONES

Dado que, dentro de las seis distribuciones evaluadas, en todas se rechazó la hipótesis nula, se utilizó el siguiente script para obtener cual de las 6 distribuciones anteriores se ajusta mejor.

SCRIPT PARA CONTENIDO DE C
<pre> > #Contenido de C > par(mfrow=c(2,2)) #Contenido de C par(mfrow=c(2,2)) plot.legend<-c("Normal","weibull","Gamma","LogNormal","Uniforme","Expone ncial","Cauchy") denscomp(list(ajusteCnormal,ajusteCweibull,ajusteCgamma,ajusteClnorm,aju steCunif,ajusteCexp,ajusteCcauchy),fitcol = c("red","green","blue","oran ge","pink","darkblue","darkgreen"),legendtext = plot.legend) qqcomp(list(ajusteCnormal,ajusteCweibull,ajusteCgamma,ajusteClnorm,ajust eCunif,ajusteCexp,ajusteCcauchy),fitcol = c("red","green","blue","orange ","pink","darkblue","darkgreen"),legendtext = plot.legend) cdfcomp(list(ajusteCnormal,ajusteCweibull,ajusteCgamma,ajusteClnorm,ajus teCunif,ajusteCexp,ajusteCcauchy),fitcol = c("red","green","blue","orang e","pink","darkblue","darkgreen"),legendtext = plot.legend) ppcomp(list(ajusteCnormal,ajusteCweibull,ajusteCgamma,ajusteClnorm,ajust eCunif,ajusteCexp,ajusteCcauchy),fitcol = c("red","green","blue","orange ","pink","darkblue","darkgreen"),legendtext = plot.legend) #bondad de ajuste gofstat(list(ajusteCnormal,ajusteCweibull,ajusteCgamma,ajusteClnorm,ajus teCunif,ajusteCexp)) </pre>
SCRIPT PARA CONTENIDO DE N
<pre> #Contenido de N par(mfrow=c(2,2)) plot.legend<-c("Normal","weibull","Gamma","LogNormal","Uniforme","Expone ncial") denscomp(list(ajusteNnormal,ajusteNweibull,ajusteNgamma,ajusteNlnorm,aju steNunif,ajusteNexp),fitcol = c("red","green","blue","orange","pink","da rkblue"),legendtext = plot.legend) qqcomp(list(ajusteNnormal,ajusteNweibull,ajusteNgamma,ajusteNlnorm,ajust eNunif,ajusteNexp),fitcol = c("red","green","blue","orange","pink","dark blue"),legendtext = plot.legend) cdfcomp(list(ajusteNnormal,ajusteNweibull,ajusteNgamma,ajusteNlnorm,ajus teNunif,ajusteNexp),fitcol = c("red","green","blue","orange","pink","dar kblue"),legendtext = plot.legend) ppcomp(list(ajusteNnormal,ajusteNweibull,ajusteNgamma,ajusteNlnorm,ajust eNunif,ajusteNexp),fitcol = c("red","green","blue","orange","pink","dark blue"),legendtext = plot.legend) #bondad de ajuste </pre>


```
gofstat(list(ajusteNnormal,ajusteNweibull,ajusteNgamma,ajusteNlnorm,ajusteNunif,ajusteNexp))
```

De manera grafica para la variable Contenido de Carbono se observa que la distribución Normal y Weibull se ajustaban a los datos, mientras que para contenido de Nitrogeno, tanto la distribución normal como beta se ajustan a la distribución.

Se muestran las siguientes graficas para la variable contenido de C y su resumen para todas las distribuciones.

```
> gofstat(list(ajustecnormal,ajustecweibull,ajustecgamma,ajusteclnorm,ajustecunif,ajustecexp,ajusteccauchy))
```

Goodness-of-fit statistics

	1-mle-norm	2-mle-weibull	3-mle-gamma	4-mle-lnorm	5-mle-unif	6-mle-exp	7-mle-cauchy
Kolmogorov-Smirnov statistic	0.1359002	0.1253070	0.1646888	0.1764101	0.1540206	0.382677	0.1559289
Cramer-von Mises statistic	0.1684879	0.1453251	0.2316809	0.2683483	0.2145420	2.034332	0.2766870
Anderson-Darling statistic	0.9524807	0.8537586	1.2935636	1.5019290	Inf	9.965680	1.9428231

Goodness-of-fit criteria

	1-mle-norm	2-mle-weibull	3-mle-gamma	4-mle-lnorm	5-mle-unif	6-mle-exp	7-mle-cauchy
Akaike's Information Criterion	129.1283	126.7238	132.6117	135.3685	NA	201.4159	147.8620
Bayesian Information Criterion	132.5061	130.1015	135.9894	138.7462	NA	203.1048	151.2397

Se observa que las distribuciones que tienen un mejor ajuste son Weibull y Normal son las que tienen un ajuste mejor de acuerdo con los criterios AIC y BIC.




Figura 32. Histograma y funcion de densidad teorica para Contenido de C.




Figura 33. Grafica QQ-Plot de distribuciones ajustadas para Contenido de C.




Figura 34. CDFS Empirica y Teorica para Contenido de C.




Figura 35. PP plot para Contenido de C.

Se muestran las siguientes graficas para la variable contenido de N y su resumen para todas las distribuciones.

```
> gofstat(list(ajustenormal,ajustenweibull,ajustengamma,ajustenlnorm,ajustenunif,ajustenexp,ajustenbeta,ajustencauchy))
```

Goodness-of-fit statistics

	1-mle-norm	2-mle-weibull	3-mle-gamma	4-mle-lnorm	5-mle-unif	6-mle-exp	7-mle-beta	8-mle-cauchy
Kolmogorov-Smirnov statistic	0.1187892	0.10172283	0.1520006	0.1669777	0.1704620	0.4185576	0.1477022	0.1520782
Cramer-von Mises statistic	0.1093209	0.08794453	0.1586276	0.1897818	0.1709884	2.0902729	0.1503521	0.1894078
Anderson-Darling statistic	0.6197028	0.54155013	0.8188035	0.9742199	Inf	10.1433951	0.7796599	1.3888859

Goodness-of-fit criteria

	1-mle-norm	2-mle-weibull	3-mle-gamma	4-mle-lnorm	5-mle-unif	6-mle-exp	7-mle-beta	8-mle-cauchy
Akaike's Information Criterion	-161.5748	-162.0183	-160.8589	-159.4618	NA	-88.53242	-161.1901	-144.1333
Bayesian Information Criterion	-158.1970	-158.6405	-157.4811	-156.0841	NA	-86.84354	-157.8123	-140.7555

```
> ajustenormal
```

Se observa que las distribuciones que tienen un mejor ajuste son Beta, Weibull y Normal de acuerdo con los criterios AIC y BIC.




Figura 36. Histograma y funcion de densidad teorica para Contenido de C.




Figura 37. Grafica QQ-Plot de distribuciones ajustadas para Contenido de N.




Figura 38. CDFS Empirica y Teorica para Contenido de N.




Figura 39. PP plot para Contenido de N.