



COLEGIO DE POSTGRADUADOS

COLEGIO DE POSTGRADUADOS

INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS

CAMPUS MONTECILLO

PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

MEDIDAS DE AUTOCORRELACIÓN ESPACIAL

Geoestadística aplicada en el estudio de los recursos forestales

Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Perez Vazquez

INTRODUCCIÓN

La autocorrelación espacial es un procedimiento intrínsecamente geográfico que indica el comportamiento de la información georreferenciada a diferentes escalas, es decir, el tipo de asociación existente entre unidades espaciales vecinas. El concepto de autocorrelación espacial (AE) tiene sustento en el principio de Tobler que plantea que en el espacio geográfico todo se encuentra relacionado con todo, pero los espacios más cercanos están más relacionados entre sí (Celemin, 2009).

La autocorrelación espacial (SA) se refiere a la correlación de una variable con ella misma en el espacio. En general, se acepta que existe autocorrelación espacial (AE) siempre que haya una variación espacial sistemática en los valores de una variable a través de un mapa, es decir, un patrón en el comportamiento de la variable según la ubicación geográfica del dato. Si los valores altos de una localización están asociados con valores altos en los vecinos, la autocorrelación espacial es positiva siendo la situación opuesta la de autocorrelación espacial negativa.

El conocer si un conjunto de datos presenta autocorrelación espacial permite estimar el tamaño de muestra óptimo, y así evitar un mayor esfuerzo en la toma de muestras, asimismo permite tomar decisiones sobre la estrategia mas conveniente para el análisis de datos.

No obstante, a pesar de su creciente importancia en el marco del análisis exploratorio de datos espaciales, su utilización es reducida en trabajos geográficos que continúan recurriendo a los coeficientes tradicionales de correlación y a la estadística descriptiva (Celemin, 2009).

ÍNDICE DE AUTOCORRELACIÓN ESPACIAL

La medición de la correlación que una misma variable tiene en diferentes unidades espaciales contiguas en una perspectiva horizontal da lugar a una de estas tres posibilidades (Figura 1):

- 1) Autocorrelación espacial positiva: las unidades espaciales vecinas presentan valores próximos. Indica una tendencia al agrupamiento de las unidades espaciales.

- 2) Autocorrelación espacial negativa: las unidades espaciales vecinas presentan valores muy disímiles. Indica una tendencia a la dispersión de las unidades espaciales.
- 3) Sin autocorrelación: no ocurre ninguna de las dos situaciones anteriores. Por lo tanto, los valores de las unidades espaciales vecinas presentan valores producidos en forma aleatoria.




Figura 1. Tendencias de Autocorrelación espacial. Fuente: (Celemín, 2009)

DEFINICIÓN DEL PROBLEMA

Se tiene interés en estudiar si los contenidos de carbono del Sitio del Monitoreo Intensivo de Carbono de Hidalgo tienen o no autocorrelación espacial. Para ello, se cuenta con el archivo shapefile de puntos denominado "hojarasca_shp" que cuenta con los siguientes campos (Cuadro 1).

Cuadro 1. Descripción del conjunto de datos contenidos en el archivo shapefile.

NOMBRE	TIPO	DESCRIPCIÓN	RANGO
FOLIO	Numérico	Número del conglomerado en el que se le colecta la información del mantillo.	1-40
TIPO_MUEST	Texto	Se refiere a la capa de mantillo recolectada.	Ho: hojarasca

NOMBRE	TIPO	DESCRIPCIÓN	RANGO
ID_COLPOS	Numérico	Identificador de la muestra, asignado por el laboratorio del colpos.	
PESO_MUEST	Numérico	Peso seco de la submuestra enviada al laboratorio	Gramos
CONC_C	Numérico	Concentración de Carbono reportada por el laboratorio	%
CONC_N	Numérico	Concentración de Nitrógeno reportada por el laboratorio	%
CONT_C	Numérico	Contenido de carbono en la capa orgánica del suelo. Es la relación (Peso total * Concentración de C)/100	g/m ²
CONT_N	Numérico	Contenido de Nitrógeno en la capa orgánica del suelo. Es la relación (Peso total * Concentración de N)/100	g/m ²
ANUALIDAD	Numérico	Es la rodalización del bosque señalados por el año de corta	Años
EDAD	Numérico	Edad del sitio, calculada por la anualidad	Años
UTM_X	Numérico	Coordenadas UTM x	m
UTM_Y	Numérico	Coordenadas UTM y	m
ALTITUD	Numérico	Altitud	M

En este caso, las variables de interés son las coordenadas UTM x, UTM y, y la variable contenido de C. Para poder trabajar con el archivo en R se utilizaron los paquetes de rgdal, spdep, sp y RANN

Script en R
<pre> > names(hojarasca_UTM) [1] "FOLIO" "TIPO_MUEST" "ID_COLPOS" "PESO_MUEST" [5] "CONC_C" "CONC_N" "CONT_C" "CONT_N" [9] "ANUALIDAD" "EDAD" "UTM_X" "UTM_Y" [13] "ALTITUD" #fijar directorio setwd("C:/Users/zaira/Documents/00 Maestria Ciencias Forestales/00 Cuatrimestre verano 2018/Geoestadística/Tarea/Autocorrelacion espacial") # Cargar librerías library(rgdal) </pre>

```
library(spdep)
library(sp)
require(RANN)

> #Leer shp
> hojarasca_UTM <- readOGR(dsn=".", layer="hojarasca_shp", pointDropZ = TRUE)
OGR data source with driver: ESRI Shapefile
Source: "C:\Users\zaira\Documents\00 Maestria Ciencias Forestales\00 Cuatrimestre verano 2018\Geoestadística\Tarea\Autocorrelación espacial",
layer: "hojarasca_shp"
with 40 features
It has 13 fields
Integer64 fields read as strings: FOLIO ID_COLPOS ANUALIDAD EDAD ALTITUD

> names(hojarasca_UTM)
[1] "FOLIO"      "TIPO_MUEST" "ID_COLPOS"   "PESO_MUEST"
[5] "CONC_C"     "CONC_N"     "CONT_C"     "CONT_N"
[9] "ANUALIDAD"  "EDAD"       "UTM_X"      "UTM_Y"
[13] "ALTITUD"

> plot(hojarasca_UTM, main="Puntos de muestreo - Contenido de C", col="darkblue")
```

La siguiente figura muestra la distribución espacial de los puntos (Figura 2):




Figura 2. Puntos de muestreo en el archivo shapefile.

Generación de una matriz y lista de vecinos tipo W y B

Para calcular la relación entre dos localidades se debe construir una matriz de pesos espaciales W_{ij} , donde ij hace referencia a las localidades i y j , respectivamente.

El procedimiento para generar la lista de vecinos fue a partir de los módulos "knn2nb" y "nb2listw", para crear la relación de vecinos y para crear la lista de vecinos para el Test de Moran. El uso de "knearneigh" permite generar la matriz de vecinos, identificando los vecinos a partir de distancias euclidianas. Si $K=1$, se toman todos los vecinos; si $K=4$ se listan los cuatro vecinos más cercanos.

Script en R

```
> coords <- coordinates(hojarasca_UTM)
> summary(coords)

> hojarasca.knn <- knn2nb(knearneigh(coords))
> hojarasca.knn
Neighbour list object:
Number of regions: 40
Number of nonzero links: 40
Percentage nonzero weights: 2.5
Average number of links: 1
Non-symmetric neighbours list

#VECINDAD TIPO W
> colW_knn <- nb2listw(hojarasca.knn, style="W")
> colW_knn
Characteristics of weights list object:
Neighbour list object:
Number of regions: 40
Number of nonzero links: 40
Percentage nonzero weights: 2.5
Average number of links: 1
Non-symmetric neighbours list

Weights style: W
Weights constants summary:
  n   nn S0 S1 S2
W 40 1600 40 60 192

> #Vecindad tipo B
> colB_knn <- nb2listw(hojarasca.knn, style="B")
> colB_knn
Characteristics of weights list object:
Neighbour list object:
Number of regions: 40
Number of nonzero links: 40
```

```

Percentage nonzero weights: 2.5
Average number of links: 1
Non-symmetric neighbours list

Weights style: B
Weights constants summary:
  n  nn S0 S1 S2
B 40 1600 40 60 192

> #Se consideran todas las conexiones entre coordenadas

> all.linked <- max(unlist(nbdists(hojarasca.knn, coords)))
[1] 887.4314

> nb <- dnearneigh(coords, 0, all.linked)
> nb
Neighbour list object:
Number of regions: 40
Number of nonzero links: 788
Percentage nonzero weights: 49.25
Average number of links: 19.

> colW <- nb2listw(nb, style="W") # Crea otra lista de vecinos

> colW
Characteristics of weights list object:
Neighbour list object:
Number of regions: 40
Number of nonzero links: 788
Percentage nonzero weights: 49.25
Average number of links: 19.7

Weights style: W
Weights constants summary:
  n  nn S0 S1 S2
W 40 1600 40 5.968475 166.8538

> colB <- nb2listw(nb, style="B") # Crea lista vecinos: 0 y 11/2%

> colB
Characteristics of weights list object:
Neighbour list object:
Number of regions: 40
Number of nonzero links: 788
Percentage nonzero weights: 49.25
Average number of links: 19.7

Weights style: B
Weights constants summary:
  n  nn S0 S1 S2
B 40 1600 788 1576 73400


> par(mfrow=c(1,2))
> plot(hojarasca_UTM)
> plot(nb, coords, add=TRUE)
> box()

```

```
> title("Todos los vecinos (knn=n-1)")  
> plot(hojarasca_UTM)  
> plot(hojarasca.knn, coords, add=TRUE)  
> box()  
> title("Solo los 4 vecinos (knn=4)")  
> Carb <- hojarasca_UTM$CONT_C
```

De acuerdo con la Figura 3, se observa una comparación para la selección de los vecinos más cercanos, si se define $knn=n-1$ se observa que se consideran todas las conexiones posibles entre los puntos, mientras que con un $KNN=4$ solo toma los cuatro vecinos que estén contiguos al punto de interés, dando una serie de vecindades menor al efecto de telaraña que tiene en la primera figura.

Todos los vecinos (knn=n-1)



Solo los 4 vecinos (knn=4)




Figura 3. Vecindad con $knn=n-1$ y 4.

Calcular el Índice de Morán con cada una de las vecindades

El Índice de Moran es un estadístico para conocer la autocorrelación espacial y esta dado por la ecuación:

$$\frac{N \sum_{i=1}^n \sum_{j=1}^n W_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\left(\sum_{i=1}^n \sum_{j=1}^n W_{ij}\right) \sum_{i=1}^n (x_i - \bar{x})^2}$$

Donde:

N = número de casos

$\bar{x}$ = media de la variable

x_i = valor de la variable en la localidad i

x_j = valor de la variable en la localidad j

W_{ij} = ponderación asociada a la localidad i relativa a la localidad j

Sus valores oscilan entre -1.0 y +1.0. que pueden indicar patrones aleatorios, aglomeración o dispersión uniforme.

Script en R

```
> Carb <- hojarasca_UTM$CONT_C
> ## Indice de Moran para vecindad W
> moran_CONT_C_KNN_W <- moran.test(Carb, colW_knn)
> print(moran_CONT_C_KNN_W)
```

Moran I test under randomisation

data: Carb
weights: colW_knn

Moran I statistic standard deviate = -1.1069, p-value = 0.8658
alternative hypothesis: greater
sample estimates:

Moran I statistic	Expectation	Variance
-0.23741231	-0.02564103	0.03659995

```
> moran_CONT_C_NN_W <- moran.test(Carb, colW)
> print(moran_CONT_C_NN_W)
```

```

Moran I test under randomisation

data: Carb
weights: colW

Moran I statistic standard deviate = 0.63065, p-value =
0.2641
alternative hypothesis: greater
sample estimates:
Moran I statistic      Expectation      Variance
0.005235296          -0.025641026          0.002397058

> moran.plot(Carb, colW_knn, pch=20, main = "KNN = 4")
> moran.plot(Carb, colW, pch=20, main = "Al menos un vecino")

> ## Indice de Moran para vecindad B
> moran_CONT_C_KNN_B <- moran.test(Carb, colB_knn)
> print(moran_CONT_C_KNN_B)

Moran I test under randomisation

data: Carb
weights: colB_knn

Moran I statistic standard deviate = -1.1069, p-value =
0.8658
alternative hypothesis: greater
sample estimates:
Moran I statistic      Expectation      Variance
-0.23741231          -0.02564103          0.03659995

> moran_CONT_C_NN_B <- moran.test(Carb, colB)
> print(moran_CONT_C_NN_B)

Moran I test under randomisation

data: Carb
weights: colB

Moran I statistic standard deviate = -0.28603, p-value =
0.6126
alternative hypothesis: greater
sample estimates:
Moran I statistic      Expectation      Variance
-0.0337777136          -0.0256410256          0.0008092162

```

*

Para la estadística I de Moran, la hipótesis nula establece que el atributo que se analiza presenta autocorrelación espacial; es decir, los procesos espaciales que promueven el patrón de valores observado siguen una tendencia espacial.

- Para la vecindad tipo W

En el primer caso, se obtuvo para la vecindad tipo W con $knn=4$, el índice de Moran arrojó un valor de -0.2374 con un $pvalue=0.8658$, lo que indica que los valores altos rechazan otros valores altos y tienden a estar cerca de valores bajos, por lo cual el Índice es negativo. Lo que indica una tendencia uniforme.

En otras palabras, el valor P es estadísticamente significativo y la puntuación del I de Moran es negativa, lo cual indica que no se puede rechazar la hipótesis nula, La distribución espacial de los valores altos y los valores bajos en el dataset está más dispersa espacialmente de lo que se esperaría si los procesos espaciales subyacentes fueran aleatorios. Un patrón espacial disperso suele reflejar algún tipo de proceso competitivo: una entidad con un valor alto rechaza a otras entidades con valores altos; del mismo modo, una entidad con un valor bajo rechaza a otras entidades con valores bajos.

```
> print(moran_CONT_C_KNN_W)
```

```
Moran I test under randomisation
```

```
data: Carb
```

```
weights: colW_knn
```

```
Moran I statistic standard deviate = -1.1069, p-value = 0.8658
```

```
alternative hypothesis: greater
```

```
sample estimates:
```

Moran I statistic	Expectation	Variance
-0.23741231	-0.02564103	0.03659995

Sin embargo, para el caso de la segunda prueba con la matriz de vecindad de al menos solo un vecino (considerando todas las conexiones entre coordenadas) se obtuvo un valor de Índice de Moran positivo, pero muy cercano a cero (0.005), con un $pvalue=0.2641$. Se puede interpretar que, si los valores positivos de los productos cruzados equilibran los valores negativos de los productos cruzados, el Índice es cercano a cero, lo que puede indicar una tendencia aleatoria o ligeramente agrupada.

Dado que el pvalue es estadísticamente significativo, no se puede rechazar la hipótesis nula de autocorrelación espacial. La distribución espacial de los valores altos y los valores bajos en el conjunto de datos está ligeramente más agrupada espacialmente de lo que se esperaría si los procesos espaciales subyacentes fueran del todo aleatorios.

```
> moran_CONT_C_NN_W <- moran.test(Carb, colW)
> print(moran_CONT_C_NN_W)
```

Moran I test under randomisation

data: Carb
weights: colW

Moran I statistic standard deviate = 0.63065, p-value = 0.2641

alternative hypothesis: greater
sample estimates:

Moran I statistic	Expectation	Variance
0.005235296	-0.025641026	0.002397058




Figura 4. Gráficas de Índice de Moran para vecindad W y Knn diferente.

Lo anterior puede ser confirmado en la Figura 4, donde un valor de I de Moran negativo refleja una mayor dispersión de los datos si se consideran 4 vecinos (valores más altos en x), mientras que se observa el contraste si se incluyen las mayores conexiones entre los datos, lo que indica una mayor agrupación de los datos (valores más altos en y), por lo cual se puede concluir que es mejor la segunda opción si se considera además el tipo de muestreo que se realizó para la variable de interés, pues refleja mejor el comportamiento de los datos.

- Para la vecindad tipo B

En el primer caso, se obtuvo para la vecindad tipo W con $knn=4$, el índice de Moran arrojó un valor de -0.2374 con un $pvalue=0.8658$. Estos resultados son los mismos para el caso de la vecindad W, por lo cual la aseveración de que al obtener un Índice de Moran negativo, indica una tendencia uniforme.

```
> moran_CONT_C_KNN_B <- moran.test(Carb, colB_knn)
> print(moran_CONT_C_KNN_B)
```

Moran I test under randomisation

data: Carb
weights: colB_knn

Moran I statistic standard deviate = -1.1069 , p-value = 0.8658

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
-0.23741231	-0.02564103	0.03659995

En el caso de la segunda prueba con la matriz de vecindad de al menos solo un vecino (considerando todas las conexiones entre coordenadas) se obtuvo un valor de Índice de Moran negativo (-0.0337), con un $pvalue=0.6126$. Dado que el valor de p es estadísticamente significativo y el I de Moran negativo, no se puede rechazar la hipótesis nula. La distribución espacial de los valores altos y los valores bajos en el conjunto de datos está más dispersa

especialmente de lo que se esperaría si los procesos espaciales subyacentes fueran aleatorios.

```
> moran_CONT_C_NN_B <- moran.test(Carb, colB)
> print(moran_CONT_C_NN_B)
```

Moran I test under randomisation

data: Carb
weights: colB

Moran I statistic standard deviate = -0.28603, p-value = 0.6126

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
-0.0337777136	-0.0256410256	0.0008092162

De acuerdo con la Figura 5, se acepta que tienen un patrón disperso o uniforme, lo que concuerda con el tipo de muestreo por conglomerados que busca este tipo de distribución de los datos, y por lo tanto la variable de interés si esta auto correlacionada de manera negativa.




Figura 5. Gráficas de Índice de Moran para vecindad B y Knn diferente.

CONCLUSIONES

De acuerdo con los resultados obtenidos, se sabe que los datos de contenido de C siguen una tendencia uniforme con un Índice de Moran negativo. En este sentido, la estimación del Índice de Moran ayudó a identificar una distancia de la vecindad adecuada para diversos métodos de análisis espacial ($knn=4$) al buscar la distancia donde la autocorrelación espacial es mayor.

LITERATURA CITADA

Celemín, J. P. (2009) 'Autocorrelación espacial e indicadores locales de asociación espacial: Importancia, estructura y aplicación', *Revista Universitaria de Geografía*, 18(1), pp. 11–31. doi: 10.1111/j.1360-0443.2004.00829.x.

RSCRIPT

```
#fijar directorio
setwd("C:/Users/zaira/Documents/00 Maestria Ciencias Forestales/00
Cuatrimestre verano 2018/Geoestadística/Tarea/Autocorrelacion espacial")

# Cargar librerías
library(rgdal)
library(spdep)
library(sp)
require(RANN)

#Leer shp
hojarasca_UTM <- readOGR(dsn=".", layer="hojarasca_shp", pointDropZ =
TRUE)
names(hojarasca_UTM)
plot(hojarasca_UTM,main="Puntos de muestreo - Contenido de
C",col="darkblue")

coords <- coordinates(hojarasca_UTM)
summary(coords)

hojarasca.knn <- knn2nb(knearneigh(coords))
hojarasca.knn

#Vecindad tipo W
colW_knn <- nb2listw(hojarasca.knn, style="W")
```

```
colW_knn

#Vecindad tipo B
colB_knn <- nb2listw(hojarasca.knn, style="B")
colB_knn

#Se consideran todas las conexiones entre coordenadas
all.linked <- max(unlist(nbdists(hojarasca.knn, coords)))
nb <- dnearneigh(coords, 0, all.linked)
colW <- nb2listw(nb, style="W") # Crea otra lista de vecinos
colB <- nb2listw(nb, style="B") # Crea lista vecinos: 0 y 1

par(mfrow=c(1,2))
plot(hojarasca_UTM)
plot(nb, coords, add=TRUE)
box()
title("Todos los vecinos (knn=n-1)")
plot(hojarasca_UTM)
plot(hojarasca.knn, coords, add=TRUE)
box()
title("Solo los 4 vecinos (knn=4)")

Carb <- hojarasca_UTM$CONT_C

## Indice de Moran para vecindad W
moran_CONT_C_KNN_W <- moran.test(Carb, colW_knn)
print(moran_CONT_C_KNN_W)
moran_CONT_C_NN_W <- moran.test(Carb, colW)
print(moran_CONT_C_NN_W)
moran.plot(Carb, colW_knn, pch=20, main = "KNN = 4")
moran.plot(Carb, colW, pch=20, main = "Al menos un vecino")

## Indice de Moran para vecindad B
moran_CONT_C_KNN_B <- moran.test(Carb, colB_knn)
print(moran_CONT_C_KNN_B)
moran_CONT_C_NN_B <- moran.test(Carb, colB)
print(moran_CONT_C_NN_B)
moran.plot(Carb, colB_knn, pch=20, main = "KNN = 4")
moran.plot(Carb, colB, pch=20, main = "Al menos un vecino")
```