



COLEGIO DE POSTGRADUADOS

# COLEGIO DE POSTGRADUADOS

INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS  
AGRÍCOLAS

CAMPUS MONTECILLO

PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

## SIMULACIÓN BOOTSTRAP NO PARAMETRICO

TAREA 6

Geoestadística aplicada en el estudio de los recursos forestales

Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Perez Vazquez

## INTRODUCCIÓN

Los métodos estadísticos clásicos se apoyan en modelos matemáticos de naturaleza estocástica, de tal forma que los resultados derivados requieren, en muchas ocasiones, complejos desarrollos analíticos, lo que han supuesto un obstáculo para su utilización comprensiva en muchas áreas científicas. Además, dichos desarrollos se basan en hipótesis que algunas veces no son soportadas por los datos, o se obtienen resultados asintóticos que no son válidos cuando el tamaño muestral no es suficientemente elevado.

Efron (1979) introduce la metodología bootstrap para estimar las distribuciones de algunos estadísticos cuando el tamaño muestral es pequeño o las expresiones de dichas distribuciones son analíticamente intratables. Desde entonces, numerosos autores han desarrollado métodos bootstrap para diversos procedimientos inferenciales, tales como modelos de regresión, datos censurados, construcción de intervalos de confianza, estimación de parámetros, etc.

Los métodos bootstrap se basan en la reproducción de los datos originales mediante un remuestreo. Si las observaciones tienen una estructura de dependencia, esta debe estar reflejada en los nuevos datos. Por lo tanto, los métodos variarán en función de la estructura temporal existente y como ésta se refleje en el objetivo a perseguir: estimación o predicción.

### • DESCRIPCIÓN DE LA INFORMACIÓN

Se dispone de una muestra formada por 40 observaciones que describen las concentraciones de C en el mantillo del Sitio de Monitoreo Intensivo del Carbono. Se necesita inferir el valor medio de dicha variable aleatoria continua en la población mediante el cálculo de un intervalo de confianza del 95%.

Para ello, se cuenta con los datos ubicados en el archivo Excel "datos\_hojarasca.csv" que cuenta con los siguientes campos (Cuadro 1).

Cuadro 1. Descripción del conjunto de datos contenidos en el archivo csv.

| NOMBRE     | TIPO     | DESCRIPCIÓN                                                                                                | RANGO            |
|------------|----------|------------------------------------------------------------------------------------------------------------|------------------|
| FOLIO      | Numérico | Número del conglomerado en el que se le colecta la información del mantillo.                               | 1-40             |
| TIPO_MUEST | Texto    | Se refiere a la capa de mantillo recolectada.                                                              | Ho:<br>hojarasca |
| ID_COLPOS  | Numérico | Identificador de la muestra, asignado por el laboratorio del COLPOS                                        |                  |
| PESO_MUEST | Numérico | Peso seco de la submuestra enviada al laboratorio                                                          | Gramos           |
| CONC_C     | Numérico | Concentración de Carbono reportada por el laboratorio                                                      | %                |
| CONC_N     | Numérico | Concentración de Nitrógeno reportada por el laboratorio                                                    | %                |
| CONT_C     | Numérico | Contenido de carbono en la capa orgánica del suelo. Es la relación (Peso total * Concentración de C)/100   | g/m <sup>2</sup> |
| CONT_N     | Numérico | Contenido de Nitrógeno en la capa orgánica del suelo. Es la relación (Peso total * Concentración de N)/100 | g/m <sup>2</sup> |
| ANUALIDAD  | Numérico | Es la rodalización del bosque señalados por el año de corta                                                | Años             |
| EDAD       | Numérico | Edad del sitio, calculada por la anualidad                                                                 | Años             |
| UTM_X      | Numérico | Coordenadas UTM x                                                                                          | m                |
| UTM_Y      | Numérico | Coordenadas UTM y                                                                                          | m                |
| ALTITUD    | Numérico | Altitud                                                                                                    | M                |

| RSCRIPT                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |  |  |  |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--|--|--|
| <pre> #Fijar directorio setwd("C:/Users/zaira/Documents/00 Maestria Ciencias Forestales/00 Cuatrimestre verano 2018/Geoestadística/Tarea/Tarea Bootstrap") rm(list=ls()) library(stats) library(MASS) library(survival) library(fitdistrplus) library(boot) library(goftest) #leer información datos&lt;-read.csv("datos_hojarasca.csv") attach(datos) &gt; names(datos) [1] "FOLIO"          "TIPO_MUESTRA"  "ID_COLPOS" [4] "PESO_MUESTRA"  "CONC_C"        "CONC_N" [7] "CONT_C"        "CONT_N"        "ANUALIDAD" [10] "EDAD"          "UTM_X"         "UTM_Y" [13] "ALTITUD" Carbono&lt;-CONC_C #variable de interes </pre> |  |  |  |

Se realizó un análisis exploratorio de los datos, obteniendo medidas de tendencia central, medidas de dispersión y medidas de forma. Obteniendo los siguientes resultados:

| n  | Media   | Mediana | Min  | Max  | Varianza | Sd       | CV        | Curtosis | Asimetría  |
|----|---------|---------|------|------|----------|----------|-----------|----------|------------|
| 40 | 45.6575 | 45.85   | 41.9 | 47.7 | 1.165583 | 1.079622 | 0.0236461 | 5.178932 | -0.9784199 |

De acuerdo con las siguientes figuras, se observa que los datos tienen una distribución que podría no ser normal. Dado que la mediana es mayor que la media y se tiene una asimetría negativa, los datos se encuentran distribuidos hacia la izquierda. Por otra parte, la curtosis al ser un valor positivo superior a 3 indica que tiene colas más pesadas que la distribución normal.




Figura 1. Histograma de frecuencias e histograma de densidades.

Por lo cual, se realizo la prueba de Shapiro Wilks y el gráfico QQ (Figura 2). La prueba de hipótesis es:

*H<sub>0</sub>: Distribución Normal*

*H<sub>a</sub>: Otra distribución*

Dado que se obtuvo un pvalue menor 0.05 se rechaza la hipótesis nula, por lo cual los datos tienen una distribución desconocida.




Figura 2. Gráfico QQ para prueba de normalidad.

### RSCRIPT

```
#Fijar directorio
setwd("C:/Users/zaira/Documents/00 Maestria Ciencias Forestales/00 Cuatr
imestre verano 2018/Geoestadística/Tarea/Tarea Boodstrap")
rm(list=ls())
library(stats)
library(MASS)
library(survival)
library(fitdistrplus)
library(boot)
library(goftest)
#leer información
datos<-read.csv("datos_hojarasca.csv")
attach(datos)
> names(datos)
[1] "FOLIO"          "TIPO_MUESTRA"  "ID_COLPOS"
[4] "PESO_MUESTRA"  "CONC_C"        "CONC_N"
[7] "CONT_C"        "CONT_N"        "ANUALIDAD"
[10] "EDAD"          "UTM_X"         "UTM_Y"
[13] "ALTITUD
Carbono<-CONC_C #variable de interes
```

## • BOOTSTRAP NO PARÁMETRICO

Dado que los datos no se distribuyen normalmente, implica que la aproximación basada en el teorema del límite central para estimar el error estándar deja de ser buena y, por lo tanto, también los intervalos paramétricos que se generen con esa estimación. Una alternativa para poder calcular los intervalos de confianza es emplear *Bootstrapping*.

El método de Bootstrapping se basa en generar nuevas pseudomuestras del mismo tamaño que la muestra real, realizando muestreo repetido de las observaciones. Si la muestra original es representativa de la población, la distribución del estadístico calculada a partir de las pseudomuestras (bootstrapping distribution) se asemejará a la distribución muestral que se obtendría si se pudiera acceder a la población para generar nuevas muestras. De tal forma que:

- La sd de la bootstrapping distribution es un estimador del SE.
- La media de la bootstrapping distribution es un estimador del verdadero parámetro poblacional.

Así pues, a partir de la *bootstrapping distribution* se pueden obtener los valores necesarios para crear el intervalo de confianza sin recurrir al teorema del límite central. Para ello, se fija un tamaño  $m$  igual a 40, y se realizaron 1000 repeticiones.

| RSCRIPT                                             |   |
|-----------------------------------------------------|---|
| > #                                                 | # |
| > #                                                 | # |
| > #                                                 | # |
| > set.seed(1234)                                    |   |
| > boot_times<-1000                                  |   |
| > resultados<-numeric(boot_times)                   |   |
| >                                                   |   |
| > #REMUESTREO BOOTSTRAP                             |   |
| > m<-40                                             |   |
| > boot<-1000                                        |   |
| > bootstrap_media<-function(){                      |   |
| + remuestreo<-sample(Carbono,m,replace = TRUE)      |   |
| + media=mean(remuestreo)                            |   |
| + }                                                 |   |
| > bootstrap_media=replicate(boot,bootstrap_media()) |   |
| > head(bootstrap_media)                             |   |
| [1] 45.5425 45.8275 45.3700 45.5200 46.0825 46.0100 |   |

Una vez realizado el remuestreo, se procedió a obtener los estadísticos descriptivos y conocer la distribución de los datos. Se obtuvieron los siguientes resultados

Cuadro 2. Comparación de datos muestreados vs remuestreo Bootstrap.

| Datos             | Media    | Median  | Min   | Max   | Varianza | Sd       | CV        | Curtosis | Asimetría  |
|-------------------|----------|---------|-------|-------|----------|----------|-----------|----------|------------|
| <b>Originales</b> | 45.6575  | 45.85   | 41.9  | 47.7  | 1.165583 | 1.079622 | 0.0236461 | 5.178932 | -0.9784199 |
| <b>Bootstrap</b>  | 45.65601 | 45.6575 | 45.10 | 46.16 | 0.028139 | 0.167747 | 0.0036741 | 2.93633  | -0.0893617 |

Como se puede observar, la media de bootstrap es similar a la media de las observaciones originales, sin embargo, en la muestra original la mediana es mayor, mientras que con el remuestreo Bootstrap la mediana es similar a la media (Figura 3).




Figura 3. Histograma de frecuencia de datos originales vs remuestreo Bootstrap.




Figura 4. Histograma estandarizado de densidades y ajuste a Distribución Normal.

Así como la asimetría es cercana a 0 y la curtosis es muy cercana a tres (Figura 4). Lo que indica que ahora los datos parecen seguir una distribución Normal. Para confirmar esto, se realizó una prueba de Shapiro-Wilk y se creó la gráfica QQ.




Figura 5. Gráfico QQ para prueba de Normalidad



La prueba de hipótesis es:

*Ho: Distribución Normal*

*Ha: Otra distribución*

Dado que se obtuvo un pvalue estadísticamente significativo (pvalue=0.6443), se acepta la hipótesis nula, y por lo tanto, los datos obtenidos por el remuestreo Bootstrap siguen una distribución normal que atiende a la teoría del límite central.

| RSCRIPT                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <pre> &gt; &gt; #Propiedades del remuestreo &gt; length(bootstrap_media) [1] 1000 &gt; mean(bootstrap_media) [1] 45.65601 &gt; median(bootstrap_media) [1] 45.6575 &gt; summary(bootstrap_media)   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.  45.10  45.55   45.66   45.66   45.77   46.16 &gt; var(bootstrap_media) [1] 0.02813905 &gt; sd(bootstrap_media) [1] 0.167747 &gt; cv2=(sd(bootstrap_media)/mean(bootstrap_media)) &gt; cv2 [1] 0.003674148 &gt; skewness(bootstrap_media) [1] -0.08936171 &gt; kurtosis(bootstrap_media) [1] 2.93633 &gt; par(mfrow=c(1,2)) &gt; hist(Carbono,freq = FALSE,breaks = 20,main = "Histograma de datos orig inales") &gt; hist(bootstrap_media,freq = FALSE,main = "Histograma de remuestreo Boo dstrap") &gt; #Histograma de datos estandarizados &gt; hist((Carbono-mean(Carbono))/(sd(Carbono)),freq = FALSE,breaks = 10,ma in = "Datos Originales",xlab = "X estandarizada") &gt; curve(dnorm(x),add = TRUE,col=) &gt; hist((bootstrap_media-mean(bootstrap_media))/sd(bootstrap_media),freq = FALSE,breaks = 10,main = "Datos Remuestreo Bootstrap",xlab = "X estand arizada") &gt; curve(dnorm(x),add = TRUE) &gt; dev.off() null device       1 </pre> |

La media de la *bootstrapping distribution* debe de ser cercana a la media de la muestra inicial a partir de la cual se está generando el bootstrapping. A esta diferencia se le llama bias. Obteniendo un valor muy pequeño (0.001485) comparado al valor de la media calculada.

| RSCRIPT                                                                                        |
|------------------------------------------------------------------------------------------------|
| <pre>&gt; #bias &gt; BIAS&lt;-mean(Carbono)-mean(bootstrap_media) &gt; BIAS [1] 0.001485</pre> |

Adicionalmente, se obtuvo un intervalo de confianza basado en percentiles, el cual es valido dado que la distribución bootstrapping se asemeja a la normal y el bias es pequeño. El intervalo basado en percentiles no ignora la asimetría de los datos por lo que se suele considerar más adecuado. En caso de no cumplirse estas condiciones, o de que ambos intervalos no se asemejen entre sí, ninguno es fiable.

El intervalo de confianza más adecuado para bootstrapping se conoce como Intervalo Bootstrapping Bias Corrected Accelerated, BCa.

| RSCRIPT                                                                                                                                                                                                            |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <pre>#intervalos de confianza por percentiles #Un IC del 95% debe abarcar desde el percentil #0.025 a 0.975  &gt; quantile(x=bootstrap_media,probs = c(0.025,0.975))       2.5%      97.5% 45.31750 45.96763</pre> |