

TAREA 7 – A

DISTRIBUCIONES DISCRETAS

I. INTRODUCCIÓN

De acuerdo con Evans *et al.* (2005), para muchas variables aleatorias se tiene que $P(X = x) > 0$ para ciertos valores de x . Esto quiere decir que existe una probabilidad positiva de que la variable sea igual a ciertos valores en particular. Si

$$\sum_{x \in R^1} P(X = x) = 1$$

esto significa que la probabilidad *total* asociada a una variable aleatoria X puede obtenerse a partir de que la probabilidad de que X sea igual a ciertos valores concretos. Ello da lugar a la siguiente definición:

Una variable aleatoria X es discreta si

$$\sum_{x \in R^1} P(X = x) = 1$$

En donde, la expresión anterior se diferencia de cualquier variable aleatoria al no cumplirse para la distribución uniforme en $[0,1]$ ni para otras distribuciones continuas. Las variables aleatorias para las que se cumple la expresión anterior pueden considerarse en cierta manera sencillas, ya que pueden comprenderse completamente considerando simplemente sus probabilidades de ser iguales a valores concretos de x .

En otras palabras, una variable aleatoria X es discreta si existe una secuencia finita y enumerable $x_1, x_2, \dots$ de diferentes números reales y otra secuencia correspondiente $p_1, p_2, \dots$ de números reales no negativos tales que $P(X = x_i) = p_i$ para todo i y además se cumple $\sum_i p_i = 1$.

II. DISTRIBUCIÓN POISSON

Decimos que una variable aleatoria Y sigue una distribución de Poisson, y lo representamos por $Y \sim \text{Poisson}(\lambda)$, si:

$$p_Y(y) = P(Y = y) = \frac{\lambda^y}{y!} e^{-\lambda}$$

La distribución de Poisson es un buen modelo para contar las veces que ocurre un suceso cuando el numero de posibles ocurrencias es muy grande pero la probabilidad de cada una de ellas es muy pequeña. Como ejemplos se pueden considerar el número de incendios en una ciudad en un día determinado, el número de impactos registrado por un contador Geiger de radiactividad; el número de llamadas telefónicas que llega a una central, el número de entradas a una página web popular de un determinado día, etc.

En R se cuenta con las siguientes funciones para el manejo de datos con la distribución Poisson (Cuadro 2).

Cuadro 1. Funciones en R para la distribución Poisson.

Función	Descripción
dpois	Encuentra valores para la función de densidad de probabilidad. <code>dpois(x, lambda, log = FALSE)</code>
ppois	Regresa la probabilidad asociada con la función de distribución de probabilidad <code>ppois(q, lambda, lower.tail = TRUE, log.p = FALSE)</code>
rpois	Toma una muestra aleatoria de una distribución Poisson <code>rpois(n, lambda)</code>
qpois	Encuentra cuantiles para la Distribución Poisson <code>qpois(p, lambda, lower.tail = TRUE, log.p = FALSE)</code>

En este sentido, se utilizó el siguiente script en R

SCRIPT IN R

```
> ##### Distribucion Poisson
> help("dpois")
> xpoisson<-rpois(n=200, lambda = 7)
> # Usando dpois
> #si P(X=4)
> dpois(x=4, lambda = 7)
[1] 0.09122619
> #si P(X=0) & P(X=1) & ...& P(X=5)
> dpois(x=0:5, lambda = 7)
[1] 0.000911882 0.006383174 0.022341108 0.052129252 0.091226192
[6] 0.127716668
> #Si P(X<=5)
> sum(dpois(x=0:5, lambda = 7))
[1] 0.3007083

> #Usando ppois
> #Si P(X<=5)
> ppois(q=5, lambda = 7, lower.tail = T)
[1] 0.3007083
> #Si P(X>=12)
> ppois(q=12, lambda = 7, lower.tail = F)
[1] 0.02699977
```

El comando `dpois` puede ser utilizado para encontrar los valores para la función de densidad de probabilidad. Si suponemos que queremos encontrar la probabilidad de que X sea igual a 4, es decir de cuatro ocurrencias con una variable aleatoria con distribución Poisson con una tasa λ igual a 7, podemos ver que hay aproximadamente 9.1% de probabilidad de que $X=4$.

También se pueden obtener múltiples probabilidades, si se supone que queremos encontrar la probabilidad de que pasen 0 ocurrencias, 1 ocurrencia, hasta cinco ocurrencias, se obtiene el valor de cada probabilidad, que va aumentando a medida que el valor de X aumenta su ocurrencia desde 0.09% ($P(X=0)$) hasta 12.77% ($P(X=5)$).

Podemos también encontrar la probabilidad de que x es menor o igual a 5, esto puede ser encontrado de diferentes maneras, tanto a partir de la suma de las probabilidades

de cada una de las ocurrencias, como a partir de usar el comando ppois. Se obtiene una probabilidad de 30.07%.

La función de distribución acumulada F_x de la variable aleatoria discreta Poisson se estimó a partir de su función de probabilidad P_x . En el gráfico se evidencia que se trata de una función por etapas.




Figura 1. Gráficas de distribución Poisson.

Para la creación de las gráficas se utilizó el siguiente script:

SCRIPT IN R

```
##Graficas
> par(mfrow=c(1,3))

> #Histograma y funcion de densidad
> hist(xpoisson,main = "Histograma de datos observados",probability = T
RUE,xlab = "X - Poisson",ylab="Densidad",plot = TRUE,col = "azure3",bor
der = "azure4")
> lines(density(xpoisson),col="red",lwd=2)
> legend("topright",legend = "Funcion de densidad",col = "red",lty = 1:
2,cex = 0.6)

> #Funcion de densidad
> plot(density(xpoisson),main="densidad de datos estimados")

> #Función de distribucion acumulativa empirica
> plot(ecdf(xpoisson),main="ECDF - Distribución Poisson",cex.main=1)
> dev.off()
```

Se realizaron las pruebas de bondad de ajuste de Anderson y Darling, Kolmogorov Smirnov y Cramer von Misses. Se observa que este tipo de pruebas no es adecuado para distribuciones discretas, teniendo pvalues poco significativos.

SCRIPT IN R

```
> #Pruebas de bondad de ajuste
> ks.test(xpoisson,"ppois",7)

One-sample Kolmogorov-Smirnov test

data: xpoisson
D = 0.11971, p-value = 0.006479
alternative hypothesis: two-sided
Warning message:
In ks.test(xpoisson, "ppois", 7) :
  ties should not be present for the Kolmogorov-Smirnov test
> ad.test(xpoisson,"ppois",7)

Anderson-Darling test of goodness-of-fit
Null hypothesis: Poisson distribution

data: xpoisson
An = 3.0241, p-value = 0.02665
> cvm.test(xpoisson,"ppois",7)

Cramer-von Mises test of goodness-of-fit
Null hypothesis: Poisson distribution

data: xpoisson
omega2 = 0.48469, p-value = 0.04346
```

Por lo cual, se utilizará la función `goodfit` perteneciente al paquete "vcd". Este paquete es adecuado para realizar pruebas de bondad de ajuste para datos discretos.

Count data vs Poisson distribution




Figura 2. Distribución Poisson vs Datos de conteo.

SCRIPT IN R

```
> #goodfit ajuste
> library(vcd)
> gfpoisson<-goodfit(xpoisson,type = "poisson",method = "MinChisq")
> summary(gfpoisson)

      Goodness-of-fit test for poisson distribution

      X^2 df  P(> X^2)
Pearson 15.56012 15 0.4118723

Warning message:
In summary.goodfit(gfpoisson) : Chi-squared approximation may be incorrect

> plot(gfpoisson,main="Count data vs Poisson distribution")
```

Distribución binomial negativa

De acuerdo con Evans *et al.* (2005), la distribución binomial negativa se aplica siempre que se cuente el número de fallos hasta que ocurre el r –ésimo éxito en ensayos independientes de un sistema aleatorio en el que la ocurrencia de un determinado suceso se considera un éxito. En otras palabras, se realizan sucesivas repeticiones independientes de pruebas Bernoulli idénticas, con probabilidades de éxito P , hasta que aparece el r –ésimo éxito, y se mide el número de fracasos.

Para lo que más se usa la distribución binomial negativa en el campo de la ingeniería es para saber si el resultado de un proyecto será el adecuado, ya que si la probabilidad de tener muchos fracasos es alta se podría descartar el proyecto antes de tener que invertir en hacer pruebas, ya que estas en el caso de la ingeniería pueden ser bastante complicadas y costosas.

En R se cuenta con las siguientes funciones para el manejo de datos con la distribución binomial negativa (Cuadro 2).

Cuadro 2. Funciones en R para la distribución Binomial Negativa.

Función	Descripción
dnbinom	Encuentra valores para la función de densidad de probabilidad. dnbinom(x, size, prob, mu, log = FALSE)
pnbinom	Regresa la probabilidad asociada con la función de distribución de probabilidad pnbinom(q, size, prob, mu, lower.tail = TRUE, log.p = FALSE)
rnbinom	Toma una muestra aleatoria de una distribución Poisson rnbinom(n, size, prob, mu)
qnbinom	Encuentra cuantiles para la Distribución Poisson qnbinom(p, size, prob, mu, lower.tail = TRUE, log.p = FALSE)

Para ejemplificar su implementación en R, se parte del siguiente supuesto:

“Suponga que del 70% de los sensores para medición de CO₂ en suelo 3 no están defectuosos y se requiere encontrar la probabilidad de tener el segundo sensor sin defectos:

a) en el tercer intento, b) en el sexto intento o antes y c) en el quinto intento o después”

En este sentido, se utilizó el siguiente script en R

SCRIPT IN R
<pre>##Distribucion nbinomial > #Si P(X=3) > dnbinom(x=3-2,2,prob=0.7) [1] 0.294 > #si P(x<=6) > pnbinom(q=6-2,2,prob = 0.7) [1] 0.989065 > #si P(X>=5) > pnbinom(q=6-2,2,prob = 0.7, lower.tail = FALSE) [1] 0.010935 > #generacion de muestra aleatoria > xnbino<-rnbinom(100,2,prob = 0.7) > xnbino [1] 0 0 0 2 1 0 0 1 3 0 0 0 2 0 2 3 1 0 1 1 2 0 0 0 0 0</pre>

[27]	0	4	0	1	1	1	0	1	0	1	0	3	0	1	1	0	2	1	0	0	0	1	1	0	0	1
[53]	1	3	0	0	3	0	0	1	2	4	0	0	0	0	1	2	0	0	0	2	0	0	1	1	2	1
[79]	1	0	1	1	2	0	1	0	3	0	1	2	1	4	1	0	0	0	0	2	0	1				

Para encontrar la solución al inciso a), dado que es un dato puntual, entonces X es igual al tercer intento menos el dato que se quiere hallar, que en este caso es el segundo sensor, obteniendo una probabilidad de 29.4%.

Para la segunda pregunta, de encontrar en el sexto intento o antes se utilizó la función "pnbinom", note que aquí se requiere cambiar el argumento x por el argumento q , dado que si se utiliza x genera un error, pues se necesita el vector de cuantiles. Por lo cual, la probabilidad de encontrar en el sexto intento o antes es igual al 98.90%.

En el último inciso donde se requiere conocer la probabilidad de encontrar fallas en el sensor en el quinto intento o después, se le adicionó el parámetro `lower.tail=false`, es decir, para que tome los valores mayores que X , obteniendo una probabilidad de 1.09%.




Figura 3. Gráficas de distribución Binomial Negativa

Para la creación de las gráficas se utilizó el siguiente script:

SCRIPT IN R
<pre>##Graficas > par(mfrow=c(1,3)) > #Histograma y funcion de densidad > hist(xnbinom,main = "Histograma de datos observados",probability = TRUE,xlab = "X - Binomial negativa",ylab="Densidad",plot = TRUE,col = "azure3",border = "azure4") > lines(density(xnbinom),col="red",lwd=2) > legend("topright",legend = "Funcion de densidad",col = "red",lty = 1:2,cex = 0.9) > #Funcion de densidad > plot(density(xnbinom),main="densidad de datos estimados") > #Función de distribucion acumulativa empirica > plot(ecdf(xnbinom),main="ECDF - Distribución NBinom",cex.main=1)</pre>

Se realizaron las pruebas de bondad de ajuste de Anderson y Darling, Kolmogorov Smirnov y Cramer von Misses. Se observa que este tipo de pruebas no es adecuado para distribuciones discretas, teniendo pvalues poco significativos.

SCRIPT IN R
<pre>> #Pruebas de bondad de ajuste > ks.test(xnbinom,"pnbinom",2,prob = 0.7) One-sample Kolmogorov-Smirnov test data: xnbinom D = 0.49, p-value < 2.2e-16 alternative hypothesis: two-sided Warning message: In ks.test(xnbinom, "pnbinom", 2, prob = 0.7) : ties should not be present for the Kolmogorov-Smirnov test > ad.test(xnbinom,"pnbinom",2,prob = 0.7) Anderson-Darling test of goodness-of-fit Null hypothesis: negative binomial distribution with parameter prob = 0.7 data: xnbinom An = 23.438, p-value = 6e-06</pre>

```

> cvm.test(xnbinom,"pnbinom",2,prob = 0.7)

      Cramer-von Mises test of goodness-of-fit
      Null hypothesis: negative binomial distribution
      with parameter prob = 0.7

data:  xnbinom
omega2 = 4.8431, p-value = 2.333e-11

> #goodfit ajuste
> library(vcd)
> gfnbinom<-goodfit(xnbinom,type = "nbinomial",method = "M ")
> summary(gfnbinom)


      Goodness-of-fit test for nbinomial distribution

              X^2 df  P(> X^2)
Likelihood Ratio 2.725267  2 0.2559858
> plot(gfnbinom,main="Count data vs nbinomial distribution")

```

Por lo cual, se utilizará la función `goodfit` perteneciente al paquete “vcd”. Este paquete es adecuado para realizar pruebas de bondad de ajuste para datos discretos (Figura 4).

Figura 4. Distribución Binomial Negativa vs Datos de conteo.



TAREA 7 – B

DESGLOSE DE ECUACIÓN DEL ÍNDICE DE MORAN

INTRODUCCIÓN

La importancia del espacio dentro del estudio estadístico de diversas variables es incuestionable. En concreto, el problema de la dependencia espacial, y en particular de la autocorrelación espacial ha sido objeto de una gran cantidad de estudios (Cressie, 1991; Lu *et al.*, 2007; Celemin, 2009; Jørgensen and Fath, 2011)

La estadística presenta la mayor parte de sus resultados bajo el supuesto de independencia, cuando se viola esta condición, los resultados obtenidos ya no son válidos.

En el caso de la estadística espacial el problema que se plantea es la pérdida de la condición de independencia de las observaciones tomadas en un área determinada. Así, en este tipo de modelos se supone que si encontramos una determinada observación en un punto de esta área es más fácil (o inversamente más difícil) encontrar observaciones semejantes en puntos próximos a éste que en puntos alejados. Es decir, hay latente en la localización de las observaciones una compleja información sobre las observaciones del entorno. La complejidad del problema aumenta debido a las interdependencias multidireccionales que se pueden plantear en el espacio. Los datos espaciales son medidas u observaciones que tienen asociada una localización específica y de forma general podemos referirnos a ellos como datos georeferenciados. Estas observaciones pueden ser de tipo discreto o continuo. La localización que tiene asociada cada observación puede ser un punto cualquiera de una determinada superficie, o bien estar asociada a un área de una superficie sobre la que se ha realizado una partición. Esta partición puede ser regular o irregular, y habitualmente se conoce como *lattice*¹ o retícula. En función de toda esta casuística se presentan diferentes modelos que llevan asociados diferentes tratamientos estadísticos.

Índice de Moran

Con el fin de poner de manifiesto la presencia de autocorrelación espacial en un conjunto de datos se han presentado en la literatura diferentes estadísticos que son capaces de evaluar la ausencia o carencia de esta propiedad en un conjunto de observaciones. Uno de los ejemplos más relevantes es el Índice de Morán, es el estadístico más utilizado, se encuentra dado por la siguiente ecuación:

$$\frac{N \sum_{i=1}^n \sum_{j=1}^n W_{ij} (x_i - \bar{x})(x_j - \bar{x})}{(\sum_{i=1}^n \sum_{j=1}^n W_{ij}) \sum_{i=1}^n (x_i - \bar{x})^2}$$

Este estadístico puede tomar valores positivos y negativos entre -1 y 1, dependiendo del signo de la correlación espacial, de tal manera que, si la correlación es positiva, obtendremos valores de I positivos y viceversa, si la correlación espacial es negativa obtendremos valores del índice negativos.

El índice de Moran mide de forma global la presencia o ausencia de autocorrelación espacial en un conjunto de observaciones distribuidas sobre una superficie. Dado que este fenómeno de mimetismo entre zonas no es necesariamente uniforme en todo el espacio, así no todas las zonas ejercen la misma influencia en su entorno, y tampoco con el mismo grado. Con la idea de cuantificar la contribución que cada zona aporta al Índice de Moran surgen los indicadores de autocorrelación parciales.

Desglose del índice de Moran.

$$\frac{N \sum_{i=1}^n \sum_{j=1}^n W_{ij} (x_i - \bar{x})(x_j - \bar{x})}{(\sum_{i=1}^n \sum_{j=1}^n W_{ij}) \sum_{i=1}^n (x_i - \bar{x})^2}$$

🔗 Partiendo primero del numerador, se tiene la siguiente ecuación:

$$N \sum_{i=1}^n \sum_{j=1}^n W_{ij} (x_i - \bar{x})(x_j - \bar{x})$$

1) Trabajando primero con la sumatoria para el índice j, se tiene el siguiente desglose:

$$N \sum_{i=1}^n [(W_{i1}(x_i - \bar{x})(x_1 - \bar{x})) + (W_{i2}(x_i - \bar{x})(x_2 - \bar{x})) + \cdots + (W_{in}(x_i - \bar{x})(x_n - \bar{x}))]$$

2) Trabajando después con la sumatoria para el índice i, se tiene el siguiente desglose:

$$\begin{aligned} N\{ & [(W_{11}(x_1 - \bar{x})(x_1 - \bar{x})) + (W_{12}(x_1 - \bar{x})(x_2 - \bar{x})) + \cdots + (W_{1n}(x_1 - \bar{x})(x_n - \bar{x}))] \\ & + [W_{21}(x_2 - \bar{x})(x_1 - \bar{x}) + W_{22}(x_2 - \bar{x})(x_2 - \bar{x}) + \cdots + W_{2n}(x_2 - \bar{x})(x_n - \bar{x})] \\ & + \cdots \\ & + [W_{n1}(x_n - \bar{x})(x_1 - \bar{x}) + W_{n2}(x_n - \bar{x})(x_2 - \bar{x}) + \cdots + W_{nn}(x_n - \bar{x})(x_n - \bar{x})]\} \end{aligned}$$

🌈 Para el caso del denominador, se tiene la siguiente ecuación:

$$\left(\sum_{i=1}^n \sum_{j=1}^n W_{ij} \right) \sum_{i=1}^n (x_i - \bar{x})^2$$

3) Partiendo primero con el primer componente de la ecuación:

$$\left(\sum_{i=1}^n \sum_{j=1}^n W_{ij} \right)$$

4) Trabajando primero con la sumatoria para el índice j, se tiene el siguiente desglose:

$$\sum_{i=1}^n [W_{i1} + W_{i2} + \cdots + W_{in}]$$

5) Trabajando después con la sumatoria para el índice i, se tiene el siguiente desglose:

$$[W_{11} + W_{12} + \cdots + W_{1n}] + [W_{21} + W_{22} + \cdots + W_{2n}] + \cdots + [W_{n1} + W_{n2} + \cdots + W_{nn}]$$

- 6) Posteriormente, desglosando el segundo componente de la ecuación del denominador:

$$\sum_{i=1}^n (x_i - \bar{x})^2$$

- 7) El desglose de la ecuación es el siguiente:

$$(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots (x_n - \bar{x})^2$$

- 8) Uniendo los dos componentes, se obtiene la ecuación siguiente para el denominador:

$$\{[W_{11} + W_{12} + \cdots + W_{1n}] + [W_{21} + W_{22} + \cdots + W_{2n}] + \cdots + [W_{n1} + W_{n2} + \cdots + W_{nn}]\} \\ * \{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots (x_n - \bar{x})^2\}$$

🌈 Por lo cual se tiene lo siguiente, la ecuación del Índice de Moran es el siguiente:

$$\frac{N \sum_{i=1}^n \sum_{j=1}^n W_{ij} (x_i - \bar{x})(x_j - \bar{x})}{(\sum_{i=1}^n \sum_{j=1}^n W_{ij}) \sum_{i=1}^n (x_i - \bar{x})^2}$$

Y su ecuación desglosada es:

$$\frac{N \{[(W_{11}(x_1 - \bar{x})(x_1 - \bar{x})) + (W_{12}(x_1 - \bar{x})(x_2 - \bar{x})) + \cdots + (W_{1n}(x_1 - \bar{x})(x_n - \bar{x}))] + \\ + [W_{21}(x_2 - \bar{x})(x_1 - \bar{x}) + W_{22}(x_2 - \bar{x})(x_2 - \bar{x}) + \cdots + W_{2n}(x_2 - \bar{x})(x_n - \bar{x})] + \\ \cdots + [W_{n1}(x_n - \bar{x})(x_1 - \bar{x}) + W_{n2}(x_n - \bar{x})(x_2 - \bar{x}) + \cdots + W_{nn}(x_n - \bar{x})(x_n - \bar{x})]\}}}{[W_{11} + W_{12} + \cdots + W_{1n}] + [W_{21} + W_{22} + \cdots + W_{2n}] + \cdots + [W_{n1} + W_{n2} + \cdots + W_{nn}] \\ * \{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots (x_n - \bar{x})^2\}}$$

Se observa que $x_i - \bar{x}$ representa la desviación de un atributo i o j a su media, mientras que la matriz de pesos entre la característica i y j , y finalmente N es el total de características u observaciones.

Finalmente, $\sum_{i=1}^n \sum_{j=1}^n W_{ij}$ representa el agregado de todos los pesos espaciales.

LITERATURA CITADA

- Celemín, J. P. (2009) 'Autocorrelación espacial e indicadores locales de asociación espacial: Importancia, estructura y aplicación', *Revista Universitaria de Geografía*, 18(1), pp. 11–31. doi: 10.1111/j.1360-0443.2004.00829.x.
- Cressie, N. A. C. (1991) *Statistics for Spatial Data* | *Statistics for Spatial Data*, New York. doi: 10.2307/2533238.
- Evans, J. M., Jeffrey S. y Rosenthal S. (2005). Probabilidad y Estadística. La ciencia de la incertidumbre. Ed. Reverte. 2da Ed. 758 p
- Jørgensen, S. E. and Fath, B. D. (2011) 'Spatial Modelling', in *Fundamentals of Ecological Modelling*, pp. 347–368. doi: 10.1016/B978-0-444-53567-2.00011-9.
- Lu, M. Von *et al.* (2007) 'SOM fractionation methods: Relevance to functional pools and to stabilization mechanisms', 39, pp. 2183–2207. doi: 10.1016/j.soilbio.2007.03.007.