



COLEGIO DE POSTGRADUADOS

COLEGIO DE POSTGRADUADOS

INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS

CAMPUS MONTECILLO

PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

SEMIVARIOGRAMAS

TAREA 10

Geoestadística aplicada en el estudio de los recursos forestales

Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Pérez Vázquez

INTRODUCCIÓN

El semivariograma es la función básica que describe la variabilidad espacial de un fenómeno de interés, indicando que tan parecidos se encuentran estos puntos a medida que estos se encuentran más alejados (Gallardo, 2006). Para cualquier variable analizada podemos calcular la varianza encontrada entre todos los pares de puntos separados por una distancia determinada, la representación gráfica de todas estas varianzas en función de la distancia que separa a las muestras es el semivariograma (o variograma).

La función del variograma muestra la variación de la variable agrupando los datos según sus distancias relativas, su función es

$$\gamma(h) = \frac{1}{2N(h)} \sum_{i=1}^n (Z_{(x)} - Z_{(x+h)})^2$$

Donde,

$\gamma(h)$ es la semivarianza para todas las muestras localizadas en el espacio se parado por el intervalo de distancia h ;

$N(h)$ es el número total de pares de muestras separados por un intervalo de distancia h ;

Z_x es el valor de la muestra en una localización x ;

$Z_{(x+h)}$ es el valor de la muestra a la distancia de intervalo h desde x .

El variograma es la piedra angular de muchas aplicaciones geoestadísticas. El variograma experimental y cualquier modelo ajustado a él deben ser precisos, solo entonces, el modelo puede describir su variación de manera confiable. Kriging requiere un variograma, y es asegurando su precisión que eventualmente obtendrá predicciones de varianza mínima para el proceso de interpolación. Si el variograma describe la variación pobremente entonces las predicciones de kriging también serán pobres, y pueden tener poca o ninguna validez, sin importar que tan "bonito" sea el mapa (Oliver and Webster, 2015).

En algunos paquetes estadísticos y varios de Sistemas de Información Geográfica la generación del variograma y la interpolación kriging es automática. Como consecuencia de

tal enfoque de caja negra, el variograma es computarizado y modelado, los valores de los parámetros derivados son insertados en la ecuación kriging sin ninguna intervención o evaluación del usuario. Como resultado, el usuario desconoce la forma del semivariograma o si el modelo tiene un buen ajuste.

Por lo anterior, el objetivo del presente trabajo es crear un variograma empírico y ajustar a diversos modelos con la finalidad de seleccionar el modelo que presente un mejor ajuste al comportamiento espacial de los datos.

DESCRIPCIÓN DE LA INFORMACIÓN

Se tiene interés en generar los semivariogramas para la variable de “contenidos de carbono (gramos de C)” en el mantillo del cuadrante central del Sitio del Monitoreo Intensivo de Carbono de Hidalgo (Figura 1). Para ello, se cuenta con los siguientes archivos shapefile (Cuadro 1):

Puntos de muestreo y área de estudio




Figura 1. Ubicación de los conglomerados dentro del SMIC-Hgo.

Cuadro 1. Descripción de archivos shapefile empleados.

NOMBRE	TIPO	DESCRIPCIÓN
polígono_3x3	Polígono	Incluye los límites del área de estudio. es un cuadrante con una superficie de 900 ha, de 3 km de largo de cada uno de sus lados. Se encuentra dividido en nueve subcuadrantes de 1 km x 1km.
polígono_Central	Polígono	Incluye únicamente los límites del cuadrante central del área de estudio.
puntos_densos	Puntos	Muestra la ubicación geográfica de los puntos de muestreo.

Con respecto al archivo "puntos_densos.shp" cuenta con los siguientes campos (Cuadro 2):

Cuadro 2. Descripción de los datos.

NOMBRE	TIPO	DESCRIPCIÓN	RANGO
FOLIO	Numérico	Número del conglomerado en el que se le colecta la información del mantillo.	1-40
SITIO	Numérico	Se refiere al sitio o parcela secundaria de medición	1-4
DENSIDAD_MU	Texto	Indica si pertenece o no al cuadrante central	Den
UTM_X	Numérico	Coordenadas UTM x	m
UTM_Y	Numérico	Coordenadas UTM y	m
ALTITUD	Numérico	Altitud	m
ANUALIDAD_	Numérico	Es la rodalización del bosque señalados por el año de corta	Años
EDAD_2013	Numérico	Edad del sitio, calculada por la anualidad	Años
MANTILLO_G	Numérico	Contenido de carbono en la capa orgánica del suelo.	g/m ²
AREA	Numérico	Área de la parcela	m ²

RSCRIPT

#Información utilizada

```

> SMIC<-readShapePoly("Poligono_3x3.shp")
> Carbono_mantillo<-readShapePoints("puntos_densos.shp")
> baseexcel<-read.csv("Base_Puntos cuadrante central.csv")
> poligono_Central<-readShapePoly("poligono_Central.shp")

> names(Carbono_mantillo)
[1] "folio"      "sitio"      "densidadmu" "utm_x"      "utm_y"
[6] "altitul_ms" "Anualidad_" "Edad_2013"  "folio_1"    "sitio_1"
[11] "mantillo_g" "area_m2"

> Cmantillo<-Carbono_mantillo$mantillo_g
> Cmantillo
[1] 1172.1322  817.4406 1471.3336  890.5346  717.4608 1762.3367
[7]  990.6177  558.1119  651.4693  793.3248 1211.4787 1409.8012
[13] 1099.7035 1223.5109  770.2523  672.6462  715.1566  317.1330
[19] 1109.3726 2078.2355  968.3315  705.9874  951.3644  991.8887
[25]  760.6916 1049.4872  931.2759 1237.8455 1247.4121 1591.4127
[31] 1357.4188  998.7937  862.1594  838.9383  711.4881  143.8021
[37]  799.1363 2081.6105 1013.6737 1195.6800  380.4631  460.9242
[43]  479.7110  622.3222  384.8409 1069.8068  569.5754  736.0092
[49]  303.2429  546.3262  597.4511 1153.5956 1223.8450  701.6772
[55] 1321.7800  707.1700  811.7046  559.5827  613.2744 1016.0886
[61] 1296.4504 1165.6979  873.1289 1185.7667 1457.1565 1380.0836
[67] 1779.2982 1213.2287  962.1273 1117.8870 1018.8287  887.3384
[73]  693.8141  853.5602 1402.2412 1205.3406 1169.2463 1849.3896
[79]  793.2828 1718.2679  853.9286  722.0593 1418.1468  971.8654
[85]  677.2556 1060.0233  520.3581 1193.4315  333.7934 1036.9780
[91]  239.3661  169.9143

```



DESCRIPCIÓN DE LA VARIABLE

Los contenidos de C en mantillo están expresados en g/m², de acuerdo con la Figura 2, se observa que los datos siguen una distribución uniforme, la cual es consistente con el diseño en conglomerados con el cual se recogieron los datos.




Figura 2. Gráfico de distribución del conjunto de datos en los ejes X y Y.

Además del análisis exploratorio clásico, se probó la normalidad de los datos con la prueba de *Shapiro-Wilk*, *Kolmogorov Smirnov*, *Anderson Darling* y *Cramer von mises*. La prueba de hipótesis fue:

$$H_0 = \text{Normalidad}$$

$$H_a = \text{Otra distribución}$$

La estacionariedad de la variable se probó mediante la prueba de *Augmented Dickey Fuller Test* (ADF), la cual elimina la autocorrelación e indica si un conjunto de datos es estacionario o no. adicionalmente se complementó con el *Test de Phillipe Perron*, el cuál es una modificación del test anterior, a diferencia que este aborda la cuestión de que el proceso de generación de datos para la variable de interés podría tener un orden superior de autocorrelación. La prueba de hipótesis fue:

$$H_0 = \text{No es estacionaria}$$

$$H_a = \text{Lo contrario}$$

Para el caso de normalidad, los valores de pvalue son estadísticamente significativos en todas las pruebas, por lo cual no se rechaza la hipótesis nula y se concluye que los datos son normales (Figura 3). Para el caso de la prueba de estacionariedad, los valores de pvalue son menores a 0.05 en ambas pruebas, por lo cual se rechaza la hipótesis nula de no estacionariedad y se concluye que el conjunto de datos presenta estacionariedad (Figura 4).




Figura 3. Gráfico QQ Plot para normalidad de los datos.




Figura 4. Dispersión de los datos, en el Eje X el número de muestras, en el eje Y el contenido de C.

RSCRIPT

```
> #Prueba de normalidad
> qqPlot(Cmantillo,xlab = "Quantiles",ylab="Gramos de C en mantillo")
[1] 38 20
> ks.test(Cmantillo,"pnorm",mean(Cmantillo),sd(Cmantillo))
```

One-sample Kolmogorov-Smirnov test

```
data: Cmantillo
D = 0.063514, p-value = 0.8288
alternative hypothesis: two-sided
```

```
> shapiro.test(Cmantillo)
```

Shapiro-Wilk normality test

```
data: Cmantillo
W = 0.98009, p-value = 0.1725
```

```
> ad.test(Cmantillo,"pnorm",mean(Cmantillo),sd(Cmantillo))

Anderson-Darling test of goodness-of-fit
Null hypothesis: Normal distribution

data: Cmantillo
An = 0.40072, p-value = 0.8477

> cvm.test(Cmantillo,"pnorm",mean(Cmantillo),sd(Cmantillo))

Cramer-von Mises test of goodness-of-fit
Null hypothesis: Normal distribution

data: Cmantillo
omega2 = 0.051818, p-value = 0.8663

#Estacionariedad
> adf.test(diff(Cmantillo),alternative = "stationary",k=0)

Augmented Dickey-Fuller Test

data: diff(Cmantillo)
Dickey-Fuller = -14.933, Lag order = 0, p-value = 0.01
alternative hypothesis: stationary

> pp.test(diff(Cmantillo),alternative = "stationary")

Phillips-Perron Unit Root Test

data: diff(Cmantillo)
Dickey-Fuller Z(alpha) = -114.72, Truncation lag parameter =
3, p-value = 0.01
alternative hypothesis: stationary
```

Para conocer el comportamiento de la información espacial georreferenciada, en particular el tipo de asociación existente entre unidades espaciales vecinas, se calculó la matriz de vecindad y el índice de moran para conocer el valor de autocorrelación espacial.

RSCRIPT – Matriz de vecindades

```
> ##Autocorrelacion espacial
> #Indice de moran
> coorden<-coordinates(Carbono_mantillo)
> coorden

> summary(coorden)
coords.x1      coords.x2
```



```

Min.      :541876   Min.      :2278936
1st Qu.:542082   1st Qu.:2279129
Median :542208   Median :2279364
Mean    :542269   Mean    :2279428
3rd Qu.:542451   3rd Qu.:2279694
Max.    :542707   Max.    :2279941
> mantillo.knn<-knn2nb(knearneigh(coorden))
> mantillo.knn
Neighbour list object:
Number of regions: 92
Number of nonzero links: 92
Percentage nonzero weights: 1.086957
Average number of links: 1
Non-symmetric neighbours list
> #vecindad tipo w
> colW_knn<-nb2listw(mantillo.knn,style = "w")
> colW_knn
Characteristics of weights list object:
Neighbour list object:
Number of regions: 92
Number of nonzero links: 92
Percentage nonzero weights: 1.086957
Average number of links: 1
Non-symmetric neighbours list

Weights style: W
Weights constants summary:
      n  nn S0  S1  S2
W 92 8464 92 138 492
> colB_knn<-nb2listw(mantillo.knn,style = "B")
> colB_knn
Characteristics of weights list object:
Neighbour list object:
Number of regions: 92
Number of nonzero links: 92
Percentage nonzero weights: 1.086957
Average number of links: 1
Non-symmetric neighbours list

Weights style: B
Weights constants summary:
      n  nn S0  S1  S2
B 92 8464 92 138 492
> #considerando todas las conexiones
> all.linked <- max(unlist(nbdists(mantillo.knn, coorden)))
> all.linked
[1] 56.89433
> nb <- dnearneigh(coorden, 0, all.linked)
> nb
Neighbour list object:
Number of regions: 92
Number of nonzero links: 150
Percentage nonzero weights: 1.772212
Average number of links: 1.630435
> colW <- nb2listw(nb, style="w") # Crea otra lista de vecinos
> colW
Characteristics of weights list object:

```

```
Neighbour list object:
Number of regions: 92
Number of nonzero links: 150
Percentage nonzero weights: 1.772212
Average number of links: 1.630435

Weights style: W
Weights constants summary:
      n  nn S0      S1      S2
W 92 8464 92 116.7222 470.8611
> colW$style
[1] "W"
> colW$neighbours
Neighbour list object:
Number of regions: 92
Number of nonzero links: 150
Percentage nonzero weights: 1.772212
Average number of links: 1.630435
> colW$weights

> colB <- nb2listw(nb, style="B") # Crealista vecinos: 0 y 116.7222
> colB
Characteristics of weights list object:
Neighbour list object:
Number of regions: 92
Number of nonzero links: 150
Percentage nonzero weights: 1.772212
Average number of links: 1.630435

Weights style: B
Weights constants summary:
      n  nn S0  S1  S2
B 92 8464 150 300 1288
> colB$style
[1] "B"
> colB$neighbours
Neighbour list object:
Number of regions: 92
Number of nonzero links: 150
Percentage nonzero weights: 1.772212
Average number of links: 1.630435
> colB$weights
> plot(Carbono_mantillo, pch=20, col="green")
> plot(nb, coorden, add=TRUE)
> plot(poligono_Central, border="gray", add=TRUE)
> title("Vecindad")
```

as vecindades que se utilizaran son con base en el diseño de conglomerados que se tiene. Como se muestra en la Figura 5 :




Figura 5. Vecindades consideradas dentro del diseño de conglomerados

Para el caso del índice de moran, se estimó para la matriz de vecindades tipo B y tipo W. La prueba de hipótesis fue:

$$H_0 = \text{la muestra es aleatoria}$$

$$H_a = \text{lo contrario}$$

Dado que para ambos tipos de vecindad se obtuvo índice positivo, con pvalue menor a 0.05, se rechaza la hipótesis nula, concluyendo que los datos presentan autocorrelación positiva, con tendencia a agruparse, lo cual es de esperarse, dado el diseño por conglomerados bajo el cual se está trabajando.

RSCRIPT
<pre>> #indice de moran > #para matriz B > idemoranb<-moran.test(Cmantillo,colB) > idemoranb</pre>

```

Moran I test under randomisation

data: Cmantillo
weights: colB

Moran I statistic standard deviate = 2.9406, p-value = 0.001638
alternative hypothesis: greater
sample estimates:
Moran I statistic      Expectation      Variance
0.32292263           -0.01098901          0.01289429

> moran.plot(Cmantillo,colB,pch=20, main="Grafica tipo B")

#ho la muestra es aleatoria. Se rechaza Ho
#ha la muestra no lo es.#Distribucion agregada

> #para matriz B
> idemoranW<-moran.test(Cmantillo,colW)
> idemoranW

Moran I test under randomisation

data: Cmantillo
weights: colW

Moran I statistic standard deviate = 2.6143, p-value = 0.004471
alternative hypothesis: greater
sample estimates:
Moran I statistic      Expectation      Variance
0.29126467           -0.01098901          0.01336698

> moran.plot(Cmantillo,colW,pch=20,main="Grafica tipo W")

```

Se tomará la matriz de vecindades tipo B, cuyo índice de Moran es mayor.




Figura 6. Matriz de vecindades tipo B y W.

OBTENCIÓN DEL VARIOGRAMA EMPÍRICO

La primera tarea es estimar el variograma de los datos muestreados, decimos $z(x_1), z(x_2) \dots$ donde $x_1, x_2, \dots$ denota la posición de la muestra en dos dimensiones espaciales. Dada la realización del fenómeno, la función de semivarianza es estimada, por el método de momentos, a través del semivariograma experimental, que se calcula mediante

$$\gamma(h) = \frac{\sum (Z(x+h) - Z(x))^2}{2n}$$

Donde $Z(x)$ es el valor de la variable en un sitio x , $Z(x+h)$ es otro valor muestral separado del anterior por una distancia h y n es el número de parejas que se encuentran separadas por dicha distancia. La función de semidistancia se calcula para varias distancias h . En la práctica, debido a la irregularidad en el muestreo y por ende en las distancias entre los sitios, se toman intervalos de distancias $\{0, h], (h, 2h], (2h, 3h], \dots\}$ y el semivariograma experimental corresponde a una distancia promedio entre parejas de sitios dentro de cada intervalo y no a una distancia h específica. Obviamente el número de parejas de puntos n dentro de los intervalos no es constante.

Para interpretar el semivariograma experimental se parte del criterio de que a menor distancia entre los sitios con mayor similitud o correlación espacial entre las observaciones. Por ello, en presencia de autocorrelación se espera que para valores de h pequeños el semivariograma experimental tenga magnitudes menores a las que esta toma cuando las distancias h se incrementan.

Asimismo, se crearon dos variogramas, el primero con los parámetros que R ajusta automáticamente, en el segundo, la distancia de separación espacial hasta la cual los pares de puntos se incluyen en las estimaciones de semivarianza fue establecida como 250 metros (que es a la distancia a la cual se encuentran distanciados los conglomerados). Para el ancho de los intervalos de distancia subsiguientes en los que se agrupan los pares de puntos de datos para las estimaciones de semivarianza, se ajustó a $width = 30$




Figura 7. Variograma experimental omnidireccional

Se observa un que en el primer variograma existe un efecto pepita que se distingue dado que al avanzar en determinadas distancias, los valores de semivarianza presentan picos de incremento, que pueden deberse a microvariaciones o a errores a pequeña escala. Mientras que una vez que se definieron esos parámetros el efecto se reduce.

Además, se creó la nube de ambos variogramas, con el objetivo de detectar valores atípicos o bruscos y para distinguir la dispersión alrededor de la semivarianza. Se observa una mayor dispersión y datos atípicos para el semivariograma con parámetros ajustados por R, mientras que disminuyen una vez que se definen el cutoff y el width (Figura 8).




Figura 8. Nube de semivariogramas.

RSCRIPT

```
> ##Semivariogramas empiricos
> mantillo.v<-variogram(Cmantillo~1,Carbano_mantillo)
> mantillo.v
```

	np	dist	gamma	dir.hor	dir.ver	id
1	2	17.46232	3134.643	0	0	var1
2	73	45.48050	105904.030	0	0	var1
3	80	76.40311	152536.970	0	0	var1
4	32	101.34403	136915.536	0	0	var1
5	56	131.41976	197666.452	0	0	var1
6	70	159.27087	124648.610	0	0	var1
7	105	187.92715	184506.563	0	0	var1
8	132	216.46803	169417.349	0	0	var1
9	198	247.23046	191267.803	0	0	var1
10	141	275.00250	131505.159	0	0	var1
11	165	304.61730	175932.214	0	0	var1
12	151	333.78120	159857.521	0	0	var1
13	184	360.82605	198648.769	0	0	var1
14	163	390.89680	206293.526	0	0	var1
15	126	421.00715	178830.787	0	0	var1

```
> plot(mantillo.v,main="Variograma empirico",
+       xlab="Distancia",ylab="Semivarianza")
> #nube
> mantillo.v.nube<-variogram(Cmantillo~1,Carbano_mantillo,cloud=TRUE)
```

```

> plot(mantillo.v.nube,main="Variogram cloud",xlab="distancia",ylab="sem
ivarianza")
> mantillo.v2<-variogram(Cmantillo~1,Carbano_mantillo,cutoff=250,width=3
0)
> mantillo.v2
      np      dist      gamma dir.hor dir.ver   id
1    2  17.46232  3134.643      0      0 var1
2   74  45.65710 104902.391      0      0 var1
3   82  77.03640 153595.355      0      0 var1
4   38 106.22115 126654.427      0      0 var1
5   60 137.02616 208452.781      0      0 var1
6   81 166.57443 148975.469      0      0 var1
7  120 196.12929 167479.247      0      0 var1
8  139 225.70084 168601.001      0      0 var1
9   70 245.49232 189831.339      0      0 var1
> plot(mantillo.v2,main="Variograma empirico (cutoff=250,width=30)",
+       xlab="Distancia",ylab="Semivarianza")
> #nube
> mantillo.v2.nube<-variogram(Cmantillo~1,Carbano_mantillo,cutoff=250,wi
dth=30,clou=TRUE)
> plot(mantillo.v2.nube,main="Variogram cloud (cutoff=250,width=30)",xla
b="distancia",ylab="semivarianza")
> #mapa
> mantillo.v2.map<-variogram(Cmantillo~1,Carbano_mantillo,cutoff=250,wid
th=30,map=TRUE)

```


AJUSTE A UN MODELO TEÓRICO

Para el ajuste del semivariograma teórico, lo primero que se hace es una inspección visual, una vez calculado el semivariograma experimental o empírico, el siguiente paso es el ajuste a un modelo teórico conocido, para ello se definieron los siguientes parámetros derivados del semivariograma empírico:







$$nugget = 0, \quad rango = 80, \quad meseta = 160,000$$

Para el ajuste a un modelo teórico, se probaron los modelos: esférico, exponencial, nugget, gaussiano, matern, circular, Bessel, pentaesférico, wave, stein, lineal, hole, exclass, logarítmico, measurement error e intercept (Cuadro 3).

Cuadro 3. Modelos de Semivariogramas Ajustados




MODELOS DE SEMIVARIOGRAMAS

MATERN			CIRCULAR		
					
Nugget	Sill	Range	Nugget	Sill	Range
0	184021.3	55.20424	0	165698.1	90.63846
MODELO BESSEL			MODELO PENTAESFÉRICO		
					
Nugget	Sill	Range	Nugget	Sill	Range
0	176137.5	30.33921	0	170034.2	131.6659
MODELO WAVE			MODELO STEIN		
					
Nugget	Sill	Range	Nugget	Sill	Range
0	128532.5	46.88587	0	184013.2	78.062

MODELOS DE SEMIVARIOGRAMAS

LINEAL



Nugget

Sill


Range

0

160108.9

71.41742

HOLE



Nugget

Sill


Range

1.975414

80711.170761

501.6692

MODELO EXCLASS



Nugget

Sill


Range

0

382244.1

458.461

MODELO INTERCEPT



Nugget

Sill

Range

0

167483.1

0

RSCRIPT

```
##Ajuste a un modelo teorico.
#nugget=0, rango=80, sill=160000
pepita=0
rango=80
meseta=160000

#modelo teorico esferico
mantillo.vf.sph<-fit.variogram(mantillo.v2,vgm(meseta,"Sph",rango,pepita
,fit.method=2))
mantillo.vf.sph
plot(mantillo.v2,mantillo.vf.sph,main="Empirico y Esferico",pch=7,col="r
ed",xlab="DISTANCIA",ylab="SEMIVARIANZA")
```

```
#modelo teorico gaussiano
mantillo.vf.gau<-fit.variogram(mantillo.v2,vgm(meseta,"Gau",rango,pepita
,fit.method=2))
mantillo.vf.gau
plot(mantillo.v2,mantillo.vf.gau,main="Empirico y Gaussiano",pch=7,col="
red",xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico exponencial
mantillo.vf.exp<-fit.variogram(mantillo.v2,vgm(meseta,"Exp",rango,pepita
,fit.method=2))
mantillo.vf.exp
plot(mantillo.v2,mantillo.vf.exp,main="Empirico y Exponencial",pch=7,col
="red",xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico nugget
mantillo.vf.nug<-fit.variogram(mantillo.v2,vgm(meseta,"Nug",0,pepita,fit
.method=2))
mantillo.vf.nug
plot(mantillo.v2,mantillo.vf.nug,main="Empirico y Nugget",pch=7,col="red
",xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico matern
mantillo.vf.mat<-fit.variogram(mantillo.v2,vgm(meseta,"Mat",rango,pepita
,fit.method=2))
mantillo.vf.mat
plot(mantillo.v2,mantillo.vf.mat,main="Empirico y Matern",pch=7,col="red
",xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico circular
mantillo.vf.cir<-fit.variogram(mantillo.v2,vgm(meseta,"Cir",rango,pepita
,fit.method=2))
mantillo.vf.cir
plot(mantillo.v2,mantillo.vf.cir,main="Empirico y Circular",pch=7,col="r
ed",xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico bessel
mantillo.vf.bes<-fit.variogram(mantillo.v2,vgm(meseta,"Bes",rango,pepita
,fit.method=2))
mantillo.vf.bes
plot(mantillo.v2,mantillo.vf.bes,main="Empirico y Bessel",pch=7,col="red
",xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico pentaesferico
mantillo.vf.pen<-fit.variogram(mantillo.v2,vgm(meseta,"Pen",rango,pepita
,fit.method=2))
mantillo.vf.pen
plot(mantillo.v2,mantillo.vf.pen,main="Empirico y Pentaesferico",pch=7,c
ol="red",xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico periodico
mantillo.vf.per<-fit.variogram(mantillo.v2,vgm(meseta,"Per",rango,pepita
,fit.method=2))
mantillo.vf.per
plot(mantillo.v2,mantillo.vf.per,main="Empirico y Periodico",pch=7,col="
red",xlab="DISTANCIA",ylab="SEMIVARIANZA")
```

```
#modelo teorico wave
mantillo.vf.wav<-fit.variogram(mantillo.v2,vgm(meseta,"Wav",rango,pepita
,fit.method=2))
mantillo.vf.wav
plot(mantillo.v2,mantillo.vf.wav,main="Empirico y Wave",pch=7,col="red",
xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico stein
mantillo.vf.ste<-fit.variogram(mantillo.v2,vgm(meseta,"Ste",rango,pepita
,fit.method=2))
mantillo.vf.ste
plot(mantillo.v2,mantillo.vf.ste,main="Empirico y Stein",pch=7,col="red"
,xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico lineal
mantillo.vf.lin<-fit.variogram(mantillo.v2,vgm(meseta,"Lin",rango,pepita
,fit.method=2))
mantillo.vf.lin
plot(mantillo.v2,mantillo.vf.lin,main="Empirico y Lineal",pch=7,col="red
",xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico hole
mantillo.vf.hol<-fit.variogram(mantillo.v2,vgm(meseta,"Hol",rango,pepita
,fit.method=2))
mantillo.vf.hol
plot(mantillo.v2,mantillo.vf.hol,main="Empirico y Hole",pch=7,col="red",
xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico Exclass
mantillo.vf.exc<-fit.variogram(mantillo.v2,vgm(meseta,"Exc",rango,pepita
,fit.method=2))
mantillo.vf.exc
plot(mantillo.v2,mantillo.vf.exc,main="Empirico y Exclass",pch=7,col="re
d",xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico Logaritmico
mantillo.vf.log<-fit.variogram(mantillo.v2,vgm(167483,"Log",47,pepita,fi
t.method=2))
mantillo.vf.log
plot(mantillo.v2,mantillo.vf.log,main="Empirico y Logaritmico",pch=7,col
="red",xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico Measurement error
mantillo.vf.err<-fit.variogram(mantillo.v2,vgm(meseta,"Err",0,pepita,fit
.method=2))
plot(mantillo.v2,mantillo.vf.err,main="Empirico y Error",pch=7,col="red"
,xlab="DISTANCIA",ylab="SEMIVARIANZA")

#modelo teorico intercept
mantillo.vf.int<-fit.variogram(mantillo.v2,vgm(meseta,"Int",0,pepita,fit
.method=2))
mantillo.vf.int
plot(mantillo.v2,mantillo.vf.int,main="Empirico y Intercepto",pch=7,col=
"red",xlab="DISTANCIA",ylab="SEMIVARIANZA")
```

SELECCIÓN DEL MEJOR MODELO

Para seleccionar el mejor modelo, se optó por utilizar la función *"fitvariogram"* con todos los modelos, de acuerdo con lo obtenido, el mejor modelo fue el modelo gaussiano (Color Rojo Figura 9).

RSCRIPT	
<pre>> ##Selección del mejor modelo > #evaluar todos los variogramas > fit.variogram(mantillo.v2,vgm(psill = meseta,range = rango,nugget = pe pita,c("Exp","Sph", "Gau","Mat", "Cir", "Bes", "Pen", "Per", "Wav", "Ste ", "Lin", "Hol"),fit.kappa=TRUE,fit.method=1)) model psill range 1 Gau 167483.1 47.24786</pre>	




Figura 9. Modelos de semivariograma ajustados. Mejor modelo Gaussiano (Color rojo)

RSCRIPT

```

> ##Selección del mejor modelo
> #evaluar todos los variogramas
> fit.variogram(mantillo.v2,vgm(psill = meseta,range = rango,nugget = pe
pita,c("Exp","Sph", "Gau","Mat", "Cir", "Bes", "Pen", "Per", "Wav", "Ste
", "Lin", "Hol"),fit.kappa=TRUE,fit.method=1))
      model      psill      range
1      Gau 167483.1 47.24786

> #con mas modelos
> fit.variogram(mantillo.v2,vgm(psill = meseta,range = rango,nugget = pe
pita,c("Exp","Sph", "Gau","Mat", "Cir", "Bes", "Pen", "Per", "Wav", "Ste
", "Lin", "Hol","Log","Spl","Leg","Err"),fit.kappa=TRUE,fit.method=2))
      model      psill      range
1      Gau 167483.1 47.24786

> #Graficar el mejor ajuste
> xyplot(gamma~dist,mantillo.v2,xlab = "DISTANCIA",ylab = "SEMIVARIANZA"
,main="Ajuste a Modelos de semivariograma",panel = function(...){
+   panel.xyplot(...,pch=19,col = 1,bg="slateblue3",size=15)
+   #modelo esferico
+   ret=variogramLine(mantillo.vf.sph,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 1,lty=5)
+   #modelo Exponencial
+   ret=variogramLine(mantillo.vf.exp,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 3,lty=5)
+   #modelo Matern
+   ret=variogramLine(mantillo.vf.mat,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 4,lty=5)
+   #modelo Circular
+   ret=variogramLine(mantillo.vf.cir,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 5,lty=5)
+   #modelo Bessel
+   ret=variogramLine(mantillo.vf.bes,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 6,lty=5)
+   #modelo Pentaesferico
+   ret=variogramLine(mantillo.vf.pen,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 7,lty=5)
+   #modelo Wave
+   ret=variogramLine(mantillo.vf.wav,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 8,lty=5)
+   #modelo Stein
+   ret=variogramLine(mantillo.vf.ste,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 9,lty=5)
+   #modelo Lineal
+   ret=variogramLine(mantillo.vf.lin,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 11,lty=5)
+   #modelo Hole
+   ret=variogramLine(mantillo.vf.hol,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 12,lty=5)
+   #modelo Exc
+   ret=variogramLine(mantillo.vf.exc,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 13,lty=5)
+   #modelo Log
+   ret=variogramLine(mantillo.vf.log,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = 14,lty=5)

```

```
+ #modelo Int
+ ret=variogramLine(mantillo.vf.int,maxdist = max(mantillo.v2$dist))
+ llines(x=ret$dist,y=ret$gamma,col = 15,lty=5)
+ #modelo gaussiano
+ ret=variogramLine(mantillo.vf.gau,maxdist = max(mantillo.v2$dist))
+ llines(x=ret$dist,y=ret$gamma,col = "red",lty=1,lwd = 2)
+ })
```

LITERATURA CITADA

- Gallardo, A. (2006) 'Geostatística', *Revista Ecosistemas*, 15(3), pp. 48–58. doi: 10.7818/re.2014.15-3.00.
- Oliver, M. A. and Webster, R. (2015) *Basic Steps in Geostatistics: The Variogram and Kriging*. New York: Springer. doi: 10.1007/978-3-319-15865-5.