



COLEGIO DE POSTGRADUADOS

COLEGIO DE POSTGRADUADOS

INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS

CAMPUS MONTECILLO

PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

INTERPOLACIÓN KRIGGING

TAREA 11

Geoestadística aplicada en el estudio de los recursos forestales

Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Pérez Vázquez

INTRODUCCIÓN

El kriging es un término que ha sido acuñado para designar al “mejor estimador lineal insesgado” de un punto y al mejor promedio lineal móvil ponderado de un bloque. Este nombre apareció alrededor de 1960 para nombrar una técnica creada en Francia por Matheron a partir de los trabajos de D. G. Krige quien fue probablemente el primero que utilizó el término de correlación espacial y del mejor estimador lineal insesgado en el campo de la evaluación de yacimientos minerales (Oliver and Webster, 2015) .

La limitación a la clase de estimadores lineales es bastante natural ya que esto significa que solamente se requiere el conocimiento del momento de segundo orden de la función aleatoria (la covarianza o el variograma) y que en general en la práctica es posible inferir a partir de una realización de esta (Gallardo, 2006; Oliver and Webster, 2015).

DESCRIPCIÓN DE LA INFORMACIÓN

Se tiene interés en generar los semivariogramas para la variable de “contenidos de carbono (gramos de C)” en el mantillo del cuadrante central del Sitio del Monitoreo Intensivo de Carbono de Hidalgo (Figura 1). Para ello, se cuenta con los siguientes archivos shapefile (Cuadro 1):

Puntos de muestreo y área de estudio




Figura 1. Ubicación de los conglomerados dentro del SMIC-Hgo.

Cuadro 1. Descripción de archivos shapefile empleados.

NOMBRE	TIPO	DESCRIPCIÓN
polígono_3x3	Polígono	Incluye los límites del área de estudio. es un cuadrante con una superficie de 900 ha, de 3 km de largo de cada uno de sus lados. Se encuentra dividido en nueve subcuadrantes de 1 km x 1km.
polígono_Central	Polígono	Incluye únicamente los limites del cuadrante central del área de estudio.
puntos_densos	Puntos	Muestra la ubicación geográfica de los puntos de muestreo.

Con respecto al archivo "puntos_densos.shp" cuenta con los siguientes campos (Cuadro 2):

Cuadro 2. Descripción de los datos.

NOMBRE	TIPO	DESCRIPCIÓN	RANGO
FOLIO	Numérico	Número del conglomerado en el que se le colecta la información del mantillo.	1-40
SITIO	Numérico	Se refiere al sitio o parcela secundaria de medición	1-4
DENSIDAD_MU	Texto	Indica si pertenece o no al cuadrante central	Den
UTM_X	Numérico	Coordenadas UTM x	m
UTM_Y	Numérico	Coordenadas UTM y	m
ALTITUD	Numérico	Altitud	m
ANUALIDAD_	Numérico	Es la rodalización del bosque señalados por el año de corta	Años
EDAD_2013	Numérico	Edad del sitio, calculada por la anualidad	Años
MANTILLO_G	Numérico	Contenido de carbono en la capa orgánica del suelo.	g/m ²
AREA	Numérico	Área de la parcela	m ²




Figura 2. Gráfico de distribución del conjunto de datos en los ejes X y Y.

DESCRIPCIÓN DE LA VARIABLE

Los contenidos de C en mantillo están expresados en g/m^2 , de acuerdo con la Figura 2, se observa que los datos siguen una distribución uniforme, la cual es consistente con el diseño en conglomerados con el cual se recogieron los datos.




Figura 3. Gráfico QQ Plot para normalidad de los datos.




Figura 4. Dispersión de los datos, en el Eje X el número de muestras, en el eje Y el contenido de C.

Asimismo, los datos tienen una distribución normal, son estacionarios y están correlacionados positivamente, mostrando un comportamiento espacial agrupado




Figura 5. Matriz de vecindades tipo B y W.

AJUSTE DE SEMIVARIOGRAMA

Se obtuvo el semivariograma empírico de los datos muestreados, y se ajusto a varios modelos conocidos (Figura 6).




Figura 6. Variograma experimental omnidireccional

De acuerdo con el análisis estructural realizado, el mejor modelo es el gaussiano, en este modelo la dependencia espacial se desvanece solo en una distancia que tiende a infinito. El principal distintivo de este modelo es su forma parabólica cerca del origen. Su expresión matemática es:

$$\gamma(h) = C_0 + C_1 \left(1 - \exp\left(\frac{-h}{a^2}\right) \right)$$

Además, se utilizaron los semivariogramas de los modelos esférico (azul), circular (verde), pentaesférico (gris) y exponencial (púrpura) con fines de comparación para la interpolación kriging (Figura 7).




Figura 7. Modelos de semivariograma ajustados. Mejor modelo Gaussiano (Color rojo)

RSCRIPT

```
xyplot(gamma~dist,mantillo.v2,xlab = "DISTANCIA",ylab = "SEMIVARIANZA",m
ain="Ajuste a Modelos de semivariograma",panel = function(...){
+   panel.xyplot(...,pch=19,col = 1,bg="slateblue3",size=15)
+   #modelo esferico
+   ret=variogramLine(mantillo.vf.sph,maxdist = max(mantillo.v2$dist))
+   llines(x=ret$dist,y=ret$gamma,col = "Blue",lty=5)
+   #modelo Exponencial
```

```
+ ret=variogramLine(mantillo.vf.exp,maxdist = max(mantillo.v2$dist))
+ llines(x=ret$dist,y=ret$gamma,col = "Green",lty=5)
+ #modelo Circular
+ ret=variogramLine(mantillo.vf.cir,maxdist = max(mantillo.v2$dist))
+ llines(x=ret$dist,y=ret$gamma,col = "Gray",lty=5)
+ #modelo Pentaesferico
+ ret=variogramLine(mantillo.vf.pen,maxdist = max(mantillo.v2$dist))
+ llines(x=ret$dist,y=ret$gamma,col = "Purple",lty=5)
+ #modelo gaussiano
+ ret=variogramLine(mantillo.vf.gau,maxdist = max(mantillo.v2$dist))
+ llines(x=ret$dist,y=ret$gamma,col = "red",lty=1,lwd = 2)
+ })
```

MODELACIÓN KRIGING

Para generar el krigeado antes se necesita un conjunto de puntos sobre el cual realizar la interpolación. Para realizar las pruebas se ha empleado una malla regular de 50,000 celdas. Posteriormente se creo una paleta de colores para la representación de la interpolación.

RSCRIPT


```
> #Creacion de malla de puntos
> mantillo.reg<-spsample(poligono_Central,50000,type = "regular")
> mantillo.grid<-SpatialPixels(mantillo.reg) #define pixeles
> str(mantillo.grid)
Formal class 'SpatialPixels' [package "sp"] with 5 slots
..@ grid      :Formal class 'GridTopology' [package "sp"] with 3 slot
s
.. .. ..@ cellcentre.offset: Named num [1:2] 541800 2278955
.. .. ..- attr(*, "names")= chr [1:2] "x1" "x2"
.. .. ..@ cellsize        : Named num [1:2] 4.47 4.47
.. .. ..- attr(*, "names")= chr [1:2] "x1" "x2"
.. .. ..@ cells.dim       : Named int [1:2] 223 223
.. .. ..- attr(*, "names")= chr [1:2] "x1" "x2"
..@ grid.index : int [1:49729] 49507 49508 49509 49510 49511 49512 495
13 49514 49515 49516 ...
..@ coords     : num [1:49729, 1:2] 541800 541805 541809 541814 541818
...
.. ..- attr(*, "dimnames")=List of 2
.. .. ..$ : NULL
.. .. ..$ : chr [1:2] "x1" "x2"
..@ bbox    : num [1:2, 1:2] 541798 2278953 542795 2279950
.. ..- attr(*, "dimnames")=List of 2
.. .. ..$ : chr [1:2] "x1" "x2"
.. .. ..$ : chr [1:2] "min" "max"
..@ proj4string:Formal class 'CRS' [package "sp"] with 1 slot
.. .. ..@ projargs: chr NA
> #Preparar paleta de colores
> color.pal<-colorRampPalette(c("lightgoldenrodyellow","lightgoldenrod",
"lightgoldenrod1","lightgoldenrod2","lightgoldenrod3","lightgoldenrod4")
)
```







Se obtuvieron los siguientes resultados para la modelación (Cuadro 3), sin embargo, como se puede apreciar en todas las modelaciones existe un fuerte efecto del diseño por conglomerados.


En este sentido, el muestreo por conglomerados es una técnica que aprovecha la existencia de grupos o conglomerados en la población que representan correctamente el total de la población con relación a la característica que se desea medir. Dicho de otro modo, estos grupos contienen toda la variabilidad de la población. Si esto sucede, podemos seleccionar únicamente algunos de estos conglomerados para realizar el estudio.

Dado que en el muestreo por conglomerados las unidades de muestreo son grupos de unidades de estudio, algo que puede resultar muy beneficioso en relación con el coste del propio muestreo. A cambio, es habitual obtener una menor precisión al usar esta técnica, causada por falta de heterogeneidad dentro de los conglomerados.

Cuadro 3. Interpolación Kriging e Incertidumbre



INTERPOLACIÓN KRIGING ESFÉRICO	
INTERPOLACIÓN	INCERTIDUMBRE
Kriging Esferico 	Incertidumbre Esferico 
INTERPOLACIÓN KRIGING CIRCULAR	
INTERPOLACIÓN	INCERTIDUMBRE
Kriging Circular 	Incertidumbre Circular 
INTERPOLACIÓN KRIGING PENTAESFÉRICO	
INTERPOLACIÓN	INCERTIDUMBRE
Kriging Pentaesférico 	Incertidumbre Pentaesférico 
INTERPOLACIÓN KRIGING EXPONENCIAL	
INTERPOLACIÓN	INCERTIDUMBRE



Como se puede apreciar en el Cuadro 3, el modelo gaussiano es el que muestra una menor incertidumbre, sin embargo, existen zonas circundantes a los conglomerados que, por consecuencia de la ausencia de puntos de muestreo, no se alcanza a estimar en esas regiones.

Se utilizo por consiguiente la comparación con el método co-kriging para comparar si existe mejoría en las estimaciones

RSCRIPT

```
#Producir el krigeado #modelo gaussiano
ko.gau<-krige(Cmantillo~1,Carbono_mantillo,mantillo.grid,mantillo.vf.gau)
ko.gau
#mapear las predicciones kriging
spplot(ko.gau["var1.pred"],col.regions=color.pal,main="Kriging Gaussiano")
#mapear la varianza
spplot(ko.gau["var1.var"],col.regions=color.pal,main="Incentidumbre Gaussiano")

#modelo esferico
ko.sph<-krige(Cmantillo~1,Carbono_mantillo,mantillo.grid,mantillo.vf.sph)
ko.sph
#mapear las predicciones kriging
spplot(ko.sph["var1.pred"],col.regions=color.pal,main="Kriging Esferico")
#mapear la varianza
spplot(ko.sph["var1.var"],col.regions=color.pal,main="Incentidumbre Esferico")

#modelo Circular
ko.cir<-krige(Cmantillo~1,Carbono_mantillo,mantillo.grid,mantillo.vf.cir)
ko.cir
#mapear las predicciones kriging
```

```

spplot(ko.cir["var1.pred"],col.regions=color.pal,main="Kriging Circular")
#mapear la varianza
spplot(ko.cir["var1.var"],col.regions=color.pal,main="Incentidumbre Circular")

#modelo Pentaesferico
ko.pen<-krige(Cmantillo~1,Carbano_mantillo,mantillo.grid,mantillo.vf.pen)
ko.pen
#mapear las predicciones kriging
spplot(ko.pen["var1.pred"],col.regions=color.pal,main="Kriging Pentaesférico")
#mapear la varianza
spplot(ko.pen["var1.var"],col.regions=color.pal,main="Incentidumbre Pentaesférico")

#modelo Exponencial
ko.exp<-krige(Cmantillo~1,Carbano_mantillo,mantillo.grid,mantillo.vf.exp)
ko.exp
#mapear las predicciones kriging
spplot(ko.exp["var1.pred"],col.regions=color.pal,main="Kriging Exponencial")
#mapear la varianza
spplot(ko.exp["var1.var"],col.regions=color.pal,main="Incentidumbre Exponencial")

```

MODELACIÓN COKRIGING

La estimación conjunta de variables aleatorias regionalizadas, más comúnmente conocida como Cokriging (Kriging Conjunto), es el análogo natural del Kriging de una función aleatoria. Mientras que el Kriging utiliza la correlación espacial para determinar los coeficientes en el estimador lineal, el Cokriging utiliza la correlación espacial y la correlación entre funciones aleatorias al mismo tiempo.

Para ello se calculo el covariograma empírico y se ajustó a modelos teóricos conocidos, en este caso, se utilizaron los mismos: gaussiano, esférico, circular, pentaesférico y exponencial.

RSCRIPT

```

> ##Cokriging
> ck.g<-gstat(NULL,"mantillo",Cmantillo~1,Carbano_mantillo)
> ck.g
data:
mantillo : formula = Cmantillo`~`1 ; data dim = 92 x 12

> #ajuste del covariograma
> ck.v<-variogram(ck.g)

```

```

> plot(ck.v,main="Covariograma empirico",xlab="Semivarianza",ylab="Distancia")
> #ajuste covariograma empirico
> #nugget=0, meseta=168000, rango=80
> pepita2=0
> meseta2=168000
> rango2=80

#ajuste covariograma
#modelo gaussiano
ck.vf.gau<-fit.lmc(ck.v2,ck.g,vgm(meseta2,"Gau",rango2,pepita2))
ck.vf.gau

#Modelo esferico
ck.vf.sph<-fit.lmc(ck.v2,ck.g,vgm(meseta2,"Sph",rango2,pepita2))
ck.vf.sph

#Modelo Circular
ck.vf.cir<-fit.lmc(ck.v2,ck.g,vgm(meseta2,"Cir",rango2,pepita2))
ck.vf.cir


#Modelo Pentaesferico
ck.vf.pen<-fit.lmc(ck.v2,ck.g,vgm(meseta2,"Pen",rango2,pepita2))
ck.vf.pen


#Modelo Exponencial
ck.vf.exp<-fit.lmc(ck.v2,ck.g,vgm(meseta2,"Exp",rango2,pepita2))
ck.vf.exp

```


Como se puede observar, el uso de la modelación co-kriging mejora un poco el efecto de los conglomerados, y como se puede notar, el modelo exponencial es el que, en comparación con los restantes, muestra una menor incertidumbre y curvas mas suavizadas.

Cuadro 4. Interpolación Co- Kriging e Incertidumbre





INTERPOLACIÓN CO-KRIGING EXPONENCIAL



RSCRIPT

```

> #Predicciones cokriging

> #predice en funcion del modelo Gaussiano
> ck.gau<-predict(ck.vf.gau,mantillo.grid)
[using ordinary kriging]
> spplot(ck.gau["mantillo.pred"],col.regions=color.pal,
+       main="Predicción CoKriging Gaussiana")
> spplot(ck.gau["mantillo.var"],col.regions=color.pal,
+       main="Incertidumbre CoKriging Gaussiana")

> #predice en funcion del modelo Esferico
> ck.sph<-predict(ck.vf.sph,mantillo.grid)
[using ordinary kriging]
> spplot(ck.sph["mantillo.pred"],col.regions=color.pal,
+       main="Predicción CoKriging Esférico")
> spplot(ck.sph["mantillo.var"],col.regions=color.pal,
+       main="Incertidumbre CoKriging Esférico")

> #predice en funcion del modelo Circular
> ck.cir<-predict(ck.vf.cir,mantillo.grid)
[using ordinary kriging]
> spplot(ck.cir["mantillo.pred"],col.regions=color.pal,
+       main="Predicción CoKriging Circular")
> spplot(ck.cir["mantillo.var"],col.regions=color.pal,
+       main="Incertidumbre CoKriging Circular")

> #predice en funcion del modelo Pentaesferico
> ck.pen<-predict(ck.vf.pen,mantillo.grid)
[using ordinary kriging]
> spplot(ck.pen["mantillo.pred"],col.regions=color.pal,
+       main="Predicción CoKriging Pentaesférico")
> spplot(ck.pen["mantillo.var"],col.regions=color.pal,
+       main="Incertidumbre CoKriging Pentaesferico")
  
```

```
> #predice en funcion del modelo Exponencial
> ck.exp<-predict(ck.vf.exp,mantillo.grid)
[using ordinary kriging]
> spplot(ck.exp["mantillo.pred"],col.regions=color.pal,
+       main="Predicción CoKriging Exponencial")
> spplot(ck.exp["mantillo.var"],col.regions=color.pal,
+       main="Incertidumbre CoKriging Exponencial")
```

CONCLUSIONES

En conclusión, dentro de la interpolación kriging, el mejor ajuste es el modelo gaussiano, sin embargo, se observa mucho el efecto de conglomerados, por lo cual, la interpolación co-kriging muestra una mejoría en las estimaciones, siendo el modelo exponencial el modelo que presenta una menor incertidumbre.

Por lo cual, se recomienda seleccionar otro tipo de muestreo mas aleatorio y denso que pueda representar mejor la variabilidad de los contenidos de C.

LITERATURA CITADA

Gallardo, A. (2006) 'Geostatística', *Revista Ecosistemas*, 15(3), pp. 48–58. doi: 10.7818/re.2014.15-3.00.

Oliver, M. A. and Webster, R. (2015) *Basic Steps in Geostatistics: The Variogram and Kriging*. New York: Springer. doi: 10.1007/978-3-319-15865-5.