



COLEGIO DE POSTGRADUADOS

COLEGIO DE POSTGRADUADOS

INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS

CAMPUS MONTECILLO

PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

ANOVA/ANCOVA

TAREA 12

Geoestadística aplicada en el estudio de los recursos forestales

Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Pérez Vázquez

INTRODUCCIÓN

El análisis de covarianza (ANCOVA) es una estrategia para el análisis de datos de diseños experimentales en donde además de medir la variable respuesta, se miden una o más variables continuas (covariables). En otras palabras, es una técnica que utiliza el análisis de regresión y el análisis de varianza para manejar casos particulares, en los cuales se tiene una o más variables externas al experimento que no están afectas a los tratamientos e influyen en el valor observado (Y_{ij}). Es muy útil en la investigación, pues permite dar una mejor explicación del comportamiento de Y_{ij} y a la vez, permite reducir el error experimental.

El análisis de covarianza permite el estudio de estas variables externas, si deben o no ser consideradas en el modelo y en que forma se las controla. Dentro de los posibles usos de ANCOVA están: 1) Control de variables externas que implica una disminución del error que se traduce en una mayor precisión del análisis; 2) Ajuste de las medias de tratamientos de la variable dependiente (Y) por las diferentes variables independientes; y 3) Ayudar en la interpretación de los datos, específicamente en la naturaleza del efecto de los tratamientos.

Los supuestos requeridos para que sea valido el ANCOVA son: 1) independencia de los errores, 2) normalidad en las variables aleatorias, 3) varianzas homogéneas, 4) aditividad de los efectos involucrados en el modelo, 5) la variable X fija, 6) la variable X no esta influenciada por los tratamientos y 7) la variable Y esta relacionada con X de forma lineal.

El modelo estadístico esta dado por:

$$y = X_1\beta + X_2\theta + e$$

Donde:

- y es el vector de observaciones
- X_1 es la matriz de diseño para variables categóricas (e.g. tratamientos)
- X_2 es la matriz de incidencias para las variables continuas (e.g. temperatura, humedad relativa, etc)
- β, θ son coeficientes de regresión
- $e \sim N(0, \sigma_e^2 I)$

En todos los modelos, β , y θ son parámetros que representan el coeficiente de regresión. Se supone que β es distinto de cero, lo cual debe probarse, caso contrario en el modelo se elimina el termino afectado por β . Por lo cual, las pruebas para determinar si el coeficiente de regresión es significativo:

$$H_0: \beta = 0$$

$$H_1: \beta \neq 0$$

Las pruebas para determinar si hay efectos de tratamientos son:

$$H_0: \tau_i = 0$$

$$H_1: \tau_i \neq 0$$

Para $i = 1, 2, \dots, t$

DESCRIPCIÓN DE LA INFORMACIÓN UTILIZADA

Los datos fueron obtenidos del paquete "agridat", el cual contiene un conjunto de datos de publicaciones relacionadas con la agricultura, en este caso, se utilizaran los datos de la librería "lasrosas.corn". el cual incluye datos del monitoreo de rendimiento de maíz para un campo de maíz en Argentina con nitrógeno variable. El dataframe contiene 3,443 datos con observaciones con las siguientes variables (Cuadro 1):

Cuadro 1. Descripción de los datos.

<i>Variable</i>	<i>Descripción</i>	<i>Unidades</i>
<i>Year</i>	Periodo de colecta de información	Años
<i>Lat</i>	Latitud	Grados decimales
<i>Long</i>	Longitud	Grados decimales
<i>Yield</i>	Rendimiento de maíz	Quintales/ha (1 quintal=100 kg)
<i>Nitro</i>	Fertilizante de N	Kg/ha
<i>Topo</i>	Factor topográfico	
	Valor de brillo (proxy para bajo contenido de materia orgánica)	
<i>Nf</i>	Nitrógeno como factor	
<i>Rep</i>	Replicas	

Los datos tienen seis tratamientos de nitrógeno con 3 repeticiones realizado en franjas. Los datos fueron recolectados durante tres años (1999 a 2001). El factor topográfico es un factor con niveles W = pendiente oeste, HT = cima de la colina, E = inclinación este y LO = bajo este.

RSCRIPT

```
#Cargar libreria
library(agridat) #Contiene la información utilizada
library(ggplot2)
library(plotrix)
library(moments)
library(car)
library(fitdistrplus)
library(nlme)
library(multcomp)
library(epade)
library(lme4)
library(gstat)

> #Obtención de la información
> ?agridat
>
> datos<-lasrosas.corn
> datos
>datos<-lasrosas.corn
>datos
>attach(datos)
>?lasrosas.corn
>str(datos)
'data.frame': 3443 obs. of 9 variables:
 $ year : int 1999 1999 1999 1999 1999 1999 1999 1999 1999 1999 1999 ...
 $ lat : num -33.1 -33.1 -33.1 -33.1 -33.1 ...
 $ long : num -63.8 -63.8 -63.8 -63.8 -63.8 ...
 $ yield: num 72.1 73.8 77.2 76.3 75.5 ...
 $ nitro: num 132 132 132 132 132 ...
 $ topo : Factor w/ 4 levels "E","HT","LO",...: 4 4 4 4 4 4 4 4 4 4 ...
 $ bv : num 163 170 168 177 171 ...
 $ rep : Factor w/ 3 levels "R1","R2","R3": 1 1 1 1 1 1 1 1 1 1 ...
 $ nf : Factor w/ 6 levels "N0","N1","N2",...: 6 6 6 6 6 6 6 6 6 6 ..
.
```

ANÁLISIS EXPLORATORIO Y VERIFICACIÓN DE SUPUESTOS

Dado que se utilizará un ANOVA, se debe primero verificar que los supuestos coincidan. ANOVA se basa en tres supuestos

- o Independencia de los errores
- o Normalidad de la variable respuesta
- o Normalidad de los residuales
- o Igualdad de varianzas entre grupos
- o Todos los grupos tienen el mismo número de muestras

La variable de interés es el rendimiento de maíz y sus variables explicativas son topo, bv, nf y rep. La variable de interés tiene las siguientes características (Cuadro 2):

Cuadro 2. Descripción de la variable de interés.

n	Media	Mediana	Min	Max	Var	Sd	CV	Curtosis	Asimetría
3443	69.8283	66.63	12.66	117.9	393.4041	19.83442	3.5205	2.243296	0.38742

Se observa que la media es ligeramente menor que la mediana y se tiene una asimetría positiva de 0.3, por lo cual la cola de la distribución tiende hacia el lado derecho (Figura 1).




Figura 1. Histograma de frecuencias de la variable de interés.

RSCRIPT

```
> #Analisis exploratorio
> y=datos$yield #Definicion de la variable respuesta
> summary(y)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 12.66  54.54   66.63   69.83   84.69  117.90
> length(y)
[1] 3443
> mean(y)
[1] 69.82831
> median(y)
[1] 66.63
> min(y)
[1] 12.66
> max(y)
[1] 117.9
> var(y)
[1] 393.4041
> sd(y)
[1] 19.83442
> mean(y)/sd(y)
[1] 3.520563
> kurtosis(y)
[1] 2.243296
> skewness(y)
[1] 0.3874288
attr(,"method")
[1] "moment"
> #Graficos
> hist(y,breaks = 20,main = "Histograma de frecuencias",xlab = "Rendimi
ento de maíz",ylab = "Frecuencia")
```

La normalidad de la variable respuesta es obtenida a partir de los gráficos del histograma, Grafico QQ y prueba de Shapiro-Wilks (Figura 2).

RSCRIPT

```
> #Normalidad de la variable respuesta
> shapiro.test(y)

Shapiro-Wilk normality test

data:  y
W = 0.95439, p-value < 2.2e-16

> qqPlot(y,main = "Gráfico de QQ")
```




Figura 2. Gráfico QQ para prueba de normalidad.

La prueba de hipótesis fue:

H_0 : Distribución Normal

H_1 : Otra Distribución

Dado que el pvalue derivado de la prueba de Shapiro-Wilk fue menor que 0.05 se rechaza la hipótesis nula y en conjunto con la gráfica QQ se observa que los datos no tienen una distribución normal, por lo cual es conveniente realizar una transformación.

No obstante, de acuerdo Witte and Witte (2009), dado que se cuenta con más de 10 muestras por grupo y, de acuerdo con Webster y Oliver como la asimetría es menor a 0.5, se considera que la desviación de la normalidad no es lo suficientemente grande como para transformar los datos y se puede realizar la función de ANOVA.

RSCRIPT

```
> #numero de muestras por grupo
> tapply(y, INDEX = datos$nf, FUN = length)
 N0  N1  N2  N3  N4  N5
573 577 571 575 572 575
```

Para calcular la varianza del rendimiento para cada nivel de Nitrógeno se utilizó igualmente la función `tapply`:

RSCRIPT						
<pre>> #Igualdad de varianzas entre grupos > tapply(y, INDEX = datos\$nf, FUN = var) #calcula la varianza de y para cada nivel de N</pre>						
	N0	N1	N2	N3	N4	N5
	438.5448	368.8136	372.8698	369.6582	366.5705	405.5653

Se puede apreciar que existen variaciones entre los grupos, sin embargo, pueden considerarse no sustanciales al ser pequeñas. Como el conjunto de datos es muy grande, ANOVA es flexible y aun con las características anteriores de los datos se puede obtener resultados correctos hasta cierto punto.

Para comprobar la homocedasticidad de varianzas en la variable de interés, se realizó la prueba de Levene. La prueba de hipótesis a realizar fue:

H_0 : Existe homogeneidad de varianzas

H_1 : Lo contrario

Por lo cual, al tener un pvalue estadísticamente significativo, se acepta la hipótesis nula.

RSCRIPT				
<pre>> leveneTest(y~datos\$nf, data = datos) Levene's Test for Homogeneity of Variance (center = median) Df F value Pr(>F) group 5 1.4196 0.2137 3437</pre>				

ANALISIS DE VARIANZA (ANOVA)

Con la finalidad de conocer si los niveles de N tienen una influencia sobre el rendimiento, para ello, se obtiene la media y el error estándar para el rendimiento de cada grupo de nitrógeno. Las graficas de barras permiten conocer la variación entre tratamientos (Figura 3).

RSCRIPT

```

>ANOVA
>EFECTO DE N SOBRE EL RENDIMIENTO
>media.nf<-tapply(y,INDEX = datos$nf,FUN = mean)
> media.nf
      N0      N1      N2      N3      N4      N5
64.97290 68.61636 69.65033 70.33586 72.56302 72.83176
> errorestandar.nf<-tapply(y,INDEX = datos$nf,FUN = std.error)
> errorestandar.nf
      N0      N1      N2      N3      N4      N5
0.8748421 0.7994946 0.8080915 0.8018004 0.8005357 0.8398399
> barras<-barplot(media.nf,ylim=c(0,max(media.nf)+10), ylab = "Rendimien
to",xlab = "Tratamientos con N",main = "Grafico de Barras por tratamien
to de N")
> segments(barras,media.nf-(2*errorestandar.nf),barras,media.nf+(2*erro
restandar.nf),lwd = 1.5)
> arrows(barras,media.nf-(2*errorestandar.nf),barras,media.nf+(2*errore
standar.nf),lwd = 1.5,angle = 90,code = 3,length = 0.05)
  
```




Figura 3. Gráfico de barras para diferencias entre tratamientos con N.

Como se puede apreciar, la grafica anterior muestra que a medida que aumenta el nivel de nitrógeno, el rendimiento aumenta, sin embargo, pueden no ser significativamente diferentes.

o ANOVA de 1 vía

Para probar lo anterior se formulará la hipótesis de que el nitrógeno si afecta significativamente el rendimiento y que la media de cada subgrupo es significativamente diferente, para probarla, se realizara un ANOVA de 1 vía y la prueba de Tukey para probar la importancia de los niveles individuales de N.

$$H_0 = \text{el nitrógeno no afecta el rendimiento}$$

$$H_a = \text{lo contrario}$$

RSCRIPT

```
> #Anova 1 via
> modelo1<-aov(y~nf,data = datos)
> summary(modelo1)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
nf	5	23987	4797	12.4	6.08e-12	***
Residuals	3437	1330110	387			

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> TukeyHSD(modelo1,conf.level = 0.95)
  Tukey multiple comparisons of means
    95% family-wise confidence level

Fit: aov(formula = y ~ nf, data = datos)

$`nf`
```

	diff	lwr	upr	p adj
N1-N0	3.6434635	0.3353282	6.951599	0.0210713
N2-N0	4.6774357	1.3606516	7.994220	0.0008383
N3-N0	5.3629638	2.0519632	8.673964	0.0000588
N4-N0	7.5901274	4.2747959	10.905459	0.0000000
N5-N0	7.8588595	4.5478589	11.169860	0.0000000
N2-N1	1.0339723	-2.2770686	4.345013	0.9489077
N3-N1	1.7195004	-1.5857469	5.024748	0.6750283
N4-N1	3.9466640	0.6370782	7.256250	0.0089057
N5-N1	4.2153960	0.9101487	7.520643	0.0038074
N3-N2	0.6855281	-2.6283756	3.999432	0.9917341
N4-N2	2.9126917	-0.4055391	6.230923	0.1234409
N5-N2	3.1814238	-0.1324799	6.495327	0.0683500
N4-N3	2.2271636	-1.0852863	5.539614	0.3916824
N5-N3	2.4958957	-0.8122196	5.804011	0.2613027
N5-N4	0.2687320	-3.0437179	3.581182	0.9999099

```
> model.tables(modelo1,type = "effects")
Tables of effects
```

nf		N0	N1	N2	N3	N4	N5
		-4.855	-1.212	-0.178	0.5075	2.735	3.003
rep		573.000	577.000	571.000	575.0000	572.000	575.000

Como se puede observar con las salidas, los niveles de nitrógeno si afectan de manera significativa el rendimiento, lo cual prueba la primera hipótesis. Mientras que la prueba de Tukey indica que existen diferencias significativas entre los niveles de nitrógeno con el tratamiento control, así como los tratamientos entre N4 vs N1 y el tratamiento entre N5 y N1.

Adicionalmente, esto se comprobó mediante la función lm para ajustar el modelo con ANOVA de 1 VIA.

```

RSCRIPT

> modelo2<-lm(y~datos$nf)
> modelo2

Call:
lm(formula = y ~ datos$nf)

Coefficients:
(Intercept)  datos$nfN1  datos$nfN2  datos$nfN3  datos$nfN4
      64.973      3.643      4.677      5.363      7.590
datos$nfN5
      7.859

> summary(modelo2)

Call:
lm(formula = y ~ datos$nf)

Residuals:
    Min       1Q   Median       3Q      Max
-52.313 -15.344  -3.126  13.563  45.337

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   64.9729    0.8218   79.060  < 2e-16 ***
datos$nfN1     3.6435    1.1602    3.140  0.0017 **
datos$nfN2     4.6774    1.1632    4.021 5.92e-05 ***
datos$nfN3     5.3630    1.1612    4.618 4.01e-06 ***
datos$nfN4     7.5901    1.1627    6.528 7.65e-11 ***
datos$nfN5     7.8589    1.1612    6.768 1.53e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 19.67 on 3437 degrees of freedom
Multiple R-squared:  0.01771, Adjusted R-squared:  0.01629
F-statistic: 12.4 on 5 and 3437 DF, p-value: 6.075e-12

```

```

> anova(modelo2)
Analysis of Variance Table

Response: y
      Df Sum Sq Mean Sq F value    Pr(>F)
datos$nf      5   23987   4797.4   12.396 6.075e-12 ***
Residuals 3437 1330110    387.0
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> #Residuales
> residuales<-modelo2$residuals
> shapiro.test(residuales)

      Shapiro-Wilk normality test

data:  residuales
W = 0.94775, p-value < 2.2e-16

> #prueba no parametrica-no supone distribución normal
> kruskal.test(y~nf,data = datos) #pvalue significativo

      Kruskal-Wallis rank sum test

data:  y by nf
Kruskal-Wallis chi-squared = 81.217, df = 5, p-value = 4.669e-16

```

Como se obtuvo un R^2 tanto el común como el ajustado muy bajo se puede pensar que el modelo explica muy poco la variación de la variable de respuesta, lo que podría ser consecuencia del efecto de otras variables. No obstante, al obtener un valor pvalue muy bajo en ambos modelos, se puede concluir que la variabilidad incrementara a medida que los niveles de nitrógeno aumentan, por lo que se prueba la primera hipótesis sobre el efecto del N.

o ANOVA de 2 vías

El ANOVA de 2 vías se realizará considerando tanto el efecto del nitrógeno, como el efecto del factor topográfico. El factor topográfico es un factor con niveles W = pendiente oeste, HT = cima de la colina, E = inclinación este y LO = bajo este.

Por lo que se formulará la siguiente hipótesis:

$H_0 = \text{la topografía no afecta el rendimiento}$

$H_a = \text{lo contrario}$

RSCRIPT				
<pre> > #ANOVA DE DOS VÍAS > media.topo<-tapply(y,INDEX = datos\$topo,FUN = mean) > media.topo E HT LO W 78.66533 48.61271 84.94852 66.78118 > errorestandar.topo<-tapply(y,INDEX = datos\$topo,FUN = std.error) > errorestandar.topo E HT LO W 0.6776905 0.2995913 0.5206874 0.4499158 > barras2<-barplot(media.topo,ylim = c(0,max(media.topo)+10),ylab = "Re ndimiento",xlab = "Factores topograficos",main = "Grafico de Barras por Factor topografico",col = "White") > segments(barras2,media.topo-(2*errorestandar.topo),barras2,media.topo +(2*errorestandar.topo),lwd = 1.5) > arrows(barras2,media.topo-(2*errorestandar.topo),barras2,media.topo+(2*errorestandar.topo),lwd = 1.5,angle = 90,code = 3,length = 0.05) </pre>				

Grafico de Barras por Factor topografico




Figura 4. Gráfico de barras para diferencias entre factores topográficos.

Como puede observarse, el factor topográfico tiene un fuerte efecto sobre el rendimiento. En particular, las partes más altas muestran un rendimiento mucho menor, además se observa que posiblemente todas las diferencias son significativas. Para probar dichas hipótesis, se realizó un ANOVA de 2 vías.

RSCRIPT																																																																	
<pre>#ajuste del modelo > modelo3<-lm(y~datos\$nf+datos\$topo) > modelo3</pre>																																																																	
Call: lm(formula = y ~ datos\$nf + datos\$topo)																																																																	
Coefficients: <table> <tr> <td>(Intercept)</td> <td>datos\$nfN1</td> <td>datos\$nfN2</td> <td>datos\$nfN3</td> <td>datos\$nfN4</td> <td></td> </tr> <tr> <td>73.895</td> <td>3.843</td> <td>4.911</td> <td>5.110</td> <td>7.543</td> <td></td> </tr> <tr> <td>datos\$nfN5</td> <td>datos\$topoHT</td> <td>datos\$topoLO</td> <td>datos\$topoW</td> <td></td> <td></td> </tr> <tr> <td>7.416</td> <td>-30.037</td> <td>6.221</td> <td>-11.951</td> <td></td> <td></td> </tr> </table>						(Intercept)	datos\$nfN1	datos\$nfN2	datos\$nfN3	datos\$nfN4		73.895	3.843	4.911	5.110	7.543		datos\$nfN5	datos\$topoHT	datos\$topoLO	datos\$topoW			7.416	-30.037	6.221	-11.951																																						
(Intercept)	datos\$nfN1	datos\$nfN2	datos\$nfN3	datos\$nfN4																																																													
73.895	3.843	4.911	5.110	7.543																																																													
datos\$nfN5	datos\$topoHT	datos\$topoLO	datos\$topoW																																																														
7.416	-30.037	6.221	-11.951																																																														
<pre>> summary(modelo3)</pre>																																																																	
Call: lm(formula = y ~ datos\$nf + datos\$topo)																																																																	
Residuals: <table> <tr> <td>Min</td> <td>1Q</td> <td>Median</td> <td>3Q</td> <td>Max</td> <td></td> </tr> <tr> <td>-47.643</td> <td>-11.895</td> <td>-1.403</td> <td>10.432</td> <td>41.541</td> <td></td> </tr> </table>						Min	1Q	Median	3Q	Max		-47.643	-11.895	-1.403	10.432	41.541																																																	
Min	1Q	Median	3Q	Max																																																													
-47.643	-11.895	-1.403	10.432	41.541																																																													
Coefficients: <table> <tr> <th></th> <th>Estimate</th> <th>Std. Error</th> <th>t value</th> <th>Pr(> t)</th> <th></th> </tr> <tr> <td>(Intercept)</td> <td>73.8946</td> <td>0.7631</td> <td>96.833</td> <td>< 2e-16</td> <td>***</td> </tr> <tr> <td>datos\$nfN1</td> <td>3.8426</td> <td>0.8479</td> <td>4.532</td> <td>6.04e-06</td> <td>***</td> </tr> <tr> <td>datos\$nfN2</td> <td>4.9109</td> <td>0.8501</td> <td>5.777</td> <td>8.29e-09</td> <td>***</td> </tr> <tr> <td>datos\$nfN3</td> <td>5.1096</td> <td>0.8486</td> <td>6.021</td> <td>1.92e-09</td> <td>***</td> </tr> <tr> <td>datos\$nfN4</td> <td>7.5426</td> <td>0.8497</td> <td>8.877</td> <td>< 2e-16</td> <td>***</td> </tr> <tr> <td>datos\$nfN5</td> <td>7.4158</td> <td>0.8487</td> <td>8.738</td> <td>< 2e-16</td> <td>***</td> </tr> <tr> <td>datos\$topoHT</td> <td>-30.0365</td> <td>0.7392</td> <td>-40.634</td> <td>< 2e-16</td> <td>***</td> </tr> <tr> <td>datos\$topoLO</td> <td>6.2212</td> <td>0.7189</td> <td>8.653</td> <td>< 2e-16</td> <td>***</td> </tr> <tr> <td>datos\$topoW</td> <td>-11.9510</td> <td>0.6938</td> <td>-17.225</td> <td>< 2e-16</td> <td>***</td> </tr> </table>							Estimate	Std. Error	t value	Pr(> t)		(Intercept)	73.8946	0.7631	96.833	< 2e-16	***	datos\$nfN1	3.8426	0.8479	4.532	6.04e-06	***	datos\$nfN2	4.9109	0.8501	5.777	8.29e-09	***	datos\$nfN3	5.1096	0.8486	6.021	1.92e-09	***	datos\$nfN4	7.5426	0.8497	8.877	< 2e-16	***	datos\$nfN5	7.4158	0.8487	8.738	< 2e-16	***	datos\$topoHT	-30.0365	0.7392	-40.634	< 2e-16	***	datos\$topoLO	6.2212	0.7189	8.653	< 2e-16	***	datos\$topoW	-11.9510	0.6938	-17.225	< 2e-16	***
	Estimate	Std. Error	t value	Pr(> t)																																																													
(Intercept)	73.8946	0.7631	96.833	< 2e-16	***																																																												
datos\$nfN1	3.8426	0.8479	4.532	6.04e-06	***																																																												
datos\$nfN2	4.9109	0.8501	5.777	8.29e-09	***																																																												
datos\$nfN3	5.1096	0.8486	6.021	1.92e-09	***																																																												
datos\$nfN4	7.5426	0.8497	8.877	< 2e-16	***																																																												
datos\$nfN5	7.4158	0.8487	8.738	< 2e-16	***																																																												
datos\$topoHT	-30.0365	0.7392	-40.634	< 2e-16	***																																																												
datos\$topoLO	6.2212	0.7189	8.653	< 2e-16	***																																																												
datos\$topoW	-11.9510	0.6938	-17.225	< 2e-16	***																																																												
--- Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1																																																																	
Residual standard error: 14.38 on 3434 degrees of freedom Multiple R-squared: 0.4759, Adjusted R-squared: 0.4747 F-statistic: 389.7 on 8 and 3434 DF, p-value: < 2.2e-16																																																																	

Se observa que ambos factores tienen un efecto significativo en el rendimiento, mientras que solo el factor topográfico E (inclinación este) no tiene un efecto sobre el rendimiento, los restantes son estadísticamente significativos.

o ANOVA con interacciones

Para conocer la interacción entre ambos factores y reducir las fuentes principales de variación en el rendimiento. Las hipótesis formuladas son

$$H_0 = \text{no existe interaccion entre } N \text{ y topografia}$$

$$H_a = \text{lo contrario}$$

RSCRIPT

```
> #ANOVA CON INTERACCIONES
> as.factor(datos$topo)
Levels: E HT LO W
> media.interaccion<-tapply(y,INDEX = list(datos$nf,datos$topo),FUN = m
ean)
> media.interaccion
      E      HT      LO      W
N0 75.13902 41.50652 81.03027 62.08192
N1 78.12808 48.33630 83.06276 65.74627
N2 78.92632 48.79830 85.06879 66.70848
N3 78.99210 50.18398 85.23255 66.16531
N4 80.39213 52.12039 87.14400 70.10682
N5 80.55078 51.03138 87.94122 69.65933
> bar3d.ade(media.interaccion,col = "white",main = "Gráfica 3D Interacc
iones N-TOPO",xlab = "Factor topográfico",ylab = "Rendimiento",zlab = "
Niveles de N")
>with(datos,interaction.plot(topo,nf,yield))
```




Figura 5. Gráfico de barras 3D para interacciones entre factores topográficos y niveles de N.

Como se puede apreciar HT (cima de la colina) es el que muestra los rendimientos más bajos y LO (bajo este) el que mayor rendimiento presenta. Además, se muestra como a medida que incrementan los niveles de Nitrógeno el rendimiento aumenta con respecto al tratamiento testigo.

Sin embargo, se observa el efecto de interacción entre el N y el factor Topografía en HT, como se puede ver en el tratamiento testigo y una vez que se adiciona N el rendimiento aumenta significativamente. Sin embargo, para las combinaciones restantes, el efecto no parece significativo.




Figura 6. Interacciones entre topografía y niveles de N sobre rendimiento.

Como se puede apreciar, los factores topográficos con menores rendimientos son HT y W con menores rendimientos. No obstante, no se observa ningún efecto adicional dado por los diferentes niveles de N, con excepción del tratamiento testigo, dado que las líneas no se cruzan puede indicar una falta de interacción. Lo cual será probado con un ANOVA.

RSCRIPT

```
> #Ajuste del modelo
> modelo5<- lm(y~datos$nf*datos$topo)
> summary(modelo5)
```

Call:
lm(formula = y ~ datos\$nf * datos\$topo)

Residuals:

Min	1Q	Median	3Q	Max
-46.755	-11.898	-1.387	10.509	41.865

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	75.1390	1.2973	57.921	< 2e-16	***
datos\$nfN1	2.9891	1.8273	1.636	0.10197	
datos\$nfN2	3.7873	1.8273	2.073	0.03828	*
datos\$nfN3	3.8531	1.8500	2.083	0.03735	*
datos\$nfN4	5.2531	1.8384	2.857	0.00430	**
datos\$nfN5	5.4118	1.8621	2.906	0.00368	**
datos\$topoHT	-33.6325	1.8031	-18.653	< 2e-16	***
datos\$topoLO	5.8912	1.7609	3.346	0.00083	***
datos\$topoW	-13.0571	1.6989	-7.685	1.98e-14	***
datos\$nfN1:datos\$topoHT	3.8407	2.5312	1.517	0.12927	
datos\$nfN2:datos\$topoHT	3.5045	2.5378	1.381	0.16739	
datos\$nfN3:datos\$topoHT	4.8244	2.5706	1.877	0.06063	.
datos\$nfN4:datos\$topoHT	5.3608	2.5598	2.094	0.03631	*
datos\$nfN5:datos\$topoHT	4.1131	2.5920	1.587	0.11264	
datos\$nfN1:datos\$topoLO	-0.9566	2.4868	-0.385	0.70052	
datos\$nfN2:datos\$topoLO	0.2512	2.4970	0.101	0.91987	
datos\$nfN3:datos\$topoLO	0.3492	2.4886	0.140	0.88842	
datos\$nfN4:datos\$topoLO	0.8606	2.4950	0.345	0.73016	
datos\$nfN5:datos\$topoLO	1.4992	2.4924	0.602	0.54754	
datos\$nfN1:datos\$topoW	0.6753	2.4015	0.281	0.77858	
datos\$nfN2:datos\$topoW	0.8393	2.3985	0.350	0.72643	
datos\$nfN3:datos\$topoW	0.2303	2.4101	0.096	0.92387	
datos\$nfN4:datos\$topoW	2.7718	2.3998	1.155	0.24817	
datos\$nfN5:datos\$topoW	2.1657	2.4126	0.898	0.36945	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 14.39 on 3419 degrees of freedom

Multiple R-squared: 0.4773, Adjusted R-squared: 0.4738

F-statistic: 135.8 on 23 and 3419 DF, p-value: < 2.2e-16

Con las salidas anteriores se observa que, en efecto, no existen interacciones significativas entre el factor topografía y los niveles de N. Por otro lado, se realizó la prueba no paramétrica, al saber que los tanto los errores como la variable de interés no tienen una distribución normal.

RSCRIPT

```
> #modelo robusto no parametrico
> modelo6<-raov(y~datos$nf*datos$topo,data = datos)
> modelo6
```

Robust ANOVA Table

	DF	RD	Mean RD	F	p-value
datos\$nf	5	764.56053	152.91211	21.96030	0.00000
datos\$topo	3	17418.76333	5806.25444	833.85875	0.00000
datos\$nf:datos\$topo	15	59.15213	3.94348	0.56634	0.90215

Dado que el pvalue del factor topográfico vs los niveles de nitrógeno tienen un pvalue estadísticamente mayor, se acepta la hipótesis nula y se concluye al igual que con los modelos anteriores que no existe interacción entre ambas variables explicatorias

ANCOVA

El Análisis de covarianza (ANCOVA) se ajusta a un nuevo modelo donde los efectos de los tratamientos (o variables factoriales) se corrigen por el efecto de las covariables continuas, para lo cual también podemos ver los efectos sobre el rendimiento.

RSCRIPT	
<pre> > #ANCOVA > modelo7<- lm(y~datos\$nf+datos\$bv,data = datos) > summary(modelo7) Call: lm(formula = y ~ datos\$nf + datos\$bv, data = datos) Residuals: Min 1Q Median 3Q Max -78.345 -10.847 -3.314 10.739 56.835 Coefficients: Estimate Std. Error t value Pr(> t) (Intercept) 268.02772 4.99630 53.645 < 2e-16 *** datos\$nfN1 3.52312 0.95075 3.706 0.000214 *** datos\$nfN2 5.07074 0.95328 5.319 1.11e-07 *** datos\$nfN3 5.60318 0.95159 5.888 4.28e-09 *** datos\$nfN4 7.34642 0.95284 7.710 1.64e-14 *** datos\$nfN5 8.00305 0.95158 8.410 < 2e-16 *** datos\$bv -1.16458 0.02839 -41.015 < 2e-16 *** --- Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1 Residual standard error: 16.12 on 3436 degrees of freedom Multiple R-squared: 0.3406, Adjusted R-squared: 0.3394 F-statistic: 295.8 on 6 and 3436 DF, p-value: < 2.2e-16 par(mfrow=c(2,2)) plot(modelo7) </pre>	

Como se puede comparar con el modelo anterior cuando se tenía un R^2 muy pequeño, mientras que con el modelo de ANCOVA y al agregar la variable continua bv se aumenta el nivel explicativo del modelo, explicando el 34% de la variación en el rendimiento. Además, se observa que el tratamiento con N3 es más significativo.




Figura 7. Características del ajuste del modelo ANCOVA.

Como se puede observar en el grafico de los residuales vs ajustados, dado que se parte de la suposición de que los errores tienen media igual a cero y varianza constante, los residuos deben verse igualmente repartidos alrededor de cero.

Sin embargo, se observa que en valores bajos de rendimiento si hay dispersión alrededor de cero, pero a medida que aumenta se viola dichos supuestos. Para el segundo grafico se observan algunos valores que no encajan en la distribución de normalidad. La tercer grafica

muestra que los datos no tienen homogeneidad de varianzas lo que viola la suposición. El ultimo grafico muestra la influencia de algunos datos sobre el modelo.

CONCLUSIONES

Para ciertos conjuntos de datos, el supuesto de normalidad no se puede cumplir, por lo cual se deben considerar otras opciones como la transformación de los datos, el uso del Modelo Lineal Generalizado o el uso de pruebas no paramétricas que no suponen una distribución normal.

No obstante, si se tienen tamaños de muestra lo suficientemente grandes el análisis de varianza es más flexible, sin embargo, la independencia de los datos debe corregirse, dado que al ser datos ambientales pueden presentar correlación espacial.

LITERATURA CITADA

Webster, R. and Oliver, M.A., 2007. Geostatistics for environmental scientists. John Wiley & Sons.

Witte, R. and Witte, J. 2009. Statistics. 9th ed. Wiley.