



COLEGIO DE POSTGRADUADOS

COLEGIO DE POSTGRADUADOS

INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS

CAMPUS MONTECILLO

PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

REGRESIÓN ESPACIAL

TAREA 13

Geoestadística aplicada en el estudio de los recursos forestales

Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Pérez Vázquez

INTRODUCCIÓN

El análisis de regresión permite modelar, examinar y explorar las relaciones espaciales, puede ayudar a explicar los factores detrás de los patrones espaciales observados y conocer las relaciones entre las distintas entidades; es decir, los métodos de regresión espacial permiten verificar las relaciones y medir cuán solidas son. A diferencia de la estadística clásica, en la regresión espacial se aprovecha la dependencia de la variable de respuesta para mejorar dicha predicción.

El método de mínimos cuadrados ordinarios (OLS, por sus siglas en ingles) es la más conocida de todas las técnicas de regresión. También es el punto de inicio adecuado para todos los análisis de regresión espacial. Proporciona un modelo global de la variable, creando una ecuación de regresión simple para representar dicho proceso.

Asimismo, el análisis de regresión espacial se puede utilizar para una gran variedad de aplicaciones:

- Para modelar algún fenómeno y sus variables explicatorias que permita la toma de decisiones
- Medir la extensión que cambia en una o más variables que en conjunto afectan los cambios en la otra.
- Crear modelos de predicción que sean consistentes y precisos.
- También puede utilizar el análisis de regresión para explorar las hipótesis.

DESCRIPCIÓN DE LA INFORMACIÓN

Se cuenta el archivo shapefile denominado "Zona_Centro.shp" que contiene la información poblacional de la zona urbana del Centro de México (Figura 1). El archivo contiene algunos municipios del Estado de México y Morelos, así como los polígonos de las delegaciones de la Ciudad de México. Para poder analizar la distribución del empleo y del capital humano en los municipios de la zona centro del país, primero se definen las variables "Población Ocupada (POCUPADA)" y "Capital Humano - Años de Escolaridad promedio en la Población igual o mayor de 15 años (ESCOLA_15)".

Área de estudio



Figura 1. Zona urbana del centro de México.

RSCRIPT

```
> #Fijar directorio
> setwd("C:/Users/zaira/Documents/00 Maestria Ciencias Forestales/00 Cuatrimestre verano
2018/Geoestadística/Tarea/Regresión espacial")
#Cargar librerías
library(maptools)
library(spdep)
library(RColorBrewer)
library(classInt)
library(moments)

> #Leer información
> empleo <- readShapePoly("Zona_Centro.shp")
> names(empleo)
```

RSCRIPT

```

[1] "ID"          "CVEGEO"      "NOM_ENT"     "NOM_MUN"     "POBTOT"      "POBMAS"
[7] "POBFEM"      "PROM_HNV"    "GRAPROES_M"  "GRAPROES_F"  "PEA"         "PEA_M"
[13] "PEA_F"       "PE_INAC"     "PE_INAC_M"   "PE_INAC_F"   "POCUPADA"     "POCUPADA_M"
[19] "POCUPADA_F"  "PDESOCUP"    "PDESOCUP_M"  "PDESOCUP_F"  "PSINDER"      "PDER_SS"
[25] "PDER_IMSS"   "PDER_ISTE"   "PDER_ISTEE"  "PDER_SEGP"   "GRAPROES"     "N_CLASE_CR"
[31] "ESCOLA_15"   "POB_15"      "CORE"        "BOHEMIOS"    "NO_CREATIV"   "CORE_P"
[37] "NO_CREAT_P"  "BOHE_P"      "OID"

> summary(empleo)

> #definir variables
> pocupada<-empleo$POCUPADA
> pocupada
 [1] 177289 271935 81494 497600 166614 752268 102985 51733 327230 144562
[11] 280788 173864 191122 259228 175245 187508 17388 48889 14594 4632
[21] 48703 4388 6950 8140 17437 10208 20677 4245 204864 33037
[31] 9650 8854 3174 17112 13388 112881 12479 4543 13586 56539
[41] 114183 9592 3757 10323 68668 9202 232026 9709 661748 3141
[51] 35504 13696 98776 3593 180389 12667 1949 49107 10034 10286
[61] 30430 6847 22012 21766 4346 8940 49546 9044 19094 87780
[71] 4564 8368 341617 457542 13327 140650 3322 23659 10672 9909
[81] 12511 1158 26836 9784 1706 100134 4748 4554 8371 36018
[91] 9474 28009 1864 2883 4270 6062 141562 22925 4162 12614
[101] 18921 9658 31042 32802 3818 28039 24330 18783 10403 6205
[111] 34316 11720 4434 1860 89973 12627 26569 5232 17012 269323
[121] 9435 322928 4918 35378 207439 23465 14345 14025 24523 29153
[131] 16907 1262 4047 58912 4824 57488 209253 138547 5538 23327
[141] 3979 6028 6692 10782 28072 3129 72840 155941 33259 6465
[151] 5562 84778 22523 5083 3417 8441 5744 23940 43834 8867
[161] 17574 2843 6584 2552 17165 11562 6413 4007 26193 39092
[171] 17538 13662 2948 5195

> capitalhumano<-empleo$ESCOLA_15
> capitalhumano
 [1] 9.61 10.77 11.01 9.12 9.38 7.87 9.24 7.00 9.68 7.44 9.22 8.63
[13] 12.68 11.12 10.78 8.88 4.83 6.63 4.83 4.37 6.16 6.86 4.74 4.53
[25] 7.11 6.20 6.26 5.72 8.38 6.24 5.56 5.42 6.41 5.95 7.45 8.55
[37] 4.30 7.19 6.44 7.87 6.06 4.98 6.96 6.80 7.15 6.96 6.09 4.06
[49] 7.48 5.09 6.09 5.40 9.29 5.89 7.06 5.01 3.76 5.41 5.73 8.02
[61] 5.45 5.87 4.90 6.07 5.50 5.59 6.19 4.88 7.87 9.41 6.85 4.87
[73] 8.95 7.50 5.38 6.62 5.71 6.83 4.86 4.87 5.87 4.53 6.15 5.96
[85] 11.18 6.64 6.15 6.26 5.72 3.93 6.86 6.93 4.69 5.16 5.44 3.58
[97] 7.22 4.30 6.33 5.49 4.19 4.92 4.63 5.93 7.48 6.12 6.78 6.71
[109] 7.01 5.90 7.00 5.98 4.66 6.45 6.85 6.52 6.17 5.17 7.40 8.69
[121] 4.28 7.91 5.22 6.51 7.57 5.36 3.65 4.92 4.32 4.13 6.31 5.06
[133] 3.99 5.31 3.88 6.43 8.50 5.84 3.59 3.13 6.66 5.27 6.81 5.32
[145] 6.54 5.21 7.26 9.01 6.80 6.45 6.00 7.69 7.33 5.98 6.56 5.15
[157] 5.44 5.73 6.25 5.27 6.62 6.27 5.10 6.16 5.97 5.59 6.85 5.18
[169] 6.48 6.47 5.21 7.17 6.28 6.12

```

ANÁLISIS EXPLORATORIO

Para conocer el comportamiento de las variables se realizó un análisis exploratorio de cada una de las variables y se determinó la normalidad de las variables. Obteniendo los siguientes resultados (Cuadro 1):

Cuadro 1. Descripción de las variables.

Variable	n	media	median	min	max	sd	cv	curtosis	asim	cor
Población ocupada	174	59,567.4	14,470	1,158	752,268	110,889	0.537181	17.4052	3.4489	0.5263
Capital humano	174	6.3732	6.165	3.13	12.68	1.64145	3.8826	4.4372	0.9909	0.5263

Como se muestra en el Cuadro 1, se observa que la media de la población ocupada es de 59,558 y la mediana es de 14,470; lo cual indica que la función de distribución se sesga hacia la izquierda. Mientras que, para la variable de capital humano, la media y la mediana son muy similares, mostrando una ligera tendencia hacia la izquierda (Figura 2).




Figura 2. Histograma de Frecuencia de ambas variables.

RSCRIPT

```
> #Estadística descriptiva de variables
> #personas empleadas
> length(pocupada)
[1] 174
> summary(pocupada)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1158   6426   14470   59568   49053   752268
> mean(pocupada)
[1] 59567.46
> median(pocupada)
[1] 14469.5
> range(pocupada)
[1] 1158 752268
> max(pocupada)
[1] 752268
> min(pocupada)
[1] 1158
> var(pocupada)
[1] 12296364084
> sd(pocupada)
[1] 110889
> mean(pocupada)/sd(pocupada)
[1] 0.5371811
> skewness(pocupada)
[1] 3.448933
> kurtosis(pocupada)
[1] 17.40527

> #años de escolaridad
> summary(capitalhumano)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  3.130   5.270   6.165   6.373   7.008   12.680
> mean(capitalhumano)
[1] 6.373276
> median(capitalhumano)
[1] 6.165
> range(capitalhumano)
[1] 3.13 12.68
> min(capitalhumano)
[1] 3.13
> max(capitalhumano)
[1] 12.68
> var(capitalhumano)
[1] 2.694389
> sd(capitalhumano)
[1] 1.641459
> mean(capitalhumano)/sd(capitalhumano)
[1] 3.882689
> kurtosis(capitalhumano)
[1] 4.437256
> skewness(capitalhumano)
[1] 0.9909921

> #Histograma
> par(mfrow=c(1,2))
```

RSCRIPT

```

> hist(pocupada,main = "Poblacion ocupada",ylab = "Frecuencia",xlab = "
Población ocupada")
> hist(capitalhumano,xlab="Años de escolaridad",ylab="Frecuencia",main=
"Años de escolaridad")

> #Prueba de normalidad de datos originales
> qqPlot(pocupada,ylab="Poblacion ocupada",main = "QQ Población ocupada
")
[1] 6 49
> qqPlot(capitalhumano,ylab="Años de escolaridad poblacion > a 15",main
="QQ Capital Humano")
[1] 13 85

```

Para probar si existe normalidad se elaboró el grafico QQ y se comprobó con la prueba de Shapiro Wilks. La hipótesis por probar fue

H_0 : los datos se distribuyen Normal

H_a : lo contrario




Figura 3. Gráficos QQ para prueba de normalidad en ambas variables.

Como se puede observar, la variable de población ocupada no tiene una distribución normal, mientras que la variable de "capital humano" muestra una ligera tendencia a la distribución normal, comparada con la otra variable. De acuerdo con el pvalue obtenido, al ser mucho menor a 0.05, se concluye que los datos no siguen una distribución normal en ninguna variable.

RSCRIPT
<pre>> shapiro.test(pocupada) Shapiro-Wilk normality test data: pocupada W = 0.54696, p-value < 2.2e-16 > shapiro.test(capitalhumano) Shapiro-Wilk normality test data: capitalhumano W = 0.94336, p-value = 2.115e-06</pre>

Dado que los datos no tienen una distribución normal, se realizará una transformación mediante la conversión a logaritmo de ambas variables y se obtendrán igualmente sus valores descriptivos (Cuadro 2).

Cuadro 2. Descripción de las variables transformadas.

Variable	n	media	median	min	max	sd	cv	curtosis	asim	cor
Población ocupada	174	9.8816	9.5797	7.0544	13.5308	1.4489	6.8199	2.4665	0.4996	0.5640
Capital humano	174	1.8211	1.8188	1.1410	2.5400	0.2479	7.3459	3.2524	0.1556	0.5640

Como se puede apreciar, en este caso para la variable de "población ocupada" la mediana ya no se encuentra tan alejada de la media, mientras que para la variable "capital humano" la media y la mediana son similares, lo cual indica que la transformación puede sugerir una distribución normal, la cual también se ve reflejada en sus histogramas correspondientes (Figura 4).




Figura 4. Histograma de frecuencias para cada variable y su correspondiente transformación.

RSCRIPT							
> #transformación							
> log_pocupada<- log(pocupada)							
> log_pocupada							
[1]	12.085536	12.513318	11.308285	13.117552	12.023435	13.530848	11.542339
[8]	10.853851	12.698419	11.881464	12.545355	12.066029	12.160667	12.465463
[15]	12.073940	12.141577	9.763536	10.797308	9.588366	8.440744	10.793496
[22]	8.386629	8.846497	9.004545	9.766350	9.230927	9.936777	8.353497
[29]	12.230102	10.405383	9.174713	9.088625	8.062748	9.747535	9.502114
[36]	11.634089	9.431803	8.421343	9.516795	10.942686	11.645558	9.168685
[43]	8.231376	9.242130	11.137039	9.127176	12.354605	9.180809	13.402640
[50]	8.052296	10.477401	9.524859	11.500610	8.186743	12.102871	9.446755
[57]	7.575072	10.801757	9.213735	9.238539	10.323184	8.831566	9.999343
[64]	9.988104	8.377011	9.098291	10.810657	9.109857	9.857129	11.382589
[71]	8.425955	9.032170	12.741446	13.033624	9.497547	11.854030	8.108322
[78]	10.071499	9.275379	9.201199	9.434364	7.054450	10.197500	9.188504
[85]	7.441907	11.514265	8.465479	8.423761	9.032529	10.491774	9.156306
[92]	10.240281	7.530480	7.966587	8.359369	8.709795	11.860493	10.039983
[99]	8.333751	9.442563	9.848028	9.175542	10.343096	10.398245	8.247482
[106]	10.241352	10.099465	9.840707	9.249850	8.733111	10.443367	9.369052
[113]	8.397057	7.528332	11.407265	9.443593	10.187500	8.562549	9.741674
[120]	12.503667	9.152181	12.685185	8.500657	10.473845	12.242593	10.063265
[127]	9.571157	9.548597	10.107367	10.280313	9.735483	7.140453	8.305731
[134]	10.983800	8.481359	10.959332	12.251299	11.838965	8.619389	10.057367
[141]	8.288786	8.704171	8.808668	9.285633	10.242528	8.048469	11.196021

RSCRIPT

```
[148] 11.957233 10.412081 8.774158 8.623713 11.347791 10.022292 8.533657
[155] 8.136518 9.040856 8.655911 10.083306 10.688165 9.090092 9.774176
[162] 7.952615 8.792398 7.844633 9.750628 9.355479 8.766082 8.295798
[169] 10.173247 10.573673 9.772125 9.522374 7.988882 8.555452

> log_capitalhumano<-log(capitalhumano)
> log_capitalhumano
 [1] 2.262804 2.376764 2.398804 2.210470 2.238580 2.063058 2.223542 1.945910
 [9] 2.270062 2.006871 2.221375 2.155245 2.540026 2.408745 2.377693 2.183802
[17] 1.574846 1.891605 1.574846 1.474763 1.818077 1.925707 1.556037 1.510722
[25] 1.961502 1.824549 1.834180 1.743969 2.125848 1.830980 1.715598 1.690096
[33] 1.857859 1.783391 2.008214 2.145931 1.458615 1.972691 1.862529 2.063058
[41] 1.801710 1.605430 1.940179 1.916923 1.967112 1.940179 1.806648 1.401183
[49] 2.012233 1.627278 1.806648 1.686399 2.228939 1.773256 1.954445 1.611436
[57] 1.324419 1.688249 1.745716 2.081938 1.695616 1.769855 1.589235 1.803359
[65] 1.704748 1.720979 1.822935 1.585145 2.063058 2.241773 1.924249 1.583094
[73] 2.191654 2.014903 1.682688 1.890095 1.742219 1.921325 1.581038 1.583094
[81] 1.769855 1.510722 1.816452 1.785070 2.414126 1.893112 1.816452 1.834180
[89] 1.743969 1.368639 1.925707 1.935860 1.545433 1.640937 1.693779 1.275363
[97] 1.976855 1.458615 1.845300 1.702928 1.432701 1.593309 1.532557 1.780024
[105] 2.012233 1.811562 1.913977 1.903599 1.947338 1.774952 1.945910 1.788421
[113] 1.539015 1.864080 1.924249 1.874874 1.819699 1.642873 2.001480 2.162173
[121] 1.453953 2.068128 1.652497 1.873339 2.024193 1.678964 1.294727 1.593309
[129] 1.463255 1.418277 1.842136 1.621366 1.383791 1.669592 1.355835 1.860975
[137] 2.140066 1.764731 1.278152 1.141033 1.896119 1.662030 1.918392 1.671473
[145] 1.877937 1.650580 1.982380 2.198335 1.916923 1.864080 1.791759 2.039921
[153] 1.991976 1.788421 1.880991 1.638997 1.693779 1.745716 1.832581 1.662030
[161] 1.890095 1.835776 1.629241 1.818077 1.786747 1.720979 1.924249 1.644805
[169] 1.868721 1.867176 1.650580 1.969906 1.837370 1.811562

> #estadística descriptiva de la variable transformada
> #poblacion ocupada
> summary(log_pocupada)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  7.054   8.768   9.580   9.882  10.801  13.531
> mean(log_pocupada)
[1] 9.881639
> median(log_pocupada)
[1] 9.579761
> range(log_pocupada)
[1] 7.05445 13.53085
> var(log_pocupada)
[1] 2.099392
> sd(log_pocupada)
[1] 1.448928
> mean(log_pocupada)/sd(log_pocupada)
[1] 6.819966
> skewness(log_pocupada)
[1] 0.4996346
> kurtosis(log_pocupada)
[1] 2.466534
```

RSCRIPT

```

> #estadística descriptiva de la variable transformada
> #poblacion ocupada
> summary(log_pocupada)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  7.054   8.768   9.580   9.882  10.801  13.531
> mean(log_pocupada)
[1] 9.881639
> median(log_pocupada)
[1] 9.579761
> range(log_pocupada)
[1] 7.05445 13.53085
> var(log_pocupada)
[1] 2.099392
> sd(log_pocupada)
[1] 1.448928
> mean(log_pocupada)/sd(log_pocupada)
[1] 6.819966
> skewness(log_pocupada)
[1] 0.4996346
> kurtosis(log_pocupada)
[1] 2.466534
> cor(log_personasempleadas, log_añosescolaridad_p15)
[1] 0.5640955

> #años de escolaridad
> summary(log_capitalhumano)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.141   1.662   1.819   1.821   1.947   2.540
> mean(log_capitalhumano)
[1] 1.821133
> median(log_capitalhumano)
[1] 1.818888
> range(log_capitalhumano)
[1] 1.141033 2.540026
> var(log_capitalhumano)
[1] 0.06145893
> sd(log_capitalhumano)
[1] 0.2479091
> mean(log_capitalhumano)/sd(log_capitalhumano)
[1] 7.345971
> skewness(log_capitalhumano)
[1] 0.1556513
> kurtosis(log_capitalhumano)
[1] 3.252493

```

Para probar si existe normalidad se elaboró el gráfico QQ y se comprobó con la prueba de Shapiro Wilk. La hipótesis por probar fue

H_0 : los datos se distribuyen Normal

H_a : lo contrario




Figura 5. Gráficos QQ para prueba de normalidad en ambas variables y su correspondiente transformación.

Como se puede observar, la variable de población ocupada transformada se alinea mucho más a la línea de 45°, lo que indica que puede tener una distribución normal o muy parecida a una distribución normal, mientras que la variable de “capital humano” muestra un mejor ajuste a la distribución normal. De acuerdo con el pvalue obtenido por la prueba de Shapiro Wilk, la variable transformada de población ocupada aun no alcanza a ser normal, sin embargo, el pvalue es mucho mas alto que en la variable original. Por otra parte, la variable de capital humano ya tiene una distribución normal con un pvalue estadísticamente significativo para aceptar la hipótesis nula.

RSCRIPT

```
> #Comparacion original vs transformada
> par(mfrow=c(2,2))

> #Histogramas de frecuencia
```

RSCRIPT

```
> #poblacion ocupada
> hist(pocupada,main = "Personas empleadas",ylab = "Frecuencia",xlab =
"Personas empleadas")
> hist(log_pocupada,xlab = "Personas empleadas - Log",ylab = "Frecuenci
a",main = "Personas empleadas - Log")
> #años de escolaridad
> hist(capitalhumano,xlab="Años de escolaridad",ylab="Frecuencia",main=
"Años de escolaridad")
> hist(log_capitalhumano,main="Años de escolaridad - Log",xlab="Años de
escolaridad - Log",ylab="Frecuencia")

> #Histograma de densidad
> #poblacion ocupada
> hist(pocupada,main = "Personas empleadas",ylab = "Densidad",xlab = "P
ersonas empleadas",freq = FALSE)
> hist(log_pocupada,xlab = "Personas empleadas - Log",ylab = "Densidad"
,main = "Personas empleadas - Log",freq = FALSE)
> #años de escolaridad
> hist(capitalhumano,xlab="Años de escolaridad",ylab="Densidad",main="A
ños de escolaridad",freq = FALSE)
> hist(log_capitalhumano,main="Años de escolaridad - Log",xlab="Años de
escolaridad - Log",ylab="Densidad",freq = FALSE)

> #QQ Plot
> #personas empleadas
> qqPlot(pocupada,ylab="Poblacion ocupada",main = "Población ocupada")
[1] 6 49
> qqPlot(log_pocupada,main = "Poblacion ocupada (Log)",ylab = "Num de p
ersonas (Logaritmo)")
[1] 6 49
> #Años de escolaridad
> qqPlot(capitalhumano,ylab="Años de escolaridad poblacion > a 15")
[1] 13 85
> qqPlot(log_capitalhumano,main="Años de escolaridad (Log)",ylab="Años
(Logaritmo)")
[1] 13 140

> #correlacion
> cor(pocupada,capitalhumano)
[1] 0.5263203
> cor(log_pocupada, log_capitalhumano)
[1] 0.5640955

> #prueba de normalidad de datos transformados
> qqPlot(log_pocupada,main = "Poblacion ocupada (Transformada)",ylab =
"Num de personas (Logaritmo)")
[1] 6 49
> shapiro.test(log_pocupada)

      Shapiro-Wilk normality test

data:  log_pocupada
W = 0.96285, p-value = 0.0001383

> qqPlot(log_capitalhumano,main="Años de escolaridad (Población > 15año
s) (Transformada)",ylab="Años (Logaritmo)")
```

RSCRIPT

```
[1] 13 140
> shapiro.test(log_capitalhumano)

      Shapiro-Wilk normality test

data:  log_capitalhumano
W = 0.99114, p-value = 0.359
```

 DEPENDENCIA ESPACIAL

Partiendo de la idea de que una región puede estar afectada no solamente por otra región contigua o vecina, sino por otras que la rodean, al igual que ella puede afectar a las otras, se puede hablar de un efecto de dependencia espacial. Para la medición de la dependencia espacial se utilizará el Índice de Morán.

Para ello, se construyo la matriz de vecindad y se grafico la red de conexión de los centroides de los municipios del archivo shapefile

RSCRIPT

```
> #Matriz de vecindades
> pr.nb<-poly2nb(empleo,queen = TRUE)
> pr.nb
Neighbour list object:
Number of regions: 174
Number of nonzero links: 950
Percentage nonzero weights: 3.137799
Average number of links: 5.45977

> # Matriz de ponderacion W estandarizada
> wqueen <- nb2listw(pr.nb, style="W")
> wqueen
Characteristics of weights list object:
Neighbour list object:
Number of regions: 174
Number of nonzero links: 950
Percentage nonzero weights: 3.137799
Average number of links: 5.45977

Weights style: W
Weights constants summary:
      n   nn  S0      S1      S2
W 174 30276 174 70.54671 724.6509
> summary(wqueen)
Characteristics of weights list object:
Neighbour list object:
Number of regions: 174
```

RSCRIPT

```

Number of nonzero links: 950
Percentage nonzero weights: 3.137799
Average number of links: 5.45977
Link number distribution:

  1  2  3  4  5  6  7  8  9 10 11 14
  3  3 19 41 32 26 20 16  9  3  1  1
3 least connected regions:
76 94 120 with 1 link
1 most connected region:
116 with 14 links

Weights style: W
Weights constants summary:
      n    nn  S0      S1      S2
W 174 30276 174 70.54671 724.6509

> # Matriz de ponderacion B estandarizada
> Bqueen <- nb2listw(pr.nb, style="B")
> Bqueen
Characteristics of weights list object:
Neighbour list object:
Number of regions: 174
Number of nonzero links: 950
Percentage nonzero weights: 3.137799
Average number of links: 5.45977

Weights style: B
Weights constants summary:
      n    nn  S0    S1    S2
B 174 30276 950 1900 23712
> summary(Bqueen)
Characteristics of weights list object:
Neighbour list object:
Number of regions: 174
Number of nonzero links: 950
Percentage nonzero weights: 3.137799
Average number of links: 5.45977
Link number distribution:

  1  2  3  4  5  6  7  8  9 10 11 14
  3  3 19 41 32 26 20 16  9  3  1  1
3 least connected regions:
76 94 120 with 1 link
1 most connected region:
116 with 14 links

Weights style: B
Weights constants summary:
      n    nn  S0    S1    S2
B 174 30276 950 1900 23712

```

Para poder visualizar las conexiones geográficas identificadas se requiere la red de los centroides de los municipios y la relación con sus vecinos, de acuerdo con la matriz tipo W. En la Figura 6 se muestran los municipios con la mayor y menor cantidad de conexiones geográficas, se observan que las mayores conexiones ubican en los municipios del centro, mientras que los menos comunicados son los municipios de la periferia.

Conexiones geográficas entre municipios




Figura 6. Conexiones geográficas entre centroides de municipios.

RSCRIPT

```
> #relaciones de los centroides con sus vecinos  
> coordenadas_centroides<-coordinates(empleo)  
> plot(empleo, border="grey", lwd=1.5,main="Conexiones geográficas entr  
e municipios")  
> plot(pr.nb,coordenadas_centroides,add=TRUE,col="Red")  
> box()
```

Para probar si el empleo y el capital humano tienen dependencia espacial, se aplica la prueba de correlación espacial de Moran al logaritmo de la población ocupada y al logaritmo del capital humano. La prueba de hipótesis fue

H_0 : no existe autocorrelación espacial

H_a : lo contrario

Se estimo el índice tanto para la matriz W como para la matriz B en ambas variables; se obtuvo un pvalue menor a 0.05 en ambas variables y con diferentes matrices. Por lo cual se rechaza la hipótesis nula y al tener un índice positivo, se observa que los datos tienen a agruparse. La matriz tipo B mostro un índice de Moran mayor que el de la matriz W (Figura 7), por lo cual los análisis posteriores se realizarán utilizando la matriz tipo W.




Figura 7. Índice de Moran para matriz tipo W y B en ambas variables.

RSCRIPT

```
> #Autocorrelacion espacial
> #H0 la dependencia espacial =0 (no hay)
> #Ha existe correlacion espacial

> #tipow
> moran_logpocupada<-moran.test(log_pocupada,wqueen,randomisation = TR
UE,alternative = "two.sided",na.action = na.exclude)
> moran_logpocupada
```

Moran I test under randomisation

RSCRIPT

```

data: log_pocupada
weights: wqueen

Moran I statistic standard deviate = 12.466, p-value < 2.2e-16
alternative hypothesis: two.sided
sample estimates:
Moran I statistic      Expectation      Variance
0.587496960          -0.005780347      0.002264968

> moran.plot(log_pocupada,wqueen,pch=20,main="Log Población Ocupada -
Matriz W")
> moran_logcapitalhumano<-moran.test(log_capitalhumano,wqueen,randomis
ation=TRUE,alternative="two.sided",na.action=na.exclude)
> moran_logcapitalhumano

      Moran I test under randomisation

data: log_capitalhumano
weights: wqueen

Moran I statistic standard deviate = 14.843, p-value < 2.2e-16
alternative hypothesis: two.sided
sample estimates:
Moran I statistic      Expectation      Variance
0.698986435          -0.005780347      0.002254493

> moran.plot(log_capitalhumano,wqueen,pch=20,main="Log Capital Humano
- Matriz W")
> #tipoB
> moran_logpocupadaB<-moran.test(log_pocupada,Bqueen,randomisation = T
RUE,alternative = "two.sided",na.action = na.exclude)
> moran_logpocupadaB

      Moran I test under randomisation

data: log_pocupada
weights: Bqueen

Moran I statistic standard deviate = 13.944, p-value < 2.2e-16
alternative hypothesis: two.sided
sample estimates:
Moran I statistic      Expectation      Variance
0.621826240          -0.005780347      0.002025918

> moran.plot(log_pocupada,Bqueen,pch=20,main="Log Poblacion Ocupada -
Matriz B")
> moran_logcapitalhumanoB<-moran.test(log_capitalhumano,Bqueen,randomi
sation=TRUE,alternative="two.sided",na.action=na.exclude)
> moran_logcapitalhumanoB

      Moran I test under randomisation

data: log_capitalhumano
weights: Bqueen

Moran I statistic standard deviate = 15.008, p-value < 2.2e-16
alternative hypothesis: two.sided
sample estimates:
Moran I statistic      Expectation      Variance
0.668157722          -0.005780347      0.002016614

```

RSCRIPT

```
> moran.plot(log_capitalhumano,Bqueen,pch=20,main="Log Capital Humano
- Matriz B")
```

Para confirmar si existe correlación espacial global, es decir, en las variables originales, también se calculó el índice de moran, utilizando únicamente la matriz tipo W. Se obtuvo un pvalue menor a 0.05, por lo cual, las variables originales también tienen autocorrelación espacial (Figura 8).




Figura 8. Índice de Moran para variables originales con matriz tipo W

Se observan los datos agrupados en el cuadrante "Low-Low" para la variable de personas ocupadas, lo que indica que hay bajos niveles de empleo con vecinos que tienen también bajos niveles de empleo.

RSCRIPT

```
> #AUTOCORRELACION VARIABLES ORIGINALES (TIPOW)
> moran_pocupada<-moran.test(pocupada,wqueen,randomisation = TRUE,alter
native = "two.sided",na.action = na.exclude)

> moran_pocupada

Moran I test under randomisation

data: pocupada
weights: wqueen

Moran I statistic standard deviate = 11.36, p-value < 2.2e-16
alternative hypothesis: two.sided
sample estimates:
```

RSCRIPT		
Moran I statistic	Expectation	Variance
0.510531158	-0.005780347	0.002065878
<pre>> moran.plot(pocupada,wqueen,pch=20,main="Población Ocupada") > moran_capitalhumano<-moran.test(capitalhumano,wqueen,randomisation = TRUE,alternative = "two.sided",na.action = na.exclude) > moran_capitalhumano</pre>		
Moran I test under randomisation		
data: capitalhumano		
weights: wqueen		
Moran I statistic standard deviate = 14.652, p-value < 2.2e-16		
alternative hypothesis: two.sided		
sample estimates:		
Moran I statistic	Expectation	Variance
0.687457813	-0.005780347	0.002238704
<pre>> moran.plot(capitalhumano,wqueen,pch=20,main="Capital Humano")</pre>		

Para mostrar de manera visual como se distribuyen espacialmente ambas variables, se realizo una estratificación por el método de cuantiles y para la asignación de color se define una escalar de tonos de color rojos para el empleo y azules para el capital humano (Figura 9).




Figura 9. Estratificación por cuantiles de las variables transformadas.

Se observa que, para ambas variables, los valores altos se encuentran en el centro del polígono, que corresponde con las delegaciones de la Ciudad de México, mientras que los valores más bajos se distribuyen en la periferia.

RSCRIPT

```
> #Estratificación
> #mapa de cuantiles del logaritmo de empleo
> brks <- round(quantile(log_pocupada, probs=seq(0,1,0.25)), digits=2)
> colours <- brewer.pal(4,"Reds")
> plot(empleo, col=colours[findInterval(log_pocupada, brks, all.inside=TRUE)],axes=F)
> legend(x=-87.9, y=25.2, legend=leglabs(brks), fill=colours, bty="n")
> title("Población Ocupada - Log")
> box()
> # Mapa de cuantiles del logaritmo de capital humano
> brks <- round(quantile(log_capitalhumano, probs=seq(0,1,0.25)), digits=2)
> colours <- brewer.pal(4,"Blues")
> plot(empleo, col=colours[findInterval(log_capitalhumano, brks, all.inside=TRUE)],axes=F)
> legend(x=-87.9, y=25.2, legend=leglabs(brks), fill=colours, bty="n")
> title("Capital Humano - Log")
> box()
```

 MODELOS DE REGRESIÓN ESPACIAL

Una vez que se confirmó la dependencia espacial de los datos, es necesario especificar un modelo de regresión espacial que tome en cuenta dicha dependencia. Para ello se analizaron los seis casos:

- a) Modelo de regresión clásico sin efectos espaciales
- b) Modelo autorregresivo
- c) Modelo de error espacial autorregresivo
- d) Modelo Durbin Espacial
- e) Modelo Mixto Autorregresivo Espacial con errores espaciales autorregresivos (SARMA)
- f) Modelo Error Durbin Espacial

Para realizar los modelos se seguirá la siguiente estrategia de selección de modelos de Anselin, (Figura 10). De manera inicial se estimará el modelo con mínimos cuadrados ordinarios, posteriormente se utilizarán los multiplicadores de Lagrange. Si alguno resulta

significativo para elegir uno de los modelos, si ambos son significativos se prueban modelos robustos para realizar la selección.




Figura 10. Estrategia para la selección de modelos. Fuente: Anselin (2005)

o *Modelo Lineal - Mínimos cuadrados ordinarios*

Comenzando con el modelo de Mínimos Cuadrados, se utilizará la función lm. Los resultados indican que el logaritmo del capital humano sale significativo y presenta una elasticidad de 3.29. lo cual se concluye que la población ocupada es altamente sensible al capital humano de la población. Se lee como elasticidad por que las dos variables se encuentran transformadas en logaritmos.

```

RSCRIPT

> #MODELO DE MINIMOS CUADRADOS ORDINARIOS
> #Regresion lineal
> MinimosCuadrados<-lm(log_pocupada~log_capitalhumano,data=empleo)
> summary(MinimosCuadrados)

Call:
lm(formula = log_pocupada ~ log_capitalhumano, data = empleo)

Residuals:
    Min       1Q   Median       3Q      Max
-4.3948 -0.8243  0.0286  0.7611  2.8910

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    3.8775     0.6763   5.734 4.33e-08 ***
log_capitalhumano 3.2969     0.3680   8.960 5.26e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.2 on 172 degrees of freedom
Multiple R-squared:  0.3182,    Adjusted R-squared:  0.3142
F-statistic: 80.27 on 1 and 172 DF,  p-value: 5.264e-16

```

Posteriormente se realizará la prueba de autocorrelación espacial para los residuales, obteniendo un valor significativo. Por lo cual hay autocorrelación espacial.

```

RSCRIPT

> #prueba de moran a residuales
> moran_residuales<-lm.morantest(MinimosCuadrados,wqueen)
> moran_residuales #hay autocorrelacion

Global Moran I for regression residuals

data:
model: lm(formula = log_pocupada ~ log_capitalhumano, data = empleo)
weights: wqueen

Moran I statistic standard deviate = 8.0244, p-value = 5.1e-16
alternative hypothesis: greater
sample estimates:
Observed Moran I      Expectation      Variance
  0.368395591      -0.009877828      0.002222204

```

o *Multiplicadores de Lagrange*

Dado que existe autocorrelación espacial en los residuales, se estimarán los multiplicadores de Lagrange, se obtendrá el Error Espacial, el Error Robusto, el Lag Espacial, el Lag Robusto y el SARMA.

Se observa que tanto el error espacial como el Lag Espacial, sale un pvalue significativo. Si se observan los robustos, el error espacial deja de ser significativo y el Lag espacial continúa siendo significativo, por lo cual, al parecer el mejor modelo es Lag Espacial Robusto.

RSCRIPT

```
> #utilizando multiplicadores de Lagrange  
> lm.LMtests(MinimosCuadrados,wqueen,test = c("LMerr","RLMerr","LMlag",  
"RLmlag","SARMA"))
```

Lagrange multiplier diagnostics for spatial dependence

```
data:  
model: lm(formula = log_pocupada ~ log_capitalhumano, data = empleo)  
weights: wqueen
```

LMerr = 58.244, df = 1, p-value = 2.32e-14

Lagrange multiplier diagnostics for spatial dependence

```
data:  
model: lm(formula = log_pocupada ~ log_capitalhumano, data = empleo)  
weights: wqueen
```

RLMerr = 0.0032553, df = 1, p-value = 0.9545

Lagrange multiplier diagnostics for spatial dependence

```
data:  
model: lm(formula = log_pocupada ~ log_capitalhumano, data = empleo)  
weights: wqueen
```

LMlag = 70.722, df = 1, p-value < 2.2e-16

Lagrange multiplier diagnostics for spatial dependence

```
data:  
model: lm(formula = log_pocupada ~ log_capitalhumano, data = empleo)  
weights: wqueen
```

RLmlag = 12.482, df = 1, p-value = 0.0004109 MEJOR MODELO!!!!!!!!!!!!!!

RSCRIPT
Lagrange multiplier diagnostics for spatial dependence <pre>data: model: lm(formula = log_pocupada ~ log_capitalhumano, data = empleo) weights: wqueen</pre> SARMA = 70.726, df = 2, p-value = 4.441e-16

o *Estimación de modelos espaciales*

Se estimaron todos los modelos, para el modelo de Error espacial se obtiene un Rho significativo de 0.67, además se corrigió la autocorrelación espacial en los errores. Lo anterior significa que el porcentaje que explica el promedio de los vecinos de la variable dependiente, es decir que la población ocupada esta explicada también por la población ocupada de los vecinos en un 67%.

RSCRIPT
<pre>> #MODELOS ESPACIALES > #Modelo de rezago espacial > ModeloEmpleo_lag <- lagsarlm(log_pocupada ~ log_capitalhumano, data=empleo, wqueen) > summary(ModeloEmpleo_lag)</pre>
Call:lagsarlm(formula = log_pocupada ~ log_capitalhumano, data = empleo, listw = wqueen)
Residuals:
Min 1Q Median 3Q Max
-3.1783841 -0.5655122 -0.0045741 0.5698724 2.4373878
Type: lag
Coefficients: (asymptotic standard errors)
Estimate Std. Error z value Pr(> z)
(Intercept) 0.73366 0.61410 1.1947 0.2322
log_capitalhumano 1.32893 0.32970 4.0307 5.562e-05
Rho: 0.67009, LR test value: 65.113, p-value: 6.6613e-16
Asymptotic standard error: 0.06377
z-value: 10.508, p-value: < 2.22e-16
Wald statistic: 110.42, p-value: < 2.22e-16
Log likelihood: -245.0376 for lag model
ML residual variance (sigma squared): 0.87624, (sigma: 0.93607)
Number of observations: 174
Number of parameters estimated: 4
AIC: 498.08, (AIC for lm: 561.19)

RSCRIPT
LM test for residual autocorrelation test value: 0.11791, p-value: 0.73132

Para el modelo de Error Espacial, se obtiene una lambda de 0.71 y también es significativo, lo que se puede interpretar como: "el empleo se explica por variables que no están en el modelo de los vecinos".

RSCRIPT															
<pre>> # Estimar el modelo de Error Espacial > ModeloEmpleo_err <- errorsarlm(log_pocupada ~ log_capitalhumano, data =empleo,wqueen) > summary(ModeloEmpleo_err)</pre>															
Call:errorsarlm(formula = log_pocupada ~ log_capitalhumano, data = empl eo, listw = wqueen)															
Residuals:															
<table><tr><td>Min</td><td>1Q</td><td>Median</td><td>3Q</td><td>Max</td></tr><tr><td>-3.229495</td><td>-0.603003</td><td>0.050277</td><td>0.613023</td><td>2.550370</td></tr></table>	Min	1Q	Median	3Q	Max	-3.229495	-0.603003	0.050277	0.613023	2.550370					
Min	1Q	Median	3Q	Max											
-3.229495	-0.603003	0.050277	0.613023	2.550370											
Type: error															
Coefficients: (asymptotic standard errors)															
<table><tr><td></td><td>Estimate</td><td>Std. Error</td><td>z value</td><td>Pr(> z)</td></tr><tr><td>(Intercept)</td><td>6.47006</td><td>0.94208</td><td>6.8679</td><td>6.516e-12</td></tr><tr><td>log_capitalhumano</td><td>1.64366</td><td>0.49579</td><td>3.3152</td><td>0.0009157</td></tr></table>		Estimate	Std. Error	z value	Pr(> z)	(Intercept)	6.47006	0.94208	6.8679	6.516e-12	log_capitalhumano	1.64366	0.49579	3.3152	0.0009157
	Estimate	Std. Error	z value	Pr(> z)											
(Intercept)	6.47006	0.94208	6.8679	6.516e-12											
log_capitalhumano	1.64366	0.49579	3.3152	0.0009157											
Lambda: 0.71817, LR test value: 58.604, p-value: 1.9318e-14															
Asymptotic standard error: 0.061095															
z-value: 11.755, p-value: < 2.22e-16															
Wald statistic: 138.18, p-value: < 2.22e-16															
Log likelihood: -248.2923 for error model															
ML residual variance (sigma squared): 0.89031, (sigma: 0.94356)															
Number of observations: 174															
Number of parameters estimated: 4															
AIC: 504.58, (AIC for lm: 561.19)															

Para los modelos de rezago y Error Espacial al mismo tiempo se utiliza el modelo SARAR, se tiene un Rho, que representa el lag espacial, de 0.70 y es significativo. Por otro lado, la lambda, que representa el error espacial, no sale significativa, lo que comprueba que en efecto, el mejor modelo es el de Rezago Espacial.

```

RSCRIPT

> # Estimar modelo SARAR
> ModeloEmpleo_sarar <- sacsarlml(log_pocupada ~ log_capitalhumano, data
=empleo, wqueen, type="sac")
> summary(ModeloEmpleo_sarar)

Call:sacsarlml(formula = log_pocupada ~ log_capitalhumano, data = empleo
'
  listw = wqueen, type = "sac")

Residuals:
      Min       1Q   Median       3Q      Max
-3.142804 -0.581190 -0.016665  0.575159  2.415785

Type: sac
Coefficients: (asymptotic standard errors)
              Estimate Std. Error z value Pr(>|z|)
(Intercept)    0.56642    0.74371  0.7616 0.446294
log_capitalhumano 1.24960    0.41976  2.9770 0.002911

Rho: 0.70235
Asymptotic standard error: 0.11906
      z-value: 5.899, p-value: 3.6575e-09
Lambda: -0.073671
Asymptotic standard error: 0.24171
      z-value: -0.30479, p-value: 0.76053

LR test value: 65.214, p-value: 6.8834e-15

Log likelihood: -244.9869 for sac model
ML residual variance (sigma squared): 0.86265, (sigma: 0.92879)
Number of observations: 174
Number of parameters estimated: 5
AIC: 499.97, (AIC for lm: 561.19)

```

Por último, se estimo el modelo Durbi, que añade un rezago a la variable capital humano, se obtiene un pvalue que muestra que no es significativo, por lo que se concluye que al no aportar información nueva, el mejor modelo es el de REZAGO ESPACIAL

```

RSCRIPT

> #Estimar el modelo de Durbin Rezago Espacial
> ModeloEmpleo_lag_durbin <- lagsarlml(log_pocupada ~ log_capitalhumano,
data=empleo,wqueen, type="mixed")
> summary(ModeloEmpleo_lag_durbin)

Call:lagsarlml(formula = log_pocupada ~ log_capitalhumano, data = empleo
'
  listw = wqueen, type = "mixed")

```

RSCRIPT

Residuals:

Min	1Q	Median	3Q	Max
-3.059210	-0.599797	-0.023718	0.585009	2.417886

Type: mixed

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.54567	0.67171	0.8124	0.41659
log_capitalhumano	1.03039	0.55554	1.8547	0.06363
lag.log_capitalhumano	0.50523	0.71928	0.7024	0.48242

Rho: 0.6515, LR test value: 52.636, p-value: 4.0157e-13

Asymptotic standard error: 0.06901

z-value: 9.4407, p-value: < 2.22e-16

Wald statistic: 89.127, p-value: < 2.22e-16

Log likelihood: -244.8002 for mixed model

ML residual variance (sigma squared): 0.88042, (sigma: 0.93831)

Number of observations: 174

Number of parameters estimated: 5

AIC: 499.6, (AIC for lm: 550.24)

LM test for residual autocorrelation

test value: 0.024694, p-value: 0.87513

RSCRIPT

```
> #Estimar el modelo de Durbin Error Espacial
> ModeloEmpleo_err_durbin <- errorsarlm(log_pocupada ~ log_capitalhuman
o, data=empleo,wqueen, etype="emixed")
> summary(ModeloEmpleo_err_durbin)
```

```
Call:errorsarlm(formula = log_pocupada ~ log_capitalhumano, data = empl
eo,
  listw = wqueen, etype = "emixed")
```

Residuals:

Min	1Q	Median	3Q	Max
-3.127211	-0.570143	-0.040392	0.575190	2.423206

Type: error

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	2.62363	1.52942	1.7154	0.086264
log_capitalhumano	1.35737	0.50232	2.7022	0.006888
lag.log_capitalhumano	2.47167	0.86244	2.8659	0.004158

Lambda: 0.65455, LR test value: 52.865, p-value: 3.5738e-13

Asymptotic standard error: 0.069289

z-value: 9.4467, p-value: < 2.22e-16

Wald statistic: 89.24, p-value: < 2.22e-16

Log likelihood: -244.6857 for error model

RSCRIPT

```

ML residual variance (sigma squared): 0.87821, (sigma: 0.93713)
Number of observations: 174
Number of parameters estimated: 5
AIC: 499.37, (AIC for lm: 550.24)

> #Comparar modelos de error espacial y durbin error espacial
> #(Hipoteis nula son iguales), con pruebas de Razon de Verosimilitud
> LR.sarlm(ModeloEmpleo_err_durbin, ModeloEmpleo_err)

Likelihood ratio for spatial linear models

data:
Likelihood ratio = 7.2132, df = 1, p-value = 0.007237
sample estimates:
Log likelihood of ModeloEmpleo_err_durbin
-244.6857
Log likelihood of ModeloEmpleo_err
-248.2923

> #Comparar modelos de rezago espacial y durbin rezago espacial
> #(Hipoteis nula son iguales), con pruebas de Razon de Verosimilitud
> LR.sarlm(ModeloEmpleo_lag_durbin, ModeloEmpleo_lag)

Likelihood ratio for spatial linear models

data:
Likelihood ratio = 0.47491, df = 1, p-value = 0.4907
sample estimates:
Log likelihood of ModeloEmpleo_lag_durbin
-244.8002
Log likelihood of ModeloEmpleo_lag
-245.0376

> #Probar la hipotesis de factor comun
> durbin.test1 <- LR.sarlm(ModeloEmpleo_lag_durbin, ModeloEmpleo_err)
> print(durbin.test1)

Likelihood ratio for spatial linear models

data:
Likelihood ratio = 6.9842, df = 1, p-value = 0.008223
sample estimates:
Log likelihood of ModeloEmpleo_lag_durbin
-244.8002
Log likelihood of ModeloEmpleo_err
-248.2923

> 1 - pchisq(durbin.test1[[1]][1],2)
Likelihood ratio
0.0304362

> #Comparar modeloss con ANOVA
> anova(ModeloEmpleo_lag, ModeloEmpleo_lag_durbin)

```

	Model	df	AIC	logLik	Test	L.Ratio	p-value
ModeloEmpleo_lag	1	4	498.08	-245.04	1		
ModeloEmpleo_lag_durbin	2	5	499.60	-244.80	2	0.47491	0.49074

RSCRIPT

```
> #Breusch-Pagan test para modelos espaciales  
> bptest.sarlm(ModeloEmpleo_lag, studentize=FALSE)
```

Breusch-Pagan test

data:

BP = 6.5471, df = 1, p-value = 0.01051